ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN – TIN HỌC



NGUYỄN LÊ ĐĂNG KHOA – PHAN GIA THIÊN

XÂY DỰNG HỆ THỐNG HỖ TRỢ CHẨN ĐOÁN KHẢ NĂNG MẮC BỆNH UNG THƯ DA

ĐỒ ÁN TỐT NGHIỆP CỬ NHÂN

Tp. Hồ Chí Minh – 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN – TIN HỌC



NGUYỄN LÊ ĐĂNG KHOA – 22280047
PHAN GIA THIÊN – 22280085

XÂY DỰNG HỆ THỐNG HỖ TRỢ CHẨN ĐOÁN KHẢ NĂNG MẮC BỆNH UNG THƯ DA

ĐỒ ÁN TỐT NGHIỆP CỬ NHÂN

CHUYÊN NGÀNH KHOA HỌC DỮ LIỆU

NGƯỜI HƯỚNG DẪN KHOA HỌC
TS. HUỲNH THẾ ĐĂNG

Tp. Hồ Chí Minh – 2026

Lời cảm ơn

Lời đầu tiên, chúng em xin phép được gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy TS. Huỳnh Thế Đăng, là người đã trực tiếp hướng dẫn và tận tình chỉ bảo chúng em trong suốt quá trình thực hiện đồ án này. Những định hướng quý báu về chuyên môn và phương pháp nghiên cứu khoa học của Thầy là kim chỉ nam giúp chúng em tiếp cận bài toán một cách hệ thống và hoàn thiện báo cáo về hệ thống hỗ trợ chẩn đoán khả năng mắc bệnh ung thư da với chất lượng tốt nhất có thể.

Chúng em cũng xin gửi lời tri ân sâu sắc nhất đến Quý Thầy Cô Khoa Toán – Tin học, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM, những người đã trang bị cho chúng em nền tảng kiến thức vững chắc về Khoa học Dữ liệu và các lĩnh vực liên quan trong suốt những năm học vừa qua.

Ngoài ra, chúng em xin bày tỏ lòng biết ơn đến tổ chức ISIC (International Skin Imaging Collaboration) và cộng đồng nghiên cứu quốc tế, những người đã cung cấp bộ dữ liệu SLICE-3D cùng các tài nguyên mã nguồn mở quý giá. Đây là cơ sở quan trọng và đáng tin cậy để chúng em thực nghiệm, kiểm chứng và đánh giá các phương pháp đề xuất trong báo cáo này.

Dù đã nỗ lực hết mình trong suốt quá trình thực hiện, bài báo cáo này vẫn khó tránh khỏi những hạn chế và thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp quý báu, những lời nhận xét chân thành từ Thầy Cô giáo viên hướng dẫn và các bạn sinh viên, để đề tài có thể được hoàn thiện hơn nữa và góp phần vào sự phát triển của lĩnh vực này.

Chúng em xin chân thành cảm ơn.

Tp.HCM, ngày 09 tháng 07 năm 2026

Tác giả

Nguyễn Lê Đăng Khoa Phan Gia Thiên

Mục lục

Danh mục hình vẽ **7**

Danh mục bảng **8**

Danh mục ký hiệu, chữ viết tắt và chú thích thuật ngữ **10**

Danh mục ký hiệu 10

Danh mục chữ viết tắt 10

Chú thích thuật ngữ 13

Lời nói đầu **15**

1 GIỚI THIỆU **16**

1.1 Bối cảnh bài toán 16

1.2 Những thách thức trong phát hiện sớm ung thư da 17

1.3 Sự phát triển của 3D Total Body Photography và bộ dữ liệu ISIC 2024 18

1.4 Động cơ và khoảng trống nghiên cứu 19

1.5 Phát biểu bài toán 20

1.6 Mục tiêu nghiên cứu 21

1.7 Phạm vi nghiên cứu 22

1.8 Đóng góp của đồ án 22

2 CƠ SỞ KHOA HỌC CHO MÔ HÌNH ĐỀ XUẤT **24**

2.1 Kiến thức miền trong phát hiện ung thư da 24

2.1.1 Quy tắc ABCDE 25

2.1.2 Dấu hiệu Ugly Duckling 26

2.1.3 Thông tin ở mức bệnh nhân (Patient Context) 28

2.2 Học sâu cho dữ liệu bảng 30

2.2.1 Đặc điểm của dữ liệu bảng 31

2.2.2 Sự phát triển của học sâu cho dữ liệu bảng 32

2.2.3 Tiêu chí lựa chọn mô hình học sâu cho dữ liệu bảng 33

2.2.4 Mô hình TabM 34

2.2.4.1 Tổng quan về TabM 34

2.2.4.2 Vì sao lựa chọn TabM trong đồ án 35
2.3 Học biểu diễn đa phương thức 36
2.3.1 Học biểu diễn (Representation Learning) 36
2.3.2 Học đa phương thức (Multimodal Learning) 37
2.3.3 Tương tác giữa các phương thức (Cross-modal Interaction) 38
2.3.4 Cơ chế Cross-Attention 39
2.4 Phương pháp đánh giá mô hình 41
2.4.1 Ma trận nhầm lẫn (Confusion Matrix) 41
2.4.2 Đường cong ROC 42
2.4.3 Diện tích dưới đường cong ROC (AUC) 42
2.4.4 Partial Area Under the ROC Curve (pAUC) 43

3 HIỆN THỰC HỆ THỐNG 45

3.1 Ký hiệu toán học 45
3.2 Kiến trúc tổng thể hệ thống 45
3.3 Bộ dữ liệu & Phân tích dữ liệu 47
3.4 Knowledge-guided Feature Engineering 50
3.4.1 Đặc trưng nội tại nốt ruồi (ABCD) — 69 đặc trưng 51
3.4.2 Chuẩn hóa mức bệnh nhân (Patient Norm) — 109 đặc trưng 51
3.4.3 Ngoại lai và Giải phẫu học (UD Advanced) — 116 đặc trưng 51
3.4.4 Ngữ cảnh tương tác phân loại (Categorical Context) — 318 đặc trưng . 52
3.4.5 Kiểm soát đa cộng tuyến và rủi ro quá khớp (Overfitting) 53
3.5 Quy trình tiền xử lý dữ liệu bảng 54
3.6 Image Representation Learning 56
3.6.1 Chuẩn hóa màu sắc (Shades of Gray Color Constancy) 56
3.6.2 Tăng cường dữ liệu (Image Augmentation) 57
3.6.3 Mạng trích xuất đặc trưng (Backbone Encoder) 57
3.7 Patient Representation Learning (TabM) 58
3.7.1 Piecewise Linear Embedding (PLE) 58
3.7.2 TabM Architecture 58
3.8 Cross-modal Fusion — Cross-Attention 58
3.8.1 Kỹ thuật K-Expansion 59
3.8.2 Cross-Attention Fusion Architecture 59
3.8.3 Gated Multimodal Unit (GMU) và Concatenation 60

3.9 Chiến lược huấn luyện & Tối ưu hóa siêu tham số 60
3.9.1 Huấn luyện phân tầng (Staged Pretraining) 60
3.9.2 Biện pháp chống sụp đổ phương thức (Anti-Modality-Collapse) 61
3.9.3 Lấy mẫu và Hàm mất mát 61
3.9.4 Tối ưu hóa 62
3.9.5 Tối ưu hóa siêu tham số (Hyperparameter Tuning) 62
3.10 Tóm tắt chương 62

4 KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ 64
4.1 Kết quả huấn luyện mô hình đề xuất 64
4.1.1 Môi trường thực nghiệm 64
4.1.2 Thiết lập dữ liệu 64
4.1.3 Cấu hình huấn luyện 65
4.1.3.1 Giai đoạn 1: Huấn luyện TabM 65
4.1.3.2 Giai đoạn 2: Huấn luyện EfficientNet 66
4.1.3.3 Giai đoạn 3: Huấn luyện Fusion Layer 66
4.1.3.4 Giai đoạn 3B: Fine-tuning toàn bộ 66
4.1.3.5 Chiến lược chung cho tất cả giai đoạn 67
4.1.4 Quy trình đánh giá trên tập kiểm tra 67
4.1.5 Tiến trình phát triển mô hình và Ablation Study 68
4.2 Đánh giá mô hình 68
4.2.1 Kết quả nhánh dữ liệu bảng (Tabular Branch) 69
4.2.2 Kết quả nhánh hình ảnh (Image Branch) 69
4.2.3 Kết quả tối ưu hóa Tầng kết hợp (Fusion) và Chiến lược huấn luyện . . 69
4.3 So sánh với các nghiên cứu liên quan 70
4.4 Phân tích 70
4.4.1 Phân tích kết quả nội bộ 70
4.4.1.1 Đóng góp của Feature Engineering (KFE) 70
4.4.1.2 So sánh nhánh đơn phương thức 71
4.4.1.3 Vì sao Concatenation vượt trội hơn Cross-Attention và GMU 71
4.4.1.4 Vai trò của chiến lược Staged Pretraining 72
4.4.1.5 Lựa chọn cấu hình cuối cùng 72

5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 73

5.1 Kết luận 73
5.2 Hạn chế 74
5.3 Hướng phát triển 75

A Phụ lục **77**
A.1 Danh mục biến metadata gốc của ISIC 2024 77
A.2 Mã nguồn dự án 80

TÀI LIỆU THAM KHẢO **81**

Danh sách hình vẽ

2.1 Quy tắc ABCDE trong đánh giá tổn thương da 26
2.2 Minh họa nguyên lý của dấu hiệu Ugly Duckling 28
2.3 Vai trò của Patient Context trong đánh giá tổn thương da 30
2.4 Nguyên lý của Cross-Attention 41

3.1 Kiến trúc tổng thể hệ thống học sâu đa phương thức. 46
3.2 Luồng tiền xử lý dữ liệu bảng 55
3.3 Quy trình huấn luyện phân tầng 4 bước. 60

Danh sách bảng

1.1 So sánh dữ liệu truyền thống và dữ liệu 3D-TBP 19

2.1 So sánh các chiến lược kết hợp đa phương thức 39

3.1 Bảng ký hiệu toán học 45
3.2 Thống kê tổng quan bộ dữ liệu ISIC 2024 47
3.3 Tóm tắt các nhóm thuộc tính metadata gốc của ISIC 2024. 49
3.4 Tổng hợp cấu hình đặc trưng đầu vào mạng TabM (Baseline & Ablation) 53
3.5 Danh sách các phép tăng cường dữ liệu ảnh (Training Pipeline) 57
3.6 Các siêu tham số của mạng TabM 59
3.7 Các siêu tham số của mô-đun Cross-Attention Fusion 60
3.8 Thiết lập cấu hình cho các giai đoạn huấn luyện (Staged Pretraining) 61
3.9 Tổng hợp các siêu tham số huấn luyện cốt lõi 62

4.1 Cấu hình môi trường thực nghiệm trên Kaggle Notebook 64
4.2 Chi tiết số lượng mẫu và bệnh nhân sau khi chia 5 fold (Test set được Kaggle ẩn cho quá trình chấm điểm). 64
4.3 Siêu tham số cấu trúc mạng TabM và PLE 65
4.4 Siêu tham số huấn luyện mô hình TabM (Stage 1) 65
4.5 Siêu tham số huấn luyện nhánh ảnh EfficientNet (Stage 2) 66
4.6 Siêu tham số khởi tạo nhánh đa phương thức (Stage 3A) 66
4.7 Siêu tham số fine-tuning toàn bộ mạng đa phương thức (Stage 3B) 67
4.8 Các phiên bản thử nghiệm (Ablation Study) trong tiến trình phát triển hệ thống. 68
4.9 So sánh pAUC giữa TabM sử dụng biến gốc và TabM kết hợp bộ đặc trưng kỹ nghệ (KFE). 69
4.10 Hiệu suất pAUC của nhánh hình ảnh độc lập (EfficientNet-B0). 69
4.11 So sánh pAUC trên tập kiểm tra chính thức Kaggle giữa các cơ chế kết hợp đa phương thức. 69
4.12 Kết quả pAUC (>80% TPR, Private set) tham chiếu từ báo cáo chính thức ISIC 2024. 70

A.1 Danh mục biến metadata gốc (khả dụng ở cả train và test) — ISIC 2024. 77

DANH MỤC KÝ HIỆU, CHỮ VIẾT TẮT VÀ CHÚ THÍCH THUẬT NGỮ

Danh mục ký hiệu

Ký hiệu	Ý nghĩa
$\mathbf{I}$	Ảnh chụp tổn thương da đầu vào.
$\mathbf{x}$	Vector dữ liệu dạng bảng (metadata) của một mẫu.
y	Nhãn thực tế của mẫu, với $y = 1$ là ác tính và $y = 0$ là lành tính.
$\hat{y}$	Xác suất mô hình dự đoán mẫu thuộc lớp ác tính.
h_{img}	Biểu diễn đặc trưng được trích xuất từ nhánh hình ảnh.
h_{tab}	Biểu diễn đặc trưng được trích xuất từ nhánh dữ liệu bảng.
h_{fusion}	Biểu diễn đa phương thức sau khi kết hợp hai nhánh.
B	Kích thước lô dữ liệu (batch size).
K	Số lượng mô hình con trong cấu trúc ensemble của TabM.
L	Số lượng token không gian được tạo từ ảnh.
d_{img}	Số chiều của biểu diễn đặc trưng ảnh.
d_{tab}	Số chiều của biểu diễn đặc trưng dữ liệu bảng.
d_{fusion}	Số chiều của không gian biểu diễn đa phương thức.
max_fpr	Ngưỡng tỷ lệ dương tính giả tối đa được sử dụng khi tính pAUC.
$pAUC_{scaled}$	Giá trị pAUC đã chuẩn hóa do thư viện đánh giá trả về.
$pAUC_{raw}$	Diện tích riêng phần thô dưới đường cong ROC sau khi giải chuẩn hóa.

Danh mục chữ viết tắt

Viết tắt	Cụm từ đầy đủ	Diễn giải tiếng Việt
3D-TBP	3D Total Body Photography	Công nghệ chụp ảnh toàn thân ba chiều.
ABCD	Asymmetry, Border, Color, Diameter	Quy tắc đánh giá bất đối xứng, bờ, màu sắc và đường kính tổn thương.
ABCDE	Asymmetry, Border, Color, Diameter, Evolution	Quy tắc ABCD có bổ sung yếu tố tiến triển theo thời gian.
AI	Artificial Intelligence	Trí tuệ nhân tạo.
API	Application Programming Interface	Giao diện lập trình ứng dụng.
AUC	Area Under the ROC Curve	Diện tích dưới đường cong ROC.
BCE	Binary Cross-Entropy	Hàm mất mát entropy chéo nhị phân.
CAT	Categorical Feature	Biến hoặc đặc trưng phân loại.
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập.
CLAHE	Contrast Limited Adaptive Histogram Equalization	Cân bằng lược đồ xám thích nghi có giới hạn tương phản.
CPU	Central Processing Unit	Bộ xử lý trung tâm.
CUDA	Compute Unified Device Architecture	Nền tảng tính toán song song trên GPU của NVIDIA.
FN	False Negative	Mẫu dương tính bị dự đoán nhầm thành âm tính.
FP	False Positive	Mẫu âm tính bị dự đoán nhầm thành dương tính.
FPR	False Positive Rate	Tỷ lệ dương tính giả.
GBDT	Gradient Boosting Decision Trees	Nhóm mô hình cây quyết định tăng cường.
GMU	Gated Multimodal Unit	Khối kết hợp đa phương thức sử dụng cơ chế cổng.
Grad-CAM	Gradient-weighted Class Activation Mapping	Phương pháp trực quan hóa vùng ảnh ảnh hưởng đến dự đoán của mạng.

Viết tắt	Cụm từ đầy đủ	Diễn giải tiếng Việt
GPU	Graphics Processing Unit	Bộ xử lý đồ họa.
HDF5	Hierarchical Data Format version 5	Định dạng tệp phân cấp dùng để lưu trữ và truy xuất dữ liệu lớn.
IARC	International Agency for Research on Cancer	Cơ quan Nghiên cứu Ung thư Quốc tế.
ISIC	International Skin Imaging Collaboration	Tổ chức hợp tác quốc tế về hình ảnh da.
KFE	Knowledge-guided Feature Engineering	Kỹ nghệ đặc trưng có định hướng bởi tri thức miền.
LOF	Local Outlier Factor	Thuật toán phát hiện ngoại lai cục bộ.
LOO	Leave-One-Out	Cách tính thống kê sau khi loại chính mẫu đang xét khỏi nhóm tham chiếu.
MLP	Multilayer Perceptron	Mạng nơ-ron truyền thẳng nhiều lớp.
NMSC	Non-Melanoma Skin Cancer	Ung thư da không phải melanoma.
NUM	Numerical Feature	Biến hoặc đặc trưng số.
pAUC	Partial Area Under the ROC Curve	Diện tích riêng phần dưới đường cong ROC.
PLE	Piecewise Linear Embedding	Phương pháp nhúng tuyến tính từng đoạn.
RAM	Random Access Memory	Bộ nhớ truy cập ngẫu nhiên.
ROC	Receiver Operating Characteristic	Đường cong biểu diễn quan hệ giữa TPR và FPR.
SHAP	SHapley Additive exPlanations	Phương pháp giải thích đóng góp của đặc trưng dựa trên giá trị Shapley.
SLICE-3D	Skin Lesion Image Crops Extracted from 3D-TBP	Bộ ảnh cắt tổn thương da được trích xuất từ dữ liệu 3D-TBP.
TN	True Negative	Mẫu âm tính được dự đoán đúng.

Viết tắt	Cụm từ đầy đủ	Diễn giải tiếng Việt
TP	True Positive	Mẫu dương tính được dự đoán đúng.
TPR	True Positive Rate	Tỷ lệ dương tính thật, còn gọi là độ nhạy.
UD	Ugly Duckling	Nhóm đặc trưng dựa trên dấu hiệu *vịt con xấu xí*.
UV	Ultraviolet	Tia cực tím.
VRAM	Video Random Access Memory	Bộ nhớ đồ họa của GPU.
WB360	Whole Body 360	Dữ liệu/ngữ cảnh ảnh toàn thân 360 độ.

Chú thích thuật ngữ

Thuật ngữ	Chú thích
Ablation Study	Thực nghiệm loại bỏ hoặc thay đổi từng thành phần để định lượng mức đóng góp của thành phần đó đối với hiệu suất chung.
Backbone	Mạng nền dùng để trích xuất đặc trưng ban đầu từ dữ liệu, chẳng hạn EfficientNet-B0 đối với ảnh.
Cross-Attention	Cơ chế chú ý trong đó biểu diễn của một phương thức được dùng để truy vấn và tương tác với biểu diễn của phương thức còn lại.
Data leakage	Hiện tượng thông tin từ tập kiểm tra hoặc tập xác thực vô tình xuất hiện trong quá trình huấn luyện, làm kết quả đánh giá bị lạc quan sai lệch.
Early stopping	Kỹ thuật dừng huấn luyện khi chỉ số trên tập xác thực không còn cải thiện sau một số epoch nhất định.

Thuật ngữ	Chú thích
Ensemble	Phương pháp kết hợp dự đoán hoặc biểu diễn của nhiều mô hình con để tăng độ ổn định và khả năng tổng quát hóa.
Feature Engineering	Quá trình xây dựng, biến đổi hoặc lựa chọn đặc trưng đầu vào dựa trên dữ liệu và tri thức miền.
Fine-tuning	Quá trình tinh chỉnh trọng số của mô hình đã được huấn luyện trước bằng tốc độ học nhỏ hơn.
Fold	Một phần dữ liệu trong quy trình kiểm định chéo; lần lượt được dùng làm tập xác thực trong khi các phần còn lại dùng để huấn luyện.
Fusion	Quá trình kết hợp thông tin từ nhiều phương thức dữ liệu, trong đồ án là hình ảnh và metadata.
Metadata	Dữ liệu có cấu trúc mô tả bệnh nhân hoặc tổn thương, chẳng hạn tuổi, giới tính, vị trí giải phẫu và các chỉ số hình thái.
Modality collapse	Hiện tượng mô hình đa phương thức phụ thuộc quá mức vào một nhánh và gần như bỏ qua thông tin từ nhánh còn lại.
Patient context	Thông tin ngữ cảnh ở mức bệnh nhân, được hình thành từ nhiều tổn thương và đặc điểm lâm sàng của cùng một người.
Patient normalization	Chuẩn hóa đặc trưng của từng tổn thương so với phân bố các tổn thương khác trên cùng bệnh nhân.
StratifiedGroupKFold	Phương pháp chia dữ liệu vừa duy trì tương đối tỷ lệ lớp, vừa bảo đảm các mẫu của cùng một bệnh nhân không xuất hiện ở nhiều tập khác nhau.
Ugly Duckling	Dấu hiệu lâm sàng cho rằng một tổn thương khác biệt rõ so với các tổn thương còn lại trên cùng bệnh nhân có thể cần được chú ý hơn.
Undersampling	Kỹ thuật giảm số mẫu của lớp chiếm đa số nhằm hạn chế mất cân bằng dữ liệu khi huấn luyện.

Lời nói đầu

Ung thư da là một trong những loại ung thư phổ biến, và việc phát hiện sớm đóng vai trò quan trọng trong việc nâng cao hiệu quả điều trị. Đồ án này trình bày quá trình xây dựng một hệ thống hỗ trợ chẩn đoán khả năng mắc bệnh ung thư da dựa trên phương pháp học sâu đa phương thức (multimodal deep learning), kết hợp thông tin từ hình ảnh tổn thương da và dữ liệu lâm sàng có cấu trúc.

Nội dung đồ án bao gồm các chương sau:

Chương 1: Giới thiệu tổng quan về bài toán, động lực nghiên cứu và mục tiêu của đồ án.

Chương 2: Trình bày cơ sở lý thuyết liên quan đến các kiến trúc học sâu, phương pháp trích xuất đặc trưng hình ảnh và dữ liệu bảng được sử dụng.

Chương 3: Trình bày chi tiết quá trình xây dựng hệ thống, bao gồm kiến trúc mô hình, chiến lược huấn luyện và các thử nghiệm thực hiện.

Chương 4: Trình bày kết quả thực nghiệm, đánh giá và thảo luận.

Chương 5: Kết luận và hướng phát triển.

Chương 1

GIỚI THIỆU

1.1 Bối cảnh bài toán

Ung thư da là một trong những loại ung thư phổ biến nhất trên thế giới và được chia thành hai nhóm chính gồm ung thư da không phải melanoma (Non-Melanoma Skin Cancer - NMSC) và ung thư hắc tố (Melanoma) [1]. Mặc dù melanoma chỉ chiếm khoảng 1% tổng số trường hợp ung thư da nhưng lại gây ra phần lớn các ca tử vong do khả năng xâm lấn mạnh và di căn nhanh nếu không được phát hiện ở giai đoạn sớm [32].

Theo thống kê của Cơ quan Nghiên cứu Ung thư Quốc tế (International Agency for Research on Cancer - IARC), mỗi năm trên thế giới ghi nhận hàng trăm nghìn ca melanoma mới cùng hàng chục nghìn trường hợp tử vong. Song song với đó, số lượng bệnh nhân mắc các dạng ung thư da không phải melanoma cũng tiếp tục gia tăng, tạo ra gánh nặng đáng kể cho hệ thống y tế ở nhiều quốc gia [2]. Xu hướng này được cho là có liên quan đến sự gia tăng tuổi thọ dân số, quá trình đô thị hóa, thay đổi lối sống và mức độ tiếp xúc với tia cực tím (Ultraviolet - UV).

Khác với nhiều loại ung thư khác, ung thư da có thể được quan sát trực tiếp thông qua bề mặt da. Điều này tạo điều kiện thuận lợi cho việc phát hiện sớm nếu tổn thương được nhận biết kịp thời. Theo American Cancer Society, tỷ lệ sống sau 5 năm của bệnh nhân melanoma có thể vượt quá 99% khi bệnh được phát hiện ở giai đoạn khu trú. Tuy nhiên, khi tế bào ung thư đã di căn đến các cơ quan khác, tỷ lệ sống giảm đáng kể [3]. Do đó, phát hiện sớm đóng vai trò quyết định trong việc nâng cao hiệu quả điều trị và giảm tỷ lệ tử vong.

Trong thực hành lâm sàng, việc đánh giá các tổn thương da nghi ngờ chủ yếu được thực hiện bởi bác sĩ chuyên khoa da liễu thông qua quan sát trực quan kết hợp với soi da (dermoscopy), theo dõi diễn biến theo thời gian và sinh thiết đối với các trường hợp cần thiết. Tuy nhiên, quá trình này đòi hỏi nhiều kinh nghiệm chuyên môn và thời gian, đặc biệt là đối với những bệnh nhân có số lượng tổn thương sắc tố trên cơ thể lớn. Bên cạnh đó, kết quả đánh giá còn chịu ảnh hưởng bởi yếu tố chủ quan giữa các bác sĩ hoặc điều kiện quan sát trong thực tế [4].

Trước những hạn chế của phương pháp đánh giá thủ công, nhiều nghiên cứu đã ứng dụng

trí tuệ nhân tạo (Artificial Intelligence - AI) nhằm hỗ trợ phát hiện sớm ung thư da. Đặc biệt với sự phát triển mạnh mẽ của học sâu (Deep Learning) giúp các mô hình có thể phân tích hình ảnh tổn thương với độ chính xác ngày càng cao. Tuy nhiên, trong thực tế quá trình chẩn đoán không chỉ dựa trên một ảnh đơn lẻ mà còn kết hợp nhiều thông tin lâm sàng khác như tuổi, giới tính, vị trí tổn thương và mối liên hệ giữa các tổn thương trên cùng một bệnh nhân. Vì vậy, các hệ thống AI hiện nay đang dần chuyển sang hướng khai thác được đồng thời dữ liệu hình ảnh và dữ liệu lâm sàng (metadata) để mô phỏng gần hơn các quy trình đánh giá trong thực tế.

1.2 Những thách thức trong phát hiện sớm ung thư da

Mặc dù ung thư da là một trong số ít các loại ung thư có thể quan sát được một cách trực tiếp thông qua bề mặt cơ thể, việc phát hiện sớm các tổn thương ác tính trong thực hành lâm sàng vẫn là một thách thức lớn. Điều này xuất phát từ đặc điểm đa dạng của tổn thương da, số lượng tổn thương trên mỗi bệnh nhân và sự phụ thuộc đáng kể vào kinh nghiệm của bác sĩ trong quá trình đánh giá. Những khó khăn này không chỉ ảnh hưởng đến hiệu quả sàng lọc mà còn là động lực cho việc nghiên cứu các hệ thống hỗ trợ chẩn đoán dựa trên trí tuệ nhân tạo (AI) [4, 1].

Một trong những thách thức lớn nhất là sự đa dạng về hình thái của tổn thương da. Các tổn thương lành tính như nevus (nốt ruồi) có thể có hình dạng, màu sắc và kích thước rất giống với melanoma ở giai đoạn sớm. Ngược lại, melanoma cũng có thể biểu hiện dưới nhiều dạng khác nhau, khiến việc phân biệt chỉ dựa trên quan sát trực quan trở nên khó khăn ngay cả đối với các bác sĩ giàu kinh nghiệm. Điều này làm tăng nguy cơ bỏ sót các trường hợp ác tính hoặc thực hiện sinh thiết không cần thiết đối với các tổn thương lành tính [4, 5].

Bên cạnh đó, số lượng tổn thương sắc tố trên cơ thể bệnh nhân thường rất lớn. Đối với những bệnh nhân có nguy cơ cao, toàn bộ cơ thể có thể xuất hiện hàng trăm, thậm chí hàng nghìn tổn thương cần được theo dõi định kỳ. Việc đánh giá thủ công từng tổn thương không chỉ tiêu tốn nhiều thời gian mà còn làm tăng khả năng bỏ sót các tổn thương bất thường, đặc biệt trong điều kiện khám lâm sàng thông thường [4].

Một yếu tố khác ảnh hưởng đến hiệu quả chẩn đoán là sự khác biệt giữa các bác sĩ trong quá trình đánh giá. Quyết định lâm sàng thường dựa trên kinh nghiệm, kỹ năng soi da và khả năng nhận biết các dấu hiệu nghi ngờ của từng bác sĩ. Do đó, cùng một tổn thương có thể được đánh giá khác nhau giữa các chuyên gia, đặc biệt đối với những trường hợp có biểu hiện không điển hình hoặc ở giai đoạn rất sớm [4, 6].

Ngoài việc đánh giá từng tổn thương riêng lẻ, bác sĩ da liễu còn phải xem xét bối cảnh của toàn bộ bệnh nhân (patient context). Trong thực tế, quyết định lâm sàng thường dựa trên sự

so sánh giữa tổn thương nghi ngờ với các tổn thương khác trên cùng một bệnh nhân nhằm phát hiện những tổn thương có đặc điểm bất thường. Cách tiếp cận này giúp nâng cao khả năng phát hiện melanoma nhưng đồng thời cũng làm tăng độ phức tạp cho quá trình sàng lọc, bởi bác sĩ phải quan sát và so sánh một lượng lớn thông tin trong thời gian ngắn [4, 7].

Những thách thức trên cho thấy việc phát hiện sớm ung thư da không chỉ phụ thuộc vào chất lượng của ảnh tổn thương mà còn đòi hỏi khai thác được nhiều nguồn thông tin lâm sàng. Điều này tạo tiền đề cho sự phát triển của các hệ thống hỗ trợ chẩn đoán sử dụng học sâu kết hợp với công nghệ 3D Total Body Photography (3D-TBP), cho phép ghi nhận toàn bộ bề mặt da và cung cấp cả dữ liệu hình ảnh lẫn metadata ở mức bệnh nhân. Những tiến bộ trên đã tạo tiền đề cho sự ra đời của bộ dữ liệu ISIC 2024, được giới thiệu chi tiết trong mục tiếp theo.

1.3 Sự phát triển của 3D Total Body Photography và bộ dữ liệu ISIC 2024

Trước nhu cầu nâng cao hiệu quả sàng lọc ung thư da, nhiều công nghệ hỗ trợ chẩn đoán đã được nghiên cứu và phát triển. Một trong số đó là 3D Total Body Photography (3D-TBP) một bước tiến quan trọng, cho phép ghi nhận lại gần như toàn bộ bề mặt da của bệnh nhân thay vì chỉ thu nhận ảnh của từng tổn thương riêng lẻ. Khác với các hệ thống dermoscopy truyền thống chỉ tập trung vào một vùng da cụ thể, 3D-TBP cung cấp cái nhìn toàn diện về toàn bộ cơ thể, giúp bác sĩ theo dõi đồng thời hàng trăm đến hàng nghìn tổn thương sắc tố trên cùng một bệnh nhân qua nhiều lần tái khám [4].

Một hệ thống 3D-TBP thường bao gồm nhiều máy ảnh được bố trí xung quanh bệnh nhân để chụp đồng thời từ nhiều góc nhìn. Sau quá trình tái tạo, hệ thống tạo ra mô hình ba chiều của toàn bộ bề mặt da và tự động xác định vị trí của từng tổn thương. Bên cạnh hình ảnh, hệ thống còn có khả năng trích xuất nhiều thông tin định lượng như vị trí giải phẫu, kích thước, màu sắc, hình dạng và các đặc trưng hình thái khác của từng tổn thương. Những dữ liệu này tạo thành metadata có giá trị lâm sàng, phản ánh không chỉ đặc điểm của từng tổn thương mà còn mối quan hệ giữa các tổn thương trên cùng một bệnh nhân [4].

Sự xuất hiện của 3D-TBP đã làm thay đổi cách tiếp cận trong các hệ thống trí tuệ nhân tạo phục vụ phát hiện ung thư da. Nếu các nghiên cứu trước đây chủ yếu xây dựng mô hình trên từng ảnh tổn thương độc lập, thì dữ liệu từ 3D-TBP cho phép khai thác đồng thời thông tin hình ảnh và thông tin ở mức bệnh nhân (patient-level information). Cách tiếp cận này gần với quy trình đánh giá của bác sĩ da liễu trong thực tế hơn, bởi quyết định lâm sàng không chỉ dựa trên

đặc điểm của một tổn thương riêng lẻ mà còn xét đến sự khác biệt giữa tổn thương đó và các tổn thương khác trên cùng bệnh nhân [4, 7].

Nhằm thúc đẩy nghiên cứu theo hướng này, cuộc thi ISIC 2024 – Skin Cancer Detection with 3D-TBP đã được tổ chức trong khuôn khổ Hội nghị quốc tế về Phân tích Hình ảnh Da (International Skin Imaging Collaboration – ISIC). Khác với các phiên bản trước, ISIC 2024 sử dụng dữ liệu được thu thập từ hệ thống 3D-TBP, trong đó mỗi mẫu dữ liệu bao gồm ảnh cắt của tổn thương (lesion image) cùng với metadata chứa các đặc trưng lâm sàng và thông tin ở mức bệnh nhân. Thiết kế này phản ánh sát hơn điều kiện chẩn đoán thực tế và khuyến khích các phương pháp khai thác đồng thời nhiều nguồn dữ liệu thay vì chỉ sử dụng ảnh đơn lẻ [4].

Đáng chú ý, nhiều nhóm nghiên cứu đạt thành tích cao tại ISIC 2024 đều không chỉ tập trung vào việc cải thiện mô hình xử lý ảnh mà còn khai thác mạnh mẽ các metadata và các đặc trưng được xây dựng từ patient context. Điều này cho thấy thông tin lâm sàng đóng vai trò quan trọng trong việc nâng cao hiệu quả phát hiện melanoma, đặc biệt đối với những trường hợp có biểu hiện không điển hình hoặc khó phân biệt bằng quan sát trực quan [4].

Xu hướng trên cho thấy bài toán phát hiện ung thư da đang chuyển dịch từ mô hình đơn phương thức (image-only) sang đa phương thức (multimodal), trong đó hình ảnh và metadata được xem là hai nguồn thông tin bổ sung cho nhau. Đây cũng là định hướng mà đồ án lựa chọn, với mục tiêu xây dựng mô hình học sâu có khả năng khai thác đồng thời dữ liệu hình ảnh và dữ liệu bảng nhằm hỗ trợ phát hiện ung thư da trên bộ dữ liệu ISIC 2024.

Đặc điểm	**Dermoscopy truyền thống**	**3D Total Body Photography**
Phạm vi quan sát	Một tổn thương	Toàn bộ cơ thể
Số lượng tổn thương	Từng tổn thương	Hàng trăm đến hàng nghìn
Metadata	Hạn chế	Phong phú
Patient Context	Không	Có
Mức độ hỗ trợ mô hình đa phương thức	Hạn chế	Cao

Bảng 1.1: So sánh dữ liệu truyền thống và dữ liệu 3D-TBP

1.4 Động cơ và khoảng trống nghiên cứu

Sự phát triển của các mô hình học sâu đã giúp nâng cao đáng kể hiệu quả của các hệ thống hỗ trợ phát hiện ung thư da từ hình ảnh. Nhiều nghiên cứu đã chứng minh rằng các mô hình học sâu có khả năng đạt hiệu năng tương đương hoặc trong một số trường hợp vượt qua bác sĩ da liễu trong bài toán phân loại tổn thương da từ ảnh dermoscopy [5]. Mặc dù đạt hiệu quả cao, đa số các nghiên cứu vẫn xem mỗi ảnh tổn thương là một mẫu dữ liệu độc lập. Việc dự

đoán chủ yếu dựa trên đặc trưng thị giác của chính tổn thương đó, trong khi các thông tin lâm sàng liên quan đến bệnh nhân thường chưa được khai thác đầy đủ.

Trong thực tế lâm sàng, quy trình đánh giá của bác sĩ lại phức tạp hơn đáng kể. Quyết định chẩn đoán không chỉ dựa trên hình ảnh đơn lẻ mà còn kết hợp với nhiều thông tin khác như tuổi, giới tính, vị trí giải phẫu, tiền sử bệnh nhân cũng như sự khác biệt giữa giữa tổn thương đang được đánh giá với các tổn thương còn lại trên cùng bệnh nhân. Đặc biệt, sự phát triển của hệ thống 3D Total Body Photography đã hỗ trợ thu thập có hệ thống đồng thời dữ liệu hình ảnh và metadata, mở ra khả năng xây dựng các hệ thống AI gần với quy trình đánh giá thực tế của bác sĩ hơn [4].

Bộ dữ liệu ISIC 2024 phản ánh rõ xu hướng này khi mỗi mẫu dữ liệu không chỉ bao gồm ảnh của tổn thương mà còn đi kèm nhiều đặc trưng lâm sàng và thông tin ở mức bệnh nhân. Nhờ đó, các phương pháp học máy có thể khai thác đồng thời dữ liệu hình ảnh và metadata để cải thiện khả năng phát hiện melanoma. Tuy nhiên, việc tận dụng hiệu quả metadata vẫn là một thách thức. Dữ liệu bảng có đặc tính khác với dữ liệu ảnh nên không thể áp dụng trực tiếp các mô hình thị giác [8, 9].

Nhiều nghiên cứu gần đây cho thấy việc sử dụng trực tiếp metadata gốc chưa khai thác hết giá trị của nguồn dữ liệu này. Thay vào đó, các đặc trưng được xây dựng từ kiến thức miền về y khoa (domain knowledge), chẳng hạn như thông tin ở mức bệnh nhân hoặc các đặc trưng phản ánh sự khác biệt giữa các tổn thương trên cùng một bệnh nhân, có thể cung cấp thêm thông tin hữu ích cho mô hình học máy mà metadata gốc chưa thể hiện đầy đủ [4]. Điều này cho thấy việc kết hợp kiến thức lâm sàng, học máy cho dữ liệu bảng và học đa phương thức là một hướng nghiên cứu có nhiều tiềm năng.

Dựa trên những vấn đề đã đề cập, đồ án lựa chọn tập trung nghiên cứu bài toán phát hiện ung thư da trên bộ dữ liệu ISIC 2024 bằng cách khai thác đồng thời dữ liệu hình ảnh và dữ liệu bảng. Thay vì chỉ sử dụng metadata gốc, đồ án hướng đến việc xây dựng các đặc trưng dựa trên kiến thức miền nhằm biểu diễn tốt hơn thông tin ở mức bệnh nhân, sau đó sử dụng mô hình học sâu cho dữ liệu bảng để học biểu diễn từ các đặc trưng này và kết hợp với biểu diễn hình ảnh trong một kiến trúc học đa phương thức để thực hiện phân loại.

1.5 Phát biểu bài toán

Bài toán nhận dạng ung thư da hắc tố trong nghiên cứu này được định nghĩa là một bài toán phân loại nhị phân (binary classification). Cho một ảnh chụp tổn thương da $\mathbf{I} \in \mathbb{R}^{H \times W \times 3}$ thu thập từ hệ thống 3D Total Body Photography (3D-TBP) kết hợp cùng dữ liệu dạng bảng

tương ứng $\mathbf{x} \in \mathbb{R}^{d_{tab}}$, nhiệm vụ của hệ thống là dự đoán xác suất $\hat{y} \in [0, 1]$ cho biết tổn thương đó là ác tính (malignant). Mục tiêu tối ưu của mô hình là tối đa hóa chỉ số partial AUC (pAUC) tại vùng tỷ lệ dương tính thật (True Positive Rate - TPR) ≥ 0.80. Nền tảng lý thuyết cho các phương pháp tiếp cận bài toán này được trình bày chi tiết tại Chương 2.

1.6 Mục tiêu nghiên cứu

Xuất phát từ những thách thức trong phát hiện sớm ung thư da và xu hướng khai thác đồng thời dữ liệu hình ảnh với dữ liệu bảng trên bộ dữ liệu ISIC 2024, đồ án hướng đến việc nghiên cứu và xây dựng một mô hình học sâu đa phương thức nhằm hỗ trợ phát hiện các tổn thương nghi ngờ ung thư da. Mô hình được thiết kế theo hướng khai thác cả đặc trưng thị giác từ ảnh tổn thương và thông tin lâm sàng từ dữ liệu bảng, qua đó nâng cao khả năng học biểu diễn và hỗ trợ quá trình phân loại.

Để đạt được mục tiêu tổng quát trên, đồ án đặt ra các mục tiêu cụ thể như sau:

- Nghiên cứu cơ sở lý thuyết về phát hiện ung thư da, các kiến thức miền trong da liễu, học sâu cho dữ liệu bảng và học biểu diễn đa phương thức nhằm xây dựng nền tảng cho mô hình đề xuất.
- Nghiên cứu và phân tích bộ dữ liệu ISIC 2024, bao gồm dữ liệu hình ảnh, dữ liệu bảng và các đặc trưng ở mức bệnh nhân, từ đó xác định các thông tin có giá trị phục vụ quá trình xây dựng mô hình.
- Xây dựng các đặc trưng dựa trên kiến thức miền (knowledge-guided feature engineering) nhằm biểu diễn tốt hơn thông tin của từng bệnh nhân, đặc biệt là các đặc trưng phản ánh mối quan hệ giữa tổn thương hiện tại với các tổn thương còn lại trên cùng bệnh nhân.
- Xây dựng mô hình học sâu cho dữ liệu bảng nhằm khai thác các đặc trưng lâm sàng và các đặc trưng được xây dựng dựa trên kiến thức miền, tạo thành nhánh xử lý dữ liệu bảng trong hệ thống.
- Xây dựng mô hình học đa phương thức kết hợp biểu diễn hình ảnh và biểu diễn dữ liệu bảng để thực hiện bài toán phát hiện ung thư da trên bộ dữ liệu ISIC 2024.
- Đánh giá hiệu quả của mô hình thông qua các chỉ số đánh giá phù hợp với cuộc thi ISIC 2024, đồng thời phân tích ảnh hưởng của các thành phần trong mô hình đối với kết quả thực nghiệm.

Các mục tiêu trên không chỉ hướng đồ án tới việc xây dựng một mô hình có khả năng phát hiện ung thư da mà còn đánh giá khả năng khai thác kiến thức miền và mô hình học sâu cho dữ liệu bảng trong bối cảnh học đa phương thức.

1.7 Phạm vi nghiên cứu

Đồ án tập trung nghiên cứu bài toán phát hiện ung thư da dựa trên bộ dữ liệu ISIC 2024 – Skin Cancer Detection with 3D Total Body Photography. Mục tiêu của đồ án là xây dựng và đánh giá một mô hình học sâu đa phương thức có khả năng khai thác đồng thời dữ liệu hình ảnh và dữ liệu bảng nhằm hỗ trợ phân loại tổn thương da.

- Về phạm vi dữ liệu, đồ án sử dụng trực tiếp bộ dữ liệu do cuộc thi ISIC 2024 công bố và không thực hiện thu thập dữ liệu mới. Mỗi mẫu dữ liệu bao gồm ảnh của tổn thương da cùng với metadata chứa các thông tin lâm sàng và các đặc trưng được trích xuất từ hệ thống 3D Total Body Photography. [4].

- Về phạm vi nghiên cứu mô hình, đồ án tập trung vào việc khai thác hai nguồn dữ liệu chính gồm hình ảnh và metadata. Nhánh xử lý hình ảnh được xây dựng nhằm học biểu diễn thị giác của tổn thương, trong khi nhánh xử lý dữ liệu bảng học biểu diễn từ metadata và các đặc trưng được xây dựng dựa trên kiến thức miền. Hai nhánh sau đó được kết hợp trong một kiến trúc học đa phương thức để thực hiện nhiệm vụ phân loại.

- Về phạm vi thực nghiệm, đồ án tập trung đánh giá hiệu quả của mô hình trên tập dữ liệu ISIC 2024 thông qua các chỉ số đánh giá được sử dụng trong cuộc thi, trong đó chỉ số chính là partial Area Under the ROC Curve (pAUC). Bên cạnh kết quả tổng thể, đồ án cũng phân tích ảnh hưởng của từng thành phần trong mô hình nhằm đánh giá đóng góp của các đặc trưng và chiến lược kết hợp dữ liệu.

Đồ án không hướng đến phát triển một hệ thống hỗ trợ chẩn đoán hoàn chỉnh phục vụ triển khai trong môi trường lâm sàng, đồng thời cũng không đánh giá hiệu quả của mô hình trên các bộ dữ liệu ngoài ISIC 2024. Do đó, các kết quả thu được chủ yếu nhằm đánh giá tính khả thi của hướng tiếp cận đề xuất, thay vì khẳng định khả năng ứng dụng trực tiếp của mô hình trong thực tiễn lâm sàng.

1.8 Đóng góp của đồ án

Dựa trên các mục tiêu nghiên cứu đã đề ra, đồ án hướng tới các đóng góp chính sau đây:

- Đồ án nghiên cứu khả năng kết hợp kiến thức miền trong da liễu với các mô hình học sâu nhằm cải thiện khả năng phát hiện ung thư da. Thay vì chỉ sử dụng trực tiếp dữ liệu đầu vào, đồ án khai thác các đặc trưng được xây dựng dựa trên thông tin lâm sàng và đặc điểm ở mức bệnh nhân, qua đó giúp mô hình tiếp cận gần hơn với quy trình đánh giá của bác sĩ da liễu trong thực tế.

- Đề xuất quy trình xây dựng biểu diễn bệnh nhân (Patient Representation) từ metadata thông qua kết hợp đặc trưng dựa trên kiến thức miền và mô hình học sâu cho dữ liệu bảng.

- Đồ án xây dựng một mô hình học đa phương thức có khả năng khai thác đồng thời dữ liệu hình ảnh và metadata trên bộ dữ liệu ISIC 2024. Hướng tiếp cận này tận dụng tính bổ sung giữa đặc trưng thị giác của tổn thương và thông tin lâm sàng của bệnh nhân, góp phần nâng cao khả năng biểu diễn dữ liệu phục vụ bài toán phân loại.

- Đồ án xây dựng kế hoạch đánh giá thực nghiệm trên bộ dữ liệu ISIC 2024, bao gồm các thí nghiệm so sánh và phân tích thành phần (ablation study). Các kết quả định lượng sẽ là cơ sở để đánh giá mức độ đóng góp của từng chiến lược xây dựng đặc trưng và từng thành phần của mô hình đối với hiệu quả phát hiện ung thư da khi quá trình huấn luyện hoàn tất.

Các đóng góp trên hướng đến việc đánh giá tính khả thi của hướng tiếp cận kết hợp kiến thức miền, học sâu cho dữ liệu bảng và học biểu diễn đa phương thức trong bài toán phát hiện ung thư da, đồng thời tạo nền tảng cho các nghiên cứu mở rộng trong tương lai.

Chương 2

CƠ SỞ KHOA HỌC CHO MÔ HÌNH ĐỀ XUẤT

2.1 Kiến thức miền trong phát hiện ung thư da

Trong các bài toán ứng dụng trí tuệ nhân tạo vào y học, hiệu quả của mô hình không chỉ phụ thuộc vào thuật toán học máy mà còn chịu ảnh hưởng lớn bởi việc khai thác kiến thức miền (domain knowledge). Đối với bài toán phát hiện ung thư da, bác sĩ da liễu không đưa ra quyết định chỉ dựa trên đặc điểm của một ảnh tổn thương đơn lẻ mà còn kết hợp nhiều tiêu chí lâm sàng và thông tin ở mức bệnh nhân để đánh giá nguy cơ ác tính. Những kiến thức này được hình thành từ nhiều năm nghiên cứu và đã trở thành cơ sở trong thực hành lâm sàng cũng như trong các hướng dẫn chẩn đoán hiện nay [10, 11].

Sự phát triển của các bộ dữ liệu thế hệ mới như ISIC 2024 đã tạo điều kiện để đưa những kiến thức lâm sàng này vào các mô hình học máy. Khác với các bộ dữ liệu chỉ cung cấp ảnh dermoscopy, ISIC 2024 còn cung cấp nhiều thông tin metadata và đặc trưng ở mức bệnh nhân, cho phép mô hình khai thác không chỉ đặc điểm thị giác mà còn cả ngữ cảnh lâm sàng của từng tổn thương [4].

Trong phạm vi đồ án, ba nhóm kiến thức miền được lựa chọn làm cơ sở cho quá trình xây dựng mô hình gồm:

- **Quy tắc ABCDE**: mô tả các đặc điểm hình thái thường gặp của melanoma.
- **Dấu hiệu Ugly Duckling**: dựa trên việc phát hiện những tổn thương có đặc điểm khác biệt so với các tổn thương còn lại trên cùng bệnh nhân.
- **Patient Context**: khai thác thông tin ở mức bệnh nhân (bao gồm metadata, đặc điểm của các tổn thương khác và các yếu tố lâm sàng liên quan) thay vì chỉ phân tích từng tổn thương riêng lẻ.

Những kiến thức này không được sử dụng như các quy tắc phân loại trực tiếp mà đóng vai trò định hướng cho quá trình xây dựng đặc trưng (feature engineering) và học biểu diễn dữ

liệu (representation learning) trong các chương tiếp theo.

2.1.1 Quy tắc ABCDE

Melanoma là loại ung thư da có biểu hiện lâm sàng đa dạng, đặc biệt ở giai đoạn sớm. Để hỗ trợ quá trình sàng lọc và nhận diện các tổn thương nghi ngờ, nhiều quy tắc đánh giá lâm sàng đã được đề xuất, trong đó quy tắc ABCDE là một trong những phương pháp được sử dụng rộng rãi nhất trong thực hành da liễu [10, 12].

Quy tắc ABCDE mô tả năm đặc điểm hình thái thường gặp của một tổn thương nghi ngờ là melanoma, bao gồm:

- **A – Asymmetry (Bất đối xứng)**: tổn thương có hình dạng không cân đối khi chia theo các trục khác nhau.
- **B – Border (Bờ tổn thương)**: bờ không đều, răng cưa hoặc mờ, khác với các tổn thương lành tính thường có ranh giới rõ ràng.
- **C – Color (Màu sắc)**: sự xuất hiện của nhiều màu sắc khác nhau trong cùng một tổn thương như nâu, đen, đỏ, trắng hoặc xanh.
- **D – Diameter (Đường kính)**: tổn thương có đường kính lớn hơn khoảng 6 mm thường có nguy cơ cao hơn, mặc dù melanoma giai đoạn sớm vẫn có thể nhỏ hơn ngưỡng này.
- **E – Evolution (Tiến triển)**: sự thay đổi theo thời gian về kích thước, màu sắc, hình dạng hoặc triệu chứng là dấu hiệu đặc biệt quan trọng trong đánh giá nguy cơ melanoma.

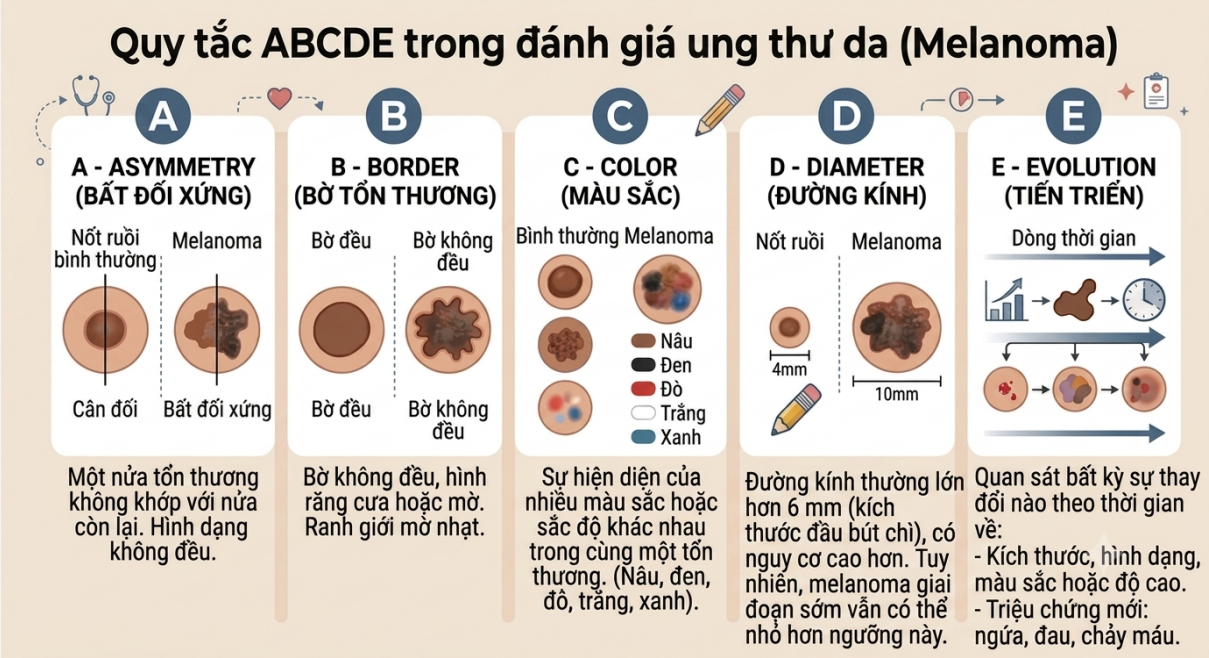
Trong số năm tiêu chí trên, Evolution được xem là yếu tố có giá trị lâm sàng cao vì phản ánh sự thay đổi của tổn thương theo thời gian, trong khi các tiêu chí còn lại chủ yếu mô tả hình thái tại một thời điểm quan sát được [10, 13].

Quy tắc ABCDE được chủ yếu được sử dụng trong quá trình sàng lọc ban đầu thay vì là tiêu chuẩn chẩn đoán tuyệt đối. Trên thực tế, nhiều tổn thương lành tính vẫn có thể thỏa mãn một hoặc nhiều tiêu chí của ABCDE, trong khi một số melanoma giai đoạn sớm lại chưa biểu hiện đầy đủ các dấu hiệu này. Do đó, trong thực hành lâm sàng, ABCDE thường được sử dụng kết hợp với các phương pháp đánh giá khác như dermoscopy, theo dõi diễn biến theo thời gian và thông tin ở mức bệnh nhân để đưa ra quyết định lâm sàng [10, 11].

Đối với các hệ thống học máy, quy tắc ABCDE không được áp dụng như một tập luật phân loại cố định. Thay vào đó, các tiêu chí về hình dạng, kích thước và màu sắc được xem là nguồn kiến thức miền để xây dựng các đặc trưng đầu vào hoặc hỗ trợ thiết kế mô hình. Nhờ đó,

mô hình có thể khai thác hiệu quả hơn các đặc điểm thị giác có ý nghĩa lâm sàng, thay vì chỉ dựa vào các mẫu thống kê trong dữ liệu.

Trong đồ án này, quy tắc ABCDE được sử dụng như một cơ sở khoa học cho việc phân tích các đặc trưng hình thái của tổn thương. Tuy nhiên, mô hình đề xuất không thực hiện phân loại trực tiếp theo các tiêu chí ABCDE mà học biểu diễn từ dữ liệu thông qua mạng học sâu. Các kiến thức lâm sàng sẽ được khai thác gián tiếp trong quá trình xây dựng đặc trưng và thiết kế mô hình ở Chương 3.



Hình 2.1: Quy tắc ABCDE trong đánh giá tổn thương da

2.1.2 Dấu hiệu Ugly Duckling

Mặc dù quy tắc ABCDE là một công cụ hữu ích trong sàng lọc melanoma, việc đánh giá từng tổn thương một cách độc lập vẫn tồn tại nhiều hạn chế. Trên thực tế, nhiều tổn thương lành tính có thể biểu hiện một hoặc nhiều đặc điểm tương tự melanoma, trong khi một số melanoma giai đoạn sớm lại chưa đáp ứng đầy đủ các tiêu chí của quy tắc ABCDE. Điều này cho thấy việc chỉ tập trung vào đặc điểm của từng tổn thương riêng lẻ chưa phản ánh đầy đủ cách bác sĩ đưa ra quyết định trong thực hành lâm sàng [10, 7].

Xuất phát từ thực tế đó, Grob và Bonerandi đã đề xuất khái niệm Ugly Duckling Sign vào năm 1998. Nguyên lý của phương pháp này dựa trên giả định rằng các nốt sắc tố trên cùng một bệnh nhân thường có xu hướng chia sẻ những đặc điểm hình thái tương đối giống nhau về màu sắc, hình dạng và kích thước. Một tổn thương có biểu hiện khác biệt rõ rệt so với "mẫu hình chung"của các tổn thương còn lại trên cùng bệnh nhân sẽ được xem là "Ugly Duckling", tổn

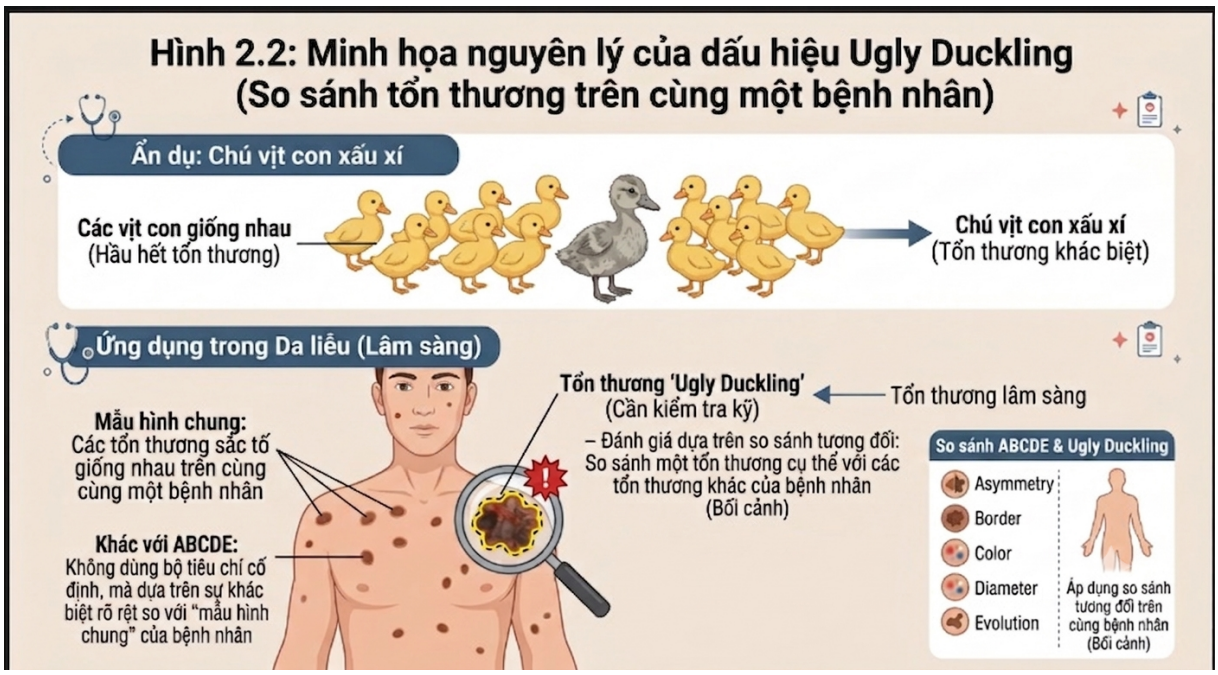
thương đó cần được chú ý và đánh giá kỹ hơn [7].

Khác với quy tắc ABCDE, dấu hiệu Ugly Duckling không đánh giá tổn thương theo một bộ tiêu chí cố định mà dựa trên so sánh tương đối giữa các tổn thương của cùng một bệnh nhân. Do đó, một tổn thương không nhất thiết phải có hình dạng bất thường hoặc kích thước lớn mới được xem là nghi ngờ. Chỉ cần tổn thương đó khác biệt đáng kể so với các tổn thương còn lại của bệnh nhân thì vẫn có thể được chỉ định kiểm tra thêm.

Cách tiếp cận này phản ánh sát hơn quy trình đánh giá của bác sĩ da liễu. Trong thực hành lâm sàng, bác sĩ thường quan sát toàn bộ cơ thể, nhận diện "kiểu hình"chung của các nốt sắc tố và tập trung vào những nốt có biểu hiện bất thường so với phần còn lại. Đây cũng là lý do khiến các hệ thống Total Body Photography và sau này là 3D Total Body Photography trở thành công cụ quan trọng trong việc theo dõi bệnh nhân có nhiều nốt sắc tố, bởi chúng cho phép quan sát đồng thời toàn bộ các tổn thương thay vì từng ảnh riêng lẻ [4].

Từ góc nhìn học máy, dấu hiệu Ugly Duckling gợi ý rằng thông tin ở mức bệnh nhân (patient-level information) có thể mang giá trị không kém so với đặc điểm của từng tổn thương riêng lẻ. Thay vì chỉ học từ ảnh của một tổn thương, mô hình có thể khai thác các đặc trưng phản ánh mối quan hệ giữa tổn thương hiện tại và các tổn thương khác trên cùng bệnh nhân. Những đặc trưng này bao gồm các giá trị thống kê, khoảng cách đến phân bố chung của bệnh nhân hoặc mức độ khác biệt so với các tổn thương còn lại. Đây là hướng tiếp cận đã được nhiều nghiên cứu gần đây áp dụng khi xây dựng các đặc trưng ở mức bệnh nhân cho bộ dữ liệu ISIC 2024 [4].

Trong đồ án, dấu hiệu Ugly Duckling không được sử dụng như một quy tắc phân loại trực tiếp. Thay vào đó, nguyên lý "so sánh tổn thương với các tổn thương khác trên cùng bệnh nhân"được xem là cơ sở để xây dựng các đặc trưng ở mức bệnh nhân trong giai đoạn tiền xử lý dữ liệu. Những đặc trưng này sau đó được sử dụng làm đầu vào cho mô hình học sâu nhằm học biểu diễn dữ liệu bảng, tạo tiền đề cho quá trình kết hợp với đặc trưng hình ảnh trong hệ thống học đa phương thức.



Hình 2.2: Minh họa nguyên lý của dấu hiệu Ugly Duckling

2.1.3 Thông tin ở mức bệnh nhân (Patient Context)

Trong thực hành lâm sàng, quá trình phát hiện ung thư da không chỉ dựa trên việc đánh giá đặc điểm của từng tổn thương mà còn xem xét bối cảnh của toàn bộ bệnh nhân (patient context). Khi khám da toàn thân, bác sĩ thường quan sát đồng thời tất cả các tổn thương sắc tố, từ đó xác định kiểu hình chung của bệnh nhân trước khi đánh giá mức độ bất thường của từng tổn thương riêng lẻ. Điều này cho thấy một tổn thương chỉ có thể được đánh giá đầy đủ khi đặt trong mối quan hệ với các tổn thương khác trên cùng bệnh nhân [4, 7].

Khái niệm patient context được nhấn mạnh trong các hệ thống 3D Total Body Photography (3D-TBP) và là một trong những điểm khác biệt quan trọng của bộ dữ liệu ISIC 2024. Không giống các bộ dữ liệu dermoscopy truyền thống, mỗi tổn thương trong ISIC 2024 không còn là một mẫu dữ liệu hoàn toàn độc lập mà được liên kết với thông tin của bệnh nhân thông qua nhiều metadata và các đặc trưng ở mức bệnh nhân. Điều này tạo điều kiện để mô hình khai thác cả đặc điểm cục bộ (lesion-level information) và đặc điểm toàn cục (patient-level information) trong quá trình dự đoán [4].

Từ góc độ lâm sàng, patient context giúp bác sĩ trả lời những câu hỏi mà một ảnh đơn lẻ không thể cung cấp, chẳng hạn như:

- Tổn thương này có kích thước lớn hơn hay nhỏ hơn đa số các tổn thương khác của bệnh nhân?
- Màu sắc của tổn thương có khác biệt đáng kể so với các tổn thương còn lại hay không?

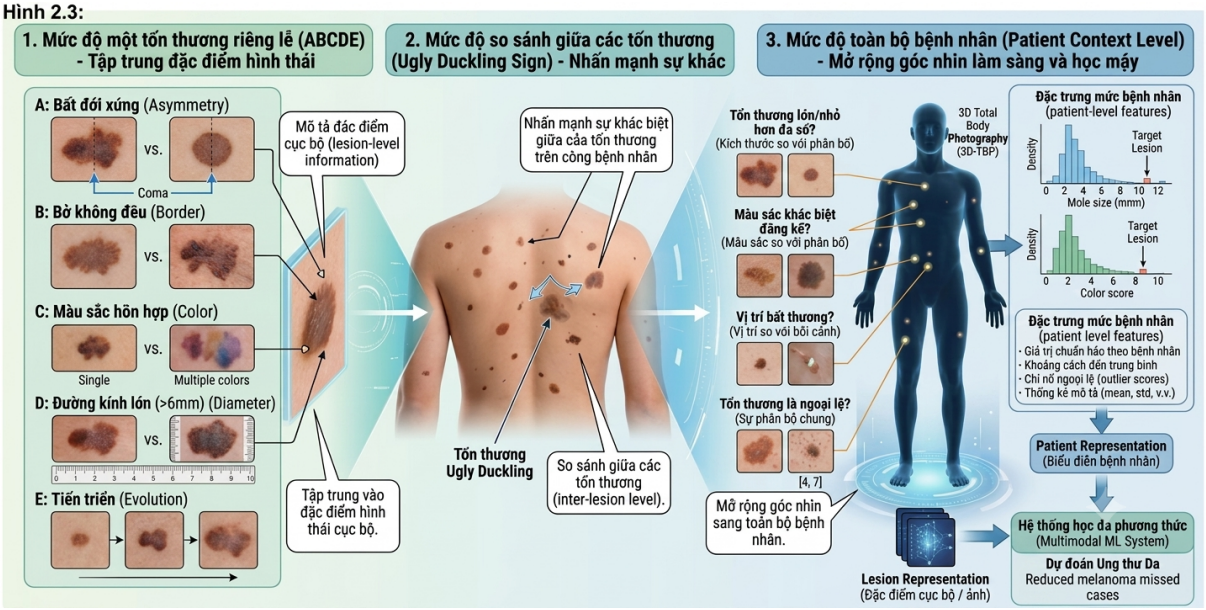
- Vị trí của tổn thương có bất thường so với các vị trí thường gặp trên bệnh nhân này không?
- Tổn thương có phải là một ngoại lệ trong phân bố chung của các tổn thương hay không?

Những thông tin này đóng vai trò quan trọng trong việc giảm tỷ lệ bỏ sót melanoma, đặc biệt đối với các tổn thương có biểu hiện không điển hình nhưng khác biệt rõ rệt so với phần lớn các tổn thương khác trên cùng bệnh nhân [4, 7].

Từ góc nhìn học máy, patient context có thể được biểu diễn thông qua các đặc trưng ở mức bệnh nhân (patient-level features). Thay vì chỉ sử dụng các giá trị gốc của metadata, nhiều nghiên cứu gần đây đề xuất xây dựng thêm các đặc trưng phản ánh mối quan hệ giữa từng tổn thương với toàn bộ phân bố của bệnh nhân, chẳng hạn như giá trị chuẩn hóa theo từng bệnh nhân, khoảng cách đến trung bình của các tổn thương, các chỉ số ngoại lệ hoặc các thống kê mô tả của toàn bộ tổn thương trên cùng bệnh nhân. Những đặc trưng này giúp mô hình khai thác được ngữ cảnh lâm sàng mà ảnh đơn lẻ không thể cung cấp [4].

Đối với đồ án này, patient context được xem là cơ sở để xây dựng biểu diễn bệnh nhân (patient representation). Thay vì đưa trực tiếp metadata vào mô hình, đồ án thực hiện quá trình xây dựng các đặc trưng dựa trên kiến thức miền nhằm phản ánh tốt hơn mối quan hệ giữa tổn thương hiện tại và toàn bộ bệnh nhân. Các đặc trưng này sau đó được sử dụng làm đầu vào cho mô hình học sâu xử lý dữ liệu bảng, tạo thành nhánh học biểu diễn metadata trước khi kết hợp với biểu diễn hình ảnh trong hệ thống học đa phương thức.

Như vậy, nếu quy tắc ABCDE giúp mô tả đặc điểm hình thái của từng tổn thương, còn Ugly Duckling nhấn mạnh sự khác biệt giữa các tổn thương, thì patient context mở rộng góc nhìn sang toàn bộ bệnh nhân. Đây cũng chính là định hướng được kế thừa trong đồ án khi xây dựng các đặc trưng ở mức bệnh nhân thay vì chỉ sử dụng các thuộc tính độc lập của từng mẫu dữ liệu.



Hình 2.3: Vai trò của Patient Context trong đánh giá tổn thương da

Ba nhóm kiến thức miền được trình bày trong mục này phản ánh các mức độ thông tin khác nhau mà bác sĩ sử dụng trong quá trình phát hiện ung thư da. Quy tắc ABCDE tập trung vào các đặc điểm hình thái của từng tổn thương, Ugly Duckling nhấn mạnh việc so sánh giữa các tổn thương trên cùng bệnh nhân, trong khi patient context mở rộng quá trình đánh giá sang mức toàn bộ bệnh nhân.

Những kiến thức này cho thấy dữ liệu lâm sàng không chỉ bao gồm các thuộc tính riêng lẻ mà còn chứa nhiều mối quan hệ giữa các tổn thương và giữa các đặc trưng của bệnh nhân. Điều này đặt ra yêu cầu phải xây dựng các đặc trưng có ý nghĩa lâm sàng trước khi đưa vào mô hình học máy. Trong đồ án, các đặc trưng này được học thông qua mô hình học sâu dành cho dữ liệu bảng, nội dung sẽ được trình bày trong mục tiếp theo.

2.2 Học sâu cho dữ liệu bảng

Trong nhiều năm, các mô hình dựa trên cây quyết định được xem là phương pháp chủ đạo cho các bài toán học máy trên dữ liệu bảng. Các thuật toán như Random Forest, XGBoost, LightGBM và CatBoost thường đạt hiệu năng cao trên nhiều bộ dữ liệu thực tế nhờ khả năng xử lý hiệu quả dữ liệu không đồng nhất, dữ liệu thiếu và các mối quan hệ phi tuyến giữa các thuộc tính [8]

Tuy nhiên, cùng với sự phát triển của các hệ thống học sâu đa phương thức, dữ liệu bảng không còn được sử dụng như một nguồn thông tin độc lập mà trở thành một trong nhiều modality của hệ thống. Khi đó, mục tiêu của mô hình không chỉ là đạt độ chính xác cao trên dữ liệu bảng

mà còn phải học được biểu diễn (representation) có thể kết hợp hiệu quả với biểu diễn của các modality khác, chẳng hạn như hình ảnh hoặc văn bản [14, 15].

Đối với bài toán phát hiện ung thư da trên bộ dữ liệu ISIC 2024, metadata không chỉ bao gồm các thuộc tính lâm sàng cơ bản mà còn chứa nhiều đặc trưng được xây dựng từ kiến thức miền và thông tin ở mức bệnh nhân. Điều này đặt ra yêu cầu lựa chọn một mô hình có khả năng học biểu diễn từ dữ liệu bảng đồng thời dễ dàng tích hợp vào kiến trúc học đa phương thức. Vì vậy, trước khi trình bày mô hình được sử dụng trong đồ án, cần xem xét đặc điểm của dữ liệu bảng cũng như sự phát triển của các phương pháp học sâu dành cho loại dữ liệu này.

2.2.1 Đặc điểm của dữ liệu bảng

Dữ liệu bảng (Tabular Data) là dạng dữ liệu được tổ chức dưới dạng các hàng và cột, trong đó mỗi hàng biểu diễn một mẫu dữ liệu và mỗi cột biểu diễn một thuộc tính của mẫu đó. Đây là dạng dữ liệu phổ biến trong nhiều lĩnh vực như tài chính, y tế, thương mại điện tử và khoa học xã hội, nơi mỗi đối tượng được mô tả thông qua tập hợp các thuộc tính số và thuộc tính phân loại [8].

Khác với dữ liệu hình ảnh hoặc văn bản, các thuộc tính trong dữ liệu bảng không có cấu trúc không gian hoặc thứ tự cố định. Mỗi thuộc tính mang một ý nghĩa riêng và có thể được đo bằng các đơn vị khác nhau. Ví dụ, trong bộ dữ liệu ISIC 2024, metadata đồng thời bao gồm tuổi bệnh nhân, giới tính, vị trí giải phẫu, các chỉ số hình thái của tổn thương và nhiều đặc trưng được xây dựng từ hệ thống 3D Total Body Photography. Các thuộc tính này có bản chất khác nhau nhưng cùng góp phần mô tả một tổn thương da.

Một đặc điểm quan trọng của dữ liệu bảng là mối quan hệ giữa các thuộc tính thường rất phức tạp và không tuyến tính. Giá trị của một thuộc tính riêng lẻ đôi khi không mang nhiều ý nghĩa, nhưng khi kết hợp với các thuộc tính khác lại có thể phản ánh những đặc điểm quan trọng của đối tượng. Vì vậy, hiệu quả của mô hình không chỉ phụ thuộc vào từng đặc trưng riêng lẻ mà còn phụ thuộc vào khả năng khai thác các tương tác giữa nhiều đặc trưng khác nhau [8].

Bên cạnh đó, dữ liệu bảng thường có tính không đồng nhất (heterogeneous). Trong cùng một tập dữ liệu có thể đồng thời tồn tại các thuộc tính số liên tục, thuộc tính phân loại, thuộc tính nhị phân và các đặc trưng được xây dựng từ kiến thức miền. Mỗi nhóm thuộc tính có phân bố thống kê và ý nghĩa khác nhau, gây khó khăn cho việc xây dựng một mô hình có khả năng học biểu diễn chung cho toàn bộ dữ liệu [8, 16].

Đối với bài toán phát hiện ung thư da, metadata còn mang một đặc điểm quan trọng khác là chứa nhiều thông tin ngữ cảnh (contextual information). Không giống các đặc trưng hình ảnh

phản ánh trực tiếp hình thái của tổn thương, metadata mô tả thông tin về bệnh nhân, vị trí giải phẫu và các đặc trưng ở mức bệnh nhân được xây dựng từ kiến thức miền. Những thông tin này đóng vai trò bổ sung cho dữ liệu hình ảnh và tạo điều kiện để mô hình khai thác đồng thời cả đặc điểm thị giác và bối cảnh lâm sàng.

Những đặc điểm trên cho thấy dữ liệu bảng không chỉ khác biệt về cấu trúc so với dữ liệu hình ảnh mà còn đặt ra yêu cầu về các mô hình có khả năng học được biểu diễn giàu thông tin từ nhiều loại thuộc tính khác nhau. Đây cũng là lý do các phương pháp học sâu cho dữ liệu bảng được nghiên cứu trong những năm gần đây nhằm thay thế hoặc bổ sung cho các mô hình học máy truyền thống trong các hệ thống học đa phương thức.

2.2.2 Sự phát triển của học sâu cho dữ liệu bảng

Trong nhiều năm, các mô hình dựa trên cây quyết định tăng cường (Gradient Boosting Decision Trees - GBDT) như XGBoost, LightGBM và CatBoost được xem là lựa chọn hàng đầu cho các bài toán học máy trên dữ liệu bảng nhờ khả năng xử lý hiệu quả dữ liệu không đồng nhất, khai thác tốt các mối quan hệ phi tuyến và ít yêu cầu tiền xử lý dữ liệu [8]. Chính vì vậy, việc áp dụng các mô hình học sâu cho dữ liệu bảng trong giai đoạn đầu chưa mang lại nhiều cải thiện rõ rệt so với các phương pháp truyền thống.

Nguyên nhân chủ yếu xuất phát từ sự khác biệt về bản chất giữa dữ liệu bảng và các dạng dữ liệu có cấu trúc như hình ảnh hoặc văn bản. Đối với dữ liệu hình ảnh, các điểm ảnh có quan hệ không gian rõ ràng nên mạng nơ-ron tích chập (CNN) có thể khai thác hiệu quả các mẫu cục bộ. Đối với dữ liệu văn bản, Transformer tận dụng mối quan hệ tuần tự giữa các từ thông qua cơ chế attention. Trong khi đó, dữ liệu bảng bao gồm nhiều thuộc tính độc lập, không có cấu trúc không gian hoặc thứ tự tự nhiên, khiến các kiến trúc học sâu truyền thống khó phát huy hiệu quả [8].

Mặc dù vậy, cùng với sự phát triển của học biểu diễn (Representation Learning), nhiều nghiên cứu đã chứng minh rằng học sâu vẫn có tiềm năng trên dữ liệu bảng nếu mô hình được thiết kế phù hợp với đặc điểm của loại dữ liệu này. Thay vì xem mỗi thuộc tính là một giá trị độc lập, các mô hình học sâu hướng tới việc học biểu diễn có ý nghĩa cho từng thuộc tính và khai thác mối quan hệ giữa các đặc trưng trong không gian biểu diễn. Đây là điểm khác biệt cơ bản giữa các phương pháp học sâu hiện đại và các mô hình học máy truyền thống.

Trong những năm gần đây, nhiều kiến trúc học sâu dành riêng cho dữ liệu bảng đã được đề xuất. Các mô hình như TabNet sử dụng cơ chế attention để lựa chọn đặc trưng quan trọng ở từng bước suy luận; FT-Transformer khai thác self-attention nhằm mô hình hóa tương tác giữa

các thuộc tính; TabR xây dựng biểu diễn dựa trên các mẫu dữ liệu tương tự trong tập huấn luyện; trong khi TabM tập trung vào việc học các biểu diễn mạnh thông qua cơ chế parameter-efficient ensembling mà không làm gia tăng đáng kể chi phí tính toán [9, 16, 17, 18].

Sự phát triển của các mô hình này cho thấy mục tiêu của học sâu trên dữ liệu bảng đã chuyển từ việc cạnh tranh trực tiếp với GBDT sang việc xây dựng biểu diễn dữ liệu có thể tích hợp với các hệ thống học sâu phức tạp hơn. Điều này đặc biệt quan trọng trong các bài toán học đa phương thức, nơi dữ liệu bảng cần được chuyển thành các vector biểu diễn có cùng không gian đặc trưng với dữ liệu hình ảnh hoặc văn bản để thực hiện quá trình kết hợp.

Đối với bài toán phát hiện ung thư da trong đồ án, metadata không chỉ được sử dụng để dự đoán trực tiếp mà còn đóng vai trò là một modality trong hệ thống học đa phương thức. Vì vậy, tiêu chí lựa chọn mô hình không chỉ dựa trên hiệu năng trên dữ liệu bảng mà còn phải xem xét khả năng học biểu diễn, khả năng tích hợp với nhánh xử lý hình ảnh và khả năng huấn luyện trong kiến trúc học sâu thống nhất. Các tiêu chí này sẽ được trình bày trong mục tiếp theo.

2.2.3 Tiêu chí lựa chọn mô hình học sâu cho dữ liệu bảng

Việc lựa chọn mô hình học sâu cho dữ liệu bảng không chỉ phụ thuộc vào độ chính xác trên một bộ dữ liệu cụ thể mà còn phải phù hợp với mục tiêu của bài toán. Đối với các hệ thống học đa phương thức, dữ liệu bảng không còn đóng vai trò là đầu vào độc lập mà trở thành một modality cần được biểu diễn trong cùng không gian đặc trưng với dữ liệu hình ảnh. Vì vậy, tiêu chí lựa chọn mô hình cần được xem xét trên cả khía cạnh hiệu năng dự đoán và khả năng học biểu diễn.

Đối với bài toán phát hiện ung thư da trên bộ dữ liệu ISIC 2024, metadata bao gồm nhiều loại thuộc tính khác nhau như thông tin lâm sàng, đặc trưng hình thái và các đặc trưng được xây dựng từ kiến thức miền. Những dữ liệu này có vai trò bổ sung cho hình ảnh trong quá trình dự đoán. Do đó, mô hình xử lý dữ liệu bảng cần đáp ứng các yêu cầu sau.

(1) Khả năng học biểu diễn từ dữ liệu bảng

Khác với các mô hình học máy truyền thống chủ yếu đưa ra kết quả dự đoán trực tiếp, mô hình học sâu trên dữ liệu bảng cần học được các vector biểu diễn (embedding) phản ánh đặc trưng tiềm ẩn của từng mẫu dữ liệu. Chất lượng của các biểu diễn này ảnh hưởng trực tiếp đến khả năng phân biệt giữa các lớp và hiệu quả của mô hình trong các tác vụ học sâu [14].

(2) Khả năng khai thác tương tác giữa các đặc trưng

Metadata trong ISIC 2024 bao gồm nhiều thuộc tính có ý nghĩa lâm sàng khác nhau. Giá trị của từng thuộc tính riêng lẻ thường chưa đủ để phản ánh nguy cơ ác tính, trong khi sự kết hợp

giữa nhiều thuộc tính lại chứa thông tin quan trọng. Vì vậy, mô hình cần có khả năng học các tương tác phi tuyến giữa các đặc trưng thay vì chỉ xem xét từng thuộc tính độc lập [8].

(3) Khả năng tích hợp với hệ thống học đa phương thức

Trong đồ án này, embedding của dữ liệu bảng sẽ được kết hợp với embedding của hình ảnh để xây dựng mô hình đa phương thức. Do đó, mô hình cần tạo ra các vector biểu diễn có kích thước cố định và dễ tích hợp với các chiến lược fusion hoặc cơ chế attention giữa các modality. Đây là yêu cầu mà các mô hình học máy truyền thống như GBDT không được thiết kế để đáp ứng trực tiếp.

(4) Khả năng mở rộng và huấn luyện hiệu quả

Bên cạnh hiệu năng, mô hình cần có khả năng mở rộng tốt và chi phí huấn luyện hợp lý để có thể tích hợp hiệu quả vào hệ thống học sâu hoàn chỉnh. Điều này đặc biệt quan trọng khi quá trình huấn luyện được thực hiện đồng thời cho cả nhánh xử lý hình ảnh và nhánh xử lý dữ liệu bảng.

Từ các yêu cầu trên có thể thấy rằng, mô hình xử lý dữ liệu bảng không chỉ cần đạt hiệu quả dự đoán mà còn phải học được các biểu diễn giàu thông tin từ metadata để phục vụ quá trình hợp nhất đa phương thức. Đây cũng là lý do các mô hình học sâu hiện đại như TabM trở thành lựa chọn phù hợp cho hệ thống đề xuất và sẽ được trình bày trong mục tiếp theo.

2.2.4 Mô hình TabM

2.2.4.1 Tổng quan về TabM

Sự phát triển của học sâu cho dữ liệu bảng đã dẫn đến nhiều kiến trúc mới nhằm cải thiện khả năng học biểu diễn và nâng cao hiệu năng trên các bài toán thực tế. Trong số đó, TabM (Tabular Deep Learning with Parameter-efficient Ensembling) là một trong những mô hình tiêu biểu được đề xuất nhằm kết hợp ưu điểm của học sâu với chiến lược ensemble mà không làm gia tăng đáng kể số lượng tham số của mô hình [9].

Khác với các phương pháp ensemble truyền thống, vốn yêu cầu huấn luyện nhiều mô hình độc lập rồi tổng hợp kết quả dự đoán, TabM sử dụng một backbone dùng chung để học biểu diễn từ dữ liệu bảng và kết hợp với nhiều đầu dự đoán (prediction heads). Thiết kế này cho phép mô hình tận dụng lợi ích của ensemble trong khi chỉ tăng thêm một lượng nhỏ tham số so với mô hình cơ sở. Nhờ đó, TabM đạt được hiệu quả cao trên nhiều bộ dữ liệu bảng mà vẫn duy trì chi phí huấn luyện hợp lý [9].

Một đặc điểm quan trọng của TabM là mô hình không được thiết kế như một bộ phân loại độc lập, mà đóng vai trò là một bộ học biểu diễn (representation learner). Sau quá trình huấn

luyện, backbone của mô hình tạo ra một vector biểu diễn chứa thông tin tổng hợp từ toàn bộ metadata, phản ánh các tương tác phi tuyến giữa các đặc trưng đầu vào. Vector biểu diễn này có thể được sử dụng trực tiếp cho nhiều nhiệm vụ khác nhau hoặc tích hợp với các modality khác trong các hệ thống học đa phương thức.

Nhờ khả năng học biểu diễn mạnh và thiết kế linh hoạt, TabM đã đạt kết quả cạnh tranh trên nhiều benchmark về dữ liệu bảng, đồng thời trở thành một lựa chọn phù hợp trong các bài toán yêu cầu kết hợp dữ liệu bảng với các nguồn dữ liệu khác như hình ảnh hoặc văn bản [9].

2.2.4.2 Vì sao lựa chọn TabM trong đồ án

Mục tiêu cuối cùng của đồ án không phải là xây dựng một mô hình chuyên biệt cho dữ liệu bảng mà là phát triển một hệ thống học đa phương thức kết hợp giữa dữ liệu hình ảnh và metadata. Trong bối cảnh đó, mô hình xử lý dữ liệu bảng cần đáp ứng đồng thời nhiều yêu cầu về khả năng học biểu diễn, khả năng tích hợp và hiệu quả huấn luyện.

Thứ nhất, TabM có khả năng học biểu diễn từ dữ liệu bảng thông qua backbone dùng chung. Trong quá trình huấn luyện, mô hình học được các vector biểu diễn (embedding) phản ánh thông tin và mối quan hệ giữa các đặc trưng của từng mẫu dữ liệu. Các vector biểu diễn này có thể được sử dụng làm đầu vào cho quá trình kết hợp với nhánh xử lý hình ảnh trong kiến trúc đa phương thức, góp phần khai thác đồng thời thông tin từ cả dữ liệu hình ảnh và metadata.

Thứ hai, metadata trong ISIC 2024 bao gồm nhiều đặc trưng được xây dựng từ kiến thức miền và ngữ cảnh bệnh nhân (patient context). Các đặc trưng này thường có mối quan hệ phi tuyến và bổ sung lẫn nhau trong việc phản ánh nguy cơ ác tính của tổn thương. Với khả năng học các tương tác giữa nhiều đặc trưng, TabM có thể khai thác hiệu quả hơn thông tin tiềm ẩn trong dữ liệu bảng, từ đó nâng cao chất lượng biểu diễn của metadata phục vụ cho mô hình đa phương thức.

Thứ ba, kiến trúc của TabM thuận lợi cho việc tích hợp và huấn luyện đồng thời với nhánh xử lý hình ảnh trong mô hình đa phương thức. Các vector biểu diễn được tạo ra từ dữ liệu bảng có thể được kết hợp với biểu diễn của dữ liệu hình ảnh thông qua các chiến lược hợp nhất (fusion) hoặc các cơ chế tương tác giữa các modality. Nhờ đó, toàn bộ hệ thống có thể được huấn luyện theo cơ chế end-to-end, giúp tối ưu đồng thời cả hai nhánh của mô hình.

Cuối cùng, TabM đạt được sự cân bằng giữa hiệu năng và chi phí tính toán. Với kiến trúc được thiết kế chuyên biệt cho dữ liệu bảng, mô hình có thể đạt hiệu quả cạnh tranh trên nhiều bộ dữ liệu trong khi vẫn duy trì quá trình huấn luyện và suy luận hiệu quả. Điều này giúp giảm chi phí tính toán khi tích hợp vào hệ thống học sâu đa phương thức, đặc biệt trong bối cảnh mô

hình cần được huấn luyện đồng thời với nhánh xử lý hình ảnh trên bộ dữ liệu ISIC 2024.

Từ các phân tích trên có thể thấy, việc lựa chọn TabM trong đồ án không chỉ dựa trên kết quả thực nghiệm của mô hình trên các benchmark dữ liệu bảng mà còn xuất phát từ khả năng học biểu diễn và khả năng tích hợp với kiến trúc học đa phương thức. Đây cũng là lý do TabM được lựa chọn làm nhánh xử lý metadata trong mô hình đề xuất.

2.3 Học biểu diễn đa phương thức

Trong nhiều bài toán trí tuệ nhân tạo hiện đại, thông tin về một đối tượng thường không được biểu diễn bởi một nguồn dữ liệu duy nhất mà đến từ nhiều phương thức (modality) khác nhau. Mỗi phương thức phản ánh một khía cạnh riêng của đối tượng và mang những ưu điểm cũng như hạn chế khác nhau. Việc khai thác đồng thời nhiều nguồn dữ liệu có thể cung cấp thông tin đầy đủ hơn so với việc sử dụng từng nguồn dữ liệu độc lập [15].

Đối với bài toán phát hiện ung thư da, ảnh tổn thương phản ánh các đặc điểm hình thái như màu sắc, cấu trúc và hình dạng của tổn thương, trong khi metadata chứa các thông tin lâm sàng như tuổi, giới tính, vị trí giải phẫu và các đặc trưng ở mức bệnh nhân. Hai nguồn dữ liệu này không thay thế mà bổ sung cho nhau trong quá trình đánh giá nguy cơ melanoma. Điều này cũng phù hợp với quy trình chẩn đoán của bác sĩ da liễu, khi quyết định lâm sàng được đưa ra dựa trên cả hình ảnh và bối cảnh của bệnh nhân.

Trong đồ án này, dữ liệu hình ảnh và metadata được xem là hai modality độc lập. Mỗi modality trước tiên được ánh xạ sang một không gian biểu diễn (representation space) thông qua các mô hình học sâu riêng biệt. Sau đó, các biểu diễn này được kết hợp để tạo thành một biểu diễn thống nhất phục vụ bài toán phân loại. Vì vậy, trước khi trình bày kiến trúc kết hợp trong Chương 3, cần tìm hiểu các khái niệm cơ bản về Representation Learning, Multimodal Learning và Cross-modal Interaction.

2.3.1 Học biểu diễn (Representation Learning)

Trong học máy truyền thống, chất lượng của mô hình phụ thuộc nhiều vào quá trình xây dựng đặc trưng, trong đó các đặc trưng đầu vào được thiết kế thủ công dựa trên kinh nghiệm của chuyên gia. Cách tiếp cận này thường mang lại hiệu quả tốt khi bài toán có kiến thức miền rõ ràng, tuy nhiên khả năng biểu diễn của mô hình bị giới hạn bởi chính các đặc trưng đã được thiết kế.

Sự phát triển của học sâu đã đưa ra một cách tiếp cận khác, gọi là học biểu diễn

(Representation Learning). Thay vì chỉ sử dụng trực tiếp các đặc trưng đầu vào, mô hình học một không gian biểu diễn tiềm ẩn (latent representation), trong đó các đặc trưng được chuyển đổi thành các vector có khả năng phản ánh những thông tin quan trọng phục vụ nhiệm vụ dự đoán [14].

Một biểu diễn tốt cần thỏa mãn ba yêu cầu cơ bản:

- Giữ lại thông tin quan trọng của dữ liệu đầu vào.
- Loại bỏ các yếu tố nhiễu hoặc ít liên quan đến nhiệm vụ dự đoán.
- Thuận lợi cho quá trình học của mô hình phía sau, chẳng hạn như phân loại hoặc kết hợp với các modality khác.

Trong đồ án này, cả hai nhánh của mô hình đều thực hiện quá trình học biểu diễn:

- **Nhánh hình ảnh**: học biểu diễn từ ảnh tổn thương thông qua mô hình thị giác.
- **Nhánh dữ liệu bảng**: học biểu diễn từ metadata và các đặc trưng được xây dựng từ kiến thức miền thông qua TabM.

Kết quả của hai nhánh không phải là dự đoán cuối cùng mà là hai vector biểu diễn có cùng mục tiêu: mô tả tổn thương dưới hai góc nhìn khác nhau. Những vector này sẽ được kết hợp trong bước học đa phương thức để tạo thành biểu diễn thống nhất của mẫu dữ liệu.

2.3.2 Học đa phương thức (Multimodal Learning)

Trong nhiều bài toán thực tế, một đối tượng thường được mô tả bởi nhiều nguồn dữ liệu khác nhau. Mỗi nguồn dữ liệu chỉ phản ánh một phần thông tin của đối tượng và không thể mô tả đầy đủ toàn bộ bản chất của bài toán. Học đa phương thức (Multimodal Learning) là lĩnh vực nghiên cứu các phương pháp khai thác đồng thời nhiều nguồn dữ liệu nhằm xây dựng mô hình có khả năng học được biểu diễn thống nhất từ các phương thức khác nhau [15].

Theo Baltrušaitis và cộng sự, một hệ thống học đa phương thức bao gồm nhiều modality, trong đó mỗi modality biểu diễn một góc nhìn khác nhau của cùng một đối tượng. Ví dụ, trong bài toán nhận dạng cảm xúc, hình ảnh khuôn mặt và giọng nói là hai modality; trong bài toán xe tự hành, camera và LiDAR là hai modality; còn trong bài toán phát hiện ung thư da của đồ án, ảnh tổn thương và metadata lâm sàng được xem là hai modality bổ sung cho nhau [15].

Đối với bộ dữ liệu ISIC 2024, ảnh tổn thương cung cấp các thông tin về hình thái như màu sắc, kết cấu và cấu trúc bề mặt da. Trong khi đó, metadata phản ánh các thông tin mà hình

ảnh không thể hiện được, chẳng hạn như tuổi, giới tính, vị trí giải phẫu, các đặc trưng được xây dựng từ hệ thống 3D Total Body Photography và các đặc trưng ở mức bệnh nhân. Hai nguồn thông tin này có bản chất khác nhau nhưng cùng hướng tới việc mô tả nguy cơ ác tính của một tổn thương da.

Nếu chỉ sử dụng ảnh, mô hình có thể bỏ qua nhiều thông tin lâm sàng quan trọng. Ngược lại, nếu chỉ sử dụng metadata thì các đặc điểm trực quan của tổn thương sẽ không được khai thác đầy đủ. Do đó, việc kết hợp đồng thời cả hai nguồn dữ liệu giúp mô hình tận dụng được ưu điểm của từng modality, từ đó xây dựng một biểu diễn đầy đủ hơn cho mỗi mẫu dữ liệu. Đây cũng là xu hướng được nhiều nghiên cứu gần đây áp dụng trong các bài toán AI y tế, đặc biệt là các hệ thống hỗ trợ chẩn đoán kết hợp ảnh y khoa với thông tin lâm sàng [4, 15].

Từ góc nhìn học biểu diễn, mục tiêu của học đa phương thức không chỉ là ghép hai nguồn dữ liệu lại với nhau mà là học được một biểu diễn chung (joint representation) chứa thông tin của tất cả các modality. Biểu diễn này cần bảo toàn các đặc trưng quan trọng của từng nguồn dữ liệu, đồng thời khai thác được mối quan hệ bổ sung giữa chúng. Khi biểu diễn chung được xây dựng hiệu quả, mô hình có thể đưa ra quyết định dựa trên nhiều khía cạnh của cùng một đối tượng thay vì chỉ dựa trên một nguồn dữ liệu đơn lẻ.

Trong đồ án này, nhánh xử lý hình ảnh và nhánh xử lý metadata trước tiên học các biểu diễn riêng biệt (Image Representation và Patient Representation). Hai biểu diễn này sau đó được kết hợp để tạo thành Multimodal Representation, làm đầu vào cho bộ phân loại cuối cùng. Cách tiếp cận này phù hợp với đặc điểm của bộ dữ liệu ISIC 2024 và phản ánh gần hơn quy trình đánh giá của bác sĩ da liễu, khi quyết định lâm sàng được đưa ra dựa trên cả đặc điểm thị giác của tổn thương và thông tin ở mức bệnh nhân.

2.3.3 Tương tác giữa các phương thức (Cross-modal Interaction)

Trong các hệ thống học đa phương thức, việc khai thác từng modality một cách độc lập thường chưa đủ để mô hình tận dụng hết thông tin của dữ liệu. Mặc dù mỗi modality có thể học được một biểu diễn riêng, quyết định cuối cùng thường phụ thuộc vào mối quan hệ giữa các modality. Do đó, một trong những vấn đề quan trọng của học đa phương thức là xây dựng cơ chế cho phép các modality tương tác (interaction) với nhau trong quá trình học biểu diễn [15].

Cross-modal Interaction là quá trình trao đổi thông tin giữa các modality nhằm khai thác tính bổ sung của từng nguồn dữ liệu. Thay vì chỉ ghép các vector biểu diễn sau khi mỗi nhánh đã hoàn thành quá trình học, cơ chế này cho phép thông tin từ một modality ảnh hưởng trực tiếp đến quá trình học biểu diễn của modality còn lại. Nhờ đó, mô hình có thể học được những đặc

trưng mà từng nguồn dữ liệu riêng lẻ không thể biểu diễn đầy đủ.

Đối với bài toán phát hiện ung thư da, hai modality được sử dụng trong đồ án gồm ảnh tổn thương và metadata ở mức bệnh nhân. Hai nguồn dữ liệu này có vai trò khác nhau nhưng mang tính bổ sung. Ảnh tổn thương phản ánh các đặc điểm trực quan như hình dạng, màu sắc và kết cấu, trong khi metadata chứa các thông tin lâm sàng như tuổi, giới tính, vị trí giải phẫu và các đặc trưng được xây dựng từ kiến thức miền. Nếu chỉ kết hợp hai vector biểu diễn bằng phép nối (concatenation), mô hình có thể khai thác được thông tin của cả hai nguồn nhưng chưa mô hình hóa được mối quan hệ giữa chúng.

Để giải quyết vấn đề này, nhiều nghiên cứu đã đề xuất các cơ chế tương tác đa phương thức, trong đó nổi bật là các phương pháp dựa trên attention. Thay vì xem các modality là độc lập, attention cho phép mô hình xác định những thành phần quan trọng của một modality dưới sự định hướng của modality còn lại. Điều này giúp quá trình học biểu diễn trở nên linh hoạt hơn và phản ánh đúng cách con người kết hợp nhiều nguồn thông tin trong quá trình ra quyết định [15, 19].

Trong đồ án này, cơ chế tương tác giữa hai modality được xây dựng thông qua Cross-Attention. Biểu diễn của metadata không chỉ đóng vai trò là thông tin bổ sung sau cùng mà còn tham gia trực tiếp vào quá trình khai thác đặc trưng hình ảnh. Cách tiếp cận này giúp mô hình học được mối quan hệ giữa đặc điểm thị giác của tổn thương và thông tin lâm sàng của bệnh nhân, từ đó tạo ra biểu diễn đa phương thức có khả năng phản ánh đầy đủ hơn bản chất của mẫu dữ liệu.

Chiến lược	**Nguyên lý**	**Ưu điểm**	**Hạn chế**
Early Fusion	Ghép dữ liệu đầu vào	Đơn giản	Khó xử lý dữ liệu khác kiểu
Late Fusion	Kết hợp kết quả dự đoán	Dễ triển khai	Không học được tương tác
Intermediate Fusion	Kết hợp embedding	Linh hoạt	Phụ thuộc kiến trúc
Cross-modal Interaction	Hai modality tương tác khi học	Khai thác quan hệ bổ sung	Thiết kế phức tạp hơn

Bảng 2.1: So sánh các chiến lược kết hợp đa phương thức

2.3.4 Cơ chế Cross-Attention

Một trong những phương pháp phổ biến để xây dựng tương tác giữa các modality là Cross-Attention. Cơ chế này được phát triển từ kiến trúc Transformer và cho phép một modality định hướng quá trình trích xuất thông tin của modality còn lại thông qua cơ chế attention [19].

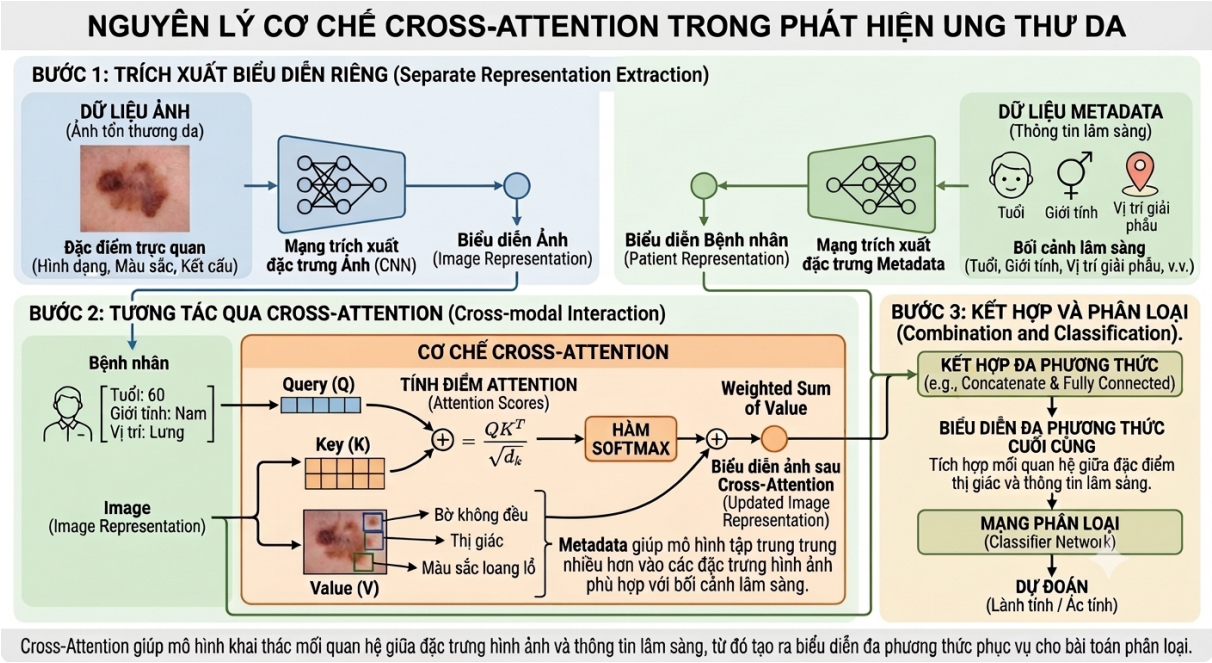
Khác với Self-Attention, trong đó Query (Q), Key (K) và Value (V) đều được tạo từ cùng một nguồn dữ liệu, Cross-Attention sử dụng Query từ một modality và Key–Value từ modality còn lại. Nhờ đó, biểu diễn của một nguồn dữ liệu được cập nhật dựa trên thông tin từ nguồn dữ liệu khác.

Giả sử trong bài toán của đồ án, nhánh hình ảnh tạo ra Image Representation và nhánh TabM tạo ra Patient Representation. Khi áp dụng Cross-Attention, biểu diễn của một nhánh sẽ được điều chỉnh dựa trên thông tin của nhánh còn lại. Ví dụ, nếu Patient Representation được sử dụng để tạo Query, còn Image Representation được sử dụng để tạo Key và Value, thì metadata sẽ đóng vai trò định hướng mô hình tập trung vào những đặc trưng hình ảnh phù hợp với bối cảnh lâm sàng của bệnh nhân.

Về trực giác, cơ chế này có thể được so sánh với quá trình bác sĩ da liễu đánh giá một tổn thương. Trước khi quan sát chi tiết ảnh tổn thương, bác sĩ thường xem xét các thông tin như tuổi, giới tính, vị trí giải phẫu hoặc tiền sử của bệnh nhân. Những thông tin này ảnh hưởng đến việc bác sĩ chú ý nhiều hơn đến một số đặc điểm hình ảnh nhất định. Cross-Attention mô phỏng chính quá trình này bằng cách cho phép thông tin lâm sàng tác động trực tiếp đến quá trình học đặc trưng hình ảnh thay vì chỉ được ghép vào ở bước cuối.

Một ưu điểm quan trọng của Cross-Attention là khả năng học mối quan hệ phụ thuộc giữa các modality. Thay vì giả định rằng hai nguồn dữ liệu đóng góp độc lập, mô hình có thể học cách điều chỉnh mức độ ảnh hưởng của từng modality đối với từng mẫu dữ liệu cụ thể. Điều này đặc biệt phù hợp với bài toán phát hiện ung thư da, trong đó vai trò của metadata có thể thay đổi tùy theo từng bệnh nhân và từng loại tổn thương.

Trong đồ án này, Cross-Attention được lựa chọn làm cơ chế kết hợp giữa Image Representation và Patient Representation. Kiến trúc chi tiết, bao gồm cách xây dựng Query, Key và Value cũng như vị trí tích hợp Cross-Attention trong mô hình, sẽ được trình bày trong Chương 3.



Hình 2.4: Nguyên lý của Cross-Attention

2.4 Phương pháp đánh giá mô hình

2.4.1 Ma trận nhầm lẫn (Confusion Matrix)

Trong các bài toán phân loại nhị phân như phát hiện ung thư da, ma trận nhầm lẫn là công cụ cơ bản để đánh giá hiệu năng của mô hình [20]. Ma trận này thống kê các kết quả dự đoán thành bốn nhóm:

- **True Positive (TP)**: Số lượng tổn thương ác tính (melanoma) được mô hình nhận diện đúng.
- **True Negative (TN)**: Số lượng tổn thương lành tính được phân loại đúng.
- **False Positive (FP)**: Số lượng tổn thương lành tính bị báo động nhầm là ác tính.
- **False Negative (FN)**: Số lượng tổn thương ác tính bị bỏ sót.

Dựa vào ma trận nhầm lẫn, các chỉ số đánh giá quan trọng được định nghĩa theo tiêu chuẩn phân tích ROC [20]:

- **Độ nhạy (Sensitivity / True Positive Rate - TPR)**: Tỷ lệ các ca ác tính được phát hiện chính xác trên tổng số ca ác tính thực tế.

$$\text{TPR} = \frac{TP}{TP + FN} \tag{2.1}$$

- **Độ đặc hiệu (Specificity)**: Tỷ lệ các ca lành tính được phân loại chính xác trên tổng số ca lành tính thực tế.

$$\text{Specificity} = \frac{TN}{TN + FP} \tag{2.2}$$

- **Tỷ lệ dương tính giả (False Positive Rate - FPR)**: Tỷ lệ các ca lành tính bị báo động nhầm, có thể tính thông qua độ đặc hiệu.

$$\text{FPR} = \frac{FP}{FP + TN} = 1 - \text{Specificity} \tag{2.3}$$

2.4.2 Đường cong ROC

Trong các bài toán phân loại nhị phân, đặc biệt là y tế, việc đánh giá mô hình chỉ thông qua độ chính xác (Accuracy) thường không phản ánh đúng hiệu năng do đặc thù mất cân bằng lớp trầm trọng. Một công cụ tiêu chuẩn được sử dụng rộng rãi để đánh giá năng lực phân biệt của mô hình ở mọi ngưỡng quyết định (thresholds) là đường cong Đặc trưng Hoạt động của Máy thu (Receiver Operating Characteristic - ROC) [20].

Đường cong ROC là đồ thị hai chiều biểu diễn mối quan hệ đánh đổi giữa Độ nhạy (TPR) trên trục tung và Tỷ lệ dương tính giả (FPR) trên trục hoành. Một mô hình lý tưởng sẽ phân tách hoàn toàn hai lớp, dẫn đến đường ROC đi qua tọa độ $(0, 1)$ – tức là phát hiện mọi ca bệnh mà không tạo ra bất kỳ báo động nhầm nào. Ngược lại, một mô hình dự đoán ngẫu nhiên (random guessing) sẽ tạo ra đường ROC bám sát đường chéo chính $y = x$.

2.4.3 Diện tích dưới đường cong ROC (AUC)

Để lượng hóa và dễ dàng so sánh hiệu năng của các mô hình trên toàn bộ đường cong ROC, chỉ số Diện tích dưới đường cong (Area Under the ROC Curve - AUC) được áp dụng. Theo phân tích của Hanley & McNeil (1982) [21], AUC mang một ý nghĩa thống kê quan trọng: nó tương đương với xác suất mà mô hình sẽ xếp hạng điểm số (xác suất dự đoán) của một mẫu dương tính cao hơn một mẫu âm tính được chọn ngẫu nhiên.

Về mặt toán học, AUC là tích phân của hàm TPR theo FPR trên toàn bộ miền giá trị:

$$\text{AUC} = \int_0^1 \text{TPR}(u)\, du, \qquad u = \text{FPR} \tag{2.4}$$

Chỉ số AUC luôn nằm trong khoảng $[0, 1]$. Giá trị $\text{AUC} = 0.5$ tương đương với mô hình dự đoán ngẫu nhiên, trong khi $\text{AUC} = 1.0$ đại diện cho một mô hình có khả năng phân loại hoàn hảo.

Ưu điểm lớn nhất của AUC là tính bất biến với các ngưỡng phân loại (threshold-invariant) và bất biến với tỷ lệ lớp (scale-invariant), giúp nó hoạt động ổn định trên các tập dữ liệu mất cân bằng.

Tuy nhiên, trong chẩn đoán y tế lâm sàng, AUC toàn phần (Full AUC) bộc lộ một hạn chế chí mạng: nó đánh giá trung bình trên mọi mức FPR, kể cả những vùng FPR quá cao (báo động giả liên tục) hoặc TPR quá thấp (bỏ sót nhiều ca bệnh) – vốn là các vùng không mang lại giá trị thực tiễn. Một hệ thống hỗ trợ lâm sàng đòi hỏi phải duy trì độ nhạy rất cao để không bỏ lọt bệnh nhân ung thư. Điều này dẫn tới sự cần thiết của một độ đo chuyên biệt hơn.

2.4.4 Partial Area Under the ROC Curve (pAUC)

Để khắc phục hạn chế của AUC truyền thống, nhiều nghiên cứu y sinh sử dụng Partial Area Under the ROC Curve (pAUC) [31]. Khác với AUC tính trên toàn bộ đường cong ROC, pAUC chỉ tính diện tích trong một khoảng giá trị FPR hoặc TPR xác định trước, phản ánh hiệu năng của mô hình tại vùng quan trọng đối với bài toán. Nếu ký hiệu $u = \text{FPR}$ và τ là ngưỡng độ nhạy tối thiểu, công thức chuẩn của pAUC trong vùng độ nhạy cao được biểu diễn qua tích phân:

$$\text{pAUC}_\tau = \int_{\{u:\, \text{TPR}(u) \geq \tau\}} \text{TPR}(u)\, du \tag{2.5}$$

Trong cuộc thi ISIC 2024 cũng như đồ án này, chỉ số đánh giá chính được lựa chọn là pAUC tại vùng độ nhạy cao (high-sensitivity region), cụ thể là TPR ≥ 0.8. Điều này hoàn toàn phù hợp với mục tiêu của hệ thống hỗ trợ sàng lọc ung thư da: việc bỏ sót một trường hợp ác tính (melanoma) có hậu quả nghiêm trọng hơn nhiều so với việc cảnh báo nhầm một tổn thương lành tính [4]. Việc duy trì mức độ nhạy tối thiểu 80% đảm bảo hệ thống có khả năng phát hiện phần lớn các ca bệnh nguy hiểm, trong khi vẫn tối ưu để giữ mức độ báo động giả ở mức chấp nhận được.

Công thức tính toán pAUC (ISIC 2024): Trong thực tiễn lập trình, hàm tính toán pAUC phổ biến của thư viện `scikit-learn` (`roc_auc_score`) hỗ trợ tính diện tích giới hạn theo FPR tối đa (`max_fpr`) chứ không phải TPR tối thiểu. Do đó, quá trình tính toán đòi hỏi một phép biến đổi không gian (label inversion) để tận dụng hàm có sẵn. Giả sử $y \in \{0, 1\}$ là nhãn thực tế và $\hat{y} \in [0, 1]$ là xác suất dự đoán, bài toán được đảo ngược như sau:

$$\tilde{y} = |y - 1|, \qquad \tilde{\hat{y}} = 1 - \hat{y} \tag{2.6}$$

Phép đảo ngược này ánh xạ đường cong ROC qua đường chéo, sao cho điều kiện TPR ≥ 0.8 trên

không gian gốc trở thành điều kiện FPR ≤ 0.2 trên không gian mới. Ngưỡng giới hạn khi đó là:

$$\text{max_fpr} = 1 - \text{min_tpr} = 1 - 0.8 = 0.2 \tag{2.7}$$

trong đó, min_tpr $= 0.8$ là ngưỡng độ nhạy tối thiểu theo yêu cầu bài toán, và max_fpr là giới hạn tỷ lệ dương tính giả lớn nhất tương ứng trên không gian đảo ngược.

Khi được gọi với đối số `max_fpr=0.2`, thư viện `scikit-learn` tính toán và trả về một giá trị pAUC đã được chuẩn hóa (standardized pAUC) theo quy tắc McClish, sao cho một mô hình dự đoán ngẫu nhiên luôn đạt 0.5 và một mô hình hoàn hảo đạt 1.0:

$$pAUC_{scaled} = \texttt{roc_auc_score}(\tilde{y}, \tilde{\tilde{y}}, \text{max_fpr} = 0.2) \tag{2.8}$$

Tuy nhiên, đồ án (và hệ thống chấm điểm ISIC 2024) yêu cầu tối ưu trên giá trị pAUC thô (raw partial AUC). Vì vậy, kết quả trên được giải chuẩn hóa (inverse scaling) để đưa về diện tích thực tế:

$$pAUC_{raw} = \frac{1}{2}(\text{max_fpr})^2 + \frac{\text{max_fpr} - \frac{1}{2}(\text{max_fpr})^2}{1.0 - 0.5} \times (pAUC_{scaled} - 0.5) \tag{2.9}$$

Trong công thức này, $pAUC_{scaled}$ là giá trị pAUC chuẩn hóa trả về từ thư viện, và $pAUC_{raw}$ là diện tích thô thực sự dưới đường cong sau khi giải chuẩn hóa.

Với max_fpr $= 0.2$, diện tích của một dự đoán ngẫu nhiên trên vùng tam giác này là $\frac{1}{2}(0.2)^2 = 0.02$, và diện tích tối đa (hoàn hảo) của hình chữ nhật bao quanh là $0.2 \times 1.0 = 0.2$. Do đó, giá trị pAUC thô ($pAUC_{raw}$) cuối cùng của mô hình sẽ luôn nằm trong khoảng $[0.02, 0.2]$. Việc hiểu chính xác cách tính toán này là cơ sở để thiết kế hàm mất mát (loss function) cũng như các chiến lược theo dõi (early stopping) trong suốt quá trình huấn luyện mô hình.

Chương 3

HIỆN THỰC HỆ THỐNG

Chương này trình bày chi tiết cách chuyển hóa các cơ sở khoa học và thiết kế lý thuyết từ Chương 2 thành một hệ thống mã nguồn thực tế. Hệ thống tuân theo mô hình học sâu đa phương thức, tận dụng cả hình ảnh và dữ liệu dạng bảng. Nhằm đảm bảo tính tập trung vào thuật toán, quy trình được minh họa thông qua các lưu đồ, công thức toán học và kiến trúc mạng. Mã nguồn Python tương ứng được tham chiếu và đính kèm tại Github.

3.1 Ký hiệu toán học

Để đảm bảo tính nhất quán trong phần trình bày kiến trúc và hiện thực hệ thống ở các mục tiếp theo, Bảng 3.1 thống kê lại các ký hiệu toán học cốt lõi sẽ được sử dụng xuyên suốt trong chương.

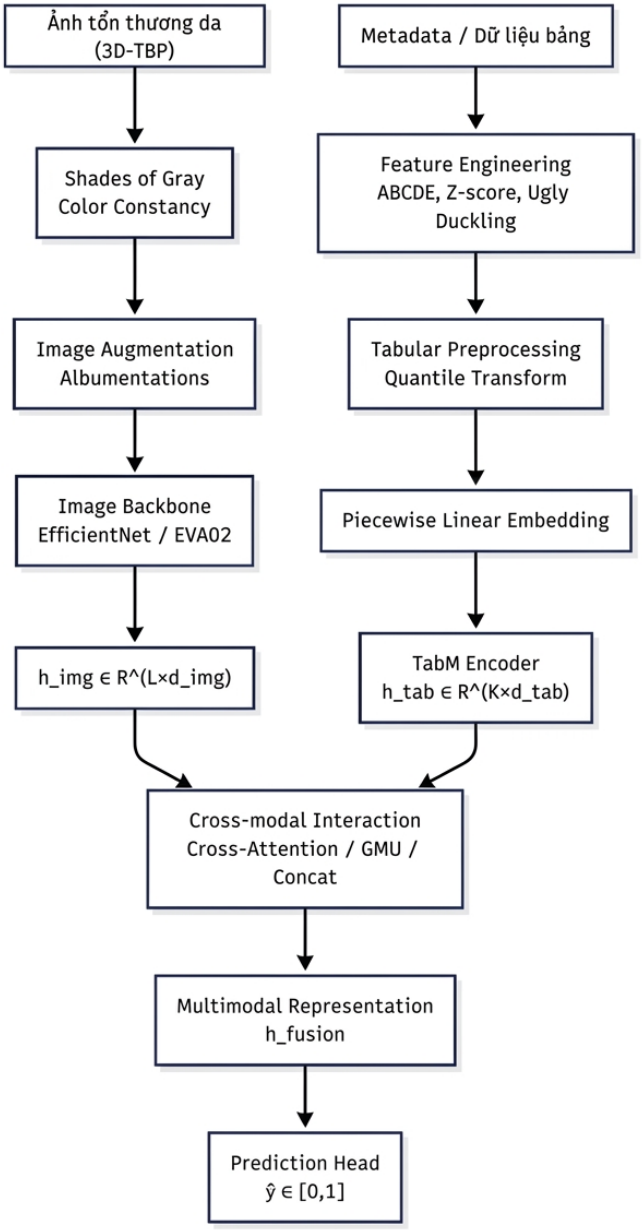
Ký hiệu	Ý nghĩa	Kích thước
$\mathbf{I}$	Ảnh chụp tổn thương da đầu vào	$H \times W \times 3$
$\mathbf{x}$	Vector dữ liệu dạng bảng	$\mathbb{R}^{d_{tab}}$
$\hat{y}$	Xác suất dự đoán ác tính	$[0, 1]$
h_{img}	Biểu diễn ảnh (chuỗi patch tokens)	$\mathbb{R}^{L \times d_{img}}$
$\bar{h}_{img}$	Vector biểu diễn ảnh sau global average pooling	$\mathbb{R}^{d_{img}}$
h_{tab}	Biểu diễn bảng đa chiều (TabM ensemble)	$\mathbb{R}^{K \times d_{tab}}$
h_{fusion}	Biểu diễn đa phương thức sau khi dung hợp	$\mathbb{R}^{B \times K \times 2d_{fusion}}$
K	Số lượng thành viên ensemble trong cấu trúc TabM	32 (mặc định)
d_{img}	Chiều biểu diễn đặc trưng ảnh (EfficientNet/EVA02)	1280 hoặc 384
d_{tab}	Chiều biểu diễn ẩn của mạng TabM	256
d_{fusion}	Chiều không gian dung hợp đa phương thức	256
B	Kích thước tập học (batch size)	Tùy cấu hình (ví dụ: 64)
L	Số lượng patch tokens không gian của ảnh	Phụ thuộc độ phân giải

Bảng 3.1: Bảng ký hiệu toán học

3.2 Kiến trúc tổng thể hệ thống

Hệ thống được thiết kế theo kiến trúc học sâu đa phương thức (Multimodal Deep Learning Architecture) với sự tương tác chặt chẽ giữa hai nhánh độc lập: Hình ảnh (Image Branch) và Bảng

(Tabular Branch), sau đó hội tụ tại module Giao thoa đa phương thức (Fusion Module).



Hình 3.1: Kiến trúc tổng thể hệ thống học sâu đa phương thức.

Mô tả luồng hoạt động tổng thể:

- **Nhánh Tabular:** Metadata trải qua bước trích xuất đặc trưng định hướng tri thức (Knowledge-guided Feature Engineering) nhằm số hóa các quy tắc lâm sàng như ABCDE và dấu hiệu "Vịt con xấu xí". Sau bước tiền xử lý gồm nội suy, lọc đặc trưng và chuẩn hóa phân phối, dữ liệu được ánh xạ thành không gian vector liên tục qua Piecewise Linear Embedding (PLE) và nạp vào mạng Tabular Ensembling (TabM) để sinh ra biểu diễn ở mức bệnh nhân h_{tab} [9].

- **Nhánh Image:** Hình ảnh thô được chuẩn hóa chiếu sáng bằng thuật toán Shades of Gray, sau đó đi qua chuỗi phép tăng cường dữ liệu. Các đặc trưng thị giác cốt lõi được trích xuất bằng mạng nơ-ron tích chập (CNN) hoặc Transformer (EVA02), sinh ra chuỗi biểu diễn h_{img}.

- **Giao thoa đa phương thức (Fusion):** Hai không gian biểu diễn h_{img} và h_{tab} được đưa vào module dung hợp (như Cross-Attention hoặc GMU) để điều chỉnh trọng số tương tác. Kết quả là một vector h_{fusion} thống nhất, được truyền qua lớp Prediction Head để tính toán xác suất ác tính $\hat{y}$.

Để đối phó với hiện tượng sụp đổ phương thức (modality collapse) thường gặp trong học đa phương thức, hệ thống tích hợp sẵn các cơ chế bảo vệ bao gồm hàm mất mát phụ (auxiliary unimodal losses), kỹ thuật ngắt phương thức ngẫu nhiên (modality dropout), và chiến lược huấn luyện phân tầng (staged pretraining) [22].

3.3 Bộ dữ liệu & Phân tích dữ liệu

Hệ thống được phát triển và đánh giá trên bộ dữ liệu **ISIC 2024 - Skin Cancer Detection with 3D-TBP**. Khác với các bộ dữ liệu ảnh soi da (dermoscopy) truyền thống, ISIC 2024 chứa các ảnh cắt (crops) được thu thập từ hệ thống chụp toàn thân 3D Total Body Photography (như Canfield VECTRA WB360). Loại dữ liệu này mang tính chất lâm sàng tiêu chuẩn, phản ánh đúng điều kiện chẩn đoán từ xa, đồng thời đi kèm với lượng metadata phong phú cho phép đối chiếu bệnh lý trên cùng một bệnh nhân [4] .

Thông tin	**Giá trị**
Tổng số mẫu quan sát	401.059
Mẫu ác tính (Malignant, Target = 1)	393
Mẫu lành tính (Benign, Target = 0)	400.666
Tỷ lệ mất cân bằng (Negative : Positive)	≈ 1.019,5 : 1 (hoặc ≈ 1.020 : 1)
Số lượng bệnh nhân (unique patient_id)	1.042
Số vùng giải phẫu (anatom_site_general)	6 nhóm
Số đặc trưng metadata gốc	38 đặc trưng
Kích thước ảnh gốc	Đa dạng (từ 224×224 đến 480×480 pixel)

Bảng 3.2: Thống kê tổng quan bộ dữ liệu ISIC 2024

Cấu trúc dữ liệu dạng bảng: Ngoài dữ liệu ảnh, mỗi mẫu trong ISIC 2024 đi kèm một tập thuộc tính dạng bảng (được lưu trữ trong tệp `train-metadata.csv` theo tên gọi chính

thức của nhà cung cấp). Cần lưu ý rằng tệp này không chỉ chứa thông tin lâm sàng thuần túy mà bao gồm ba nhóm đặc trưng có nguồn gốc khác nhau:

- **Đặc trưng nhân khẩu học – lâm sàng (demographic-clinical features):** gồm tuổi (`age_approx`), giới tính (`sex`), và vị trí giải phẫu của tổn thương (`anatom_site_general`) — là các thông tin được thu thập trực tiếp từ bệnh nhân hoặc bác sĩ, *độc lập* với ảnh chụp.
- **Đặc trưng đo lường tự động trích xuất từ ảnh (image-derived features):** là nhóm `tbp_lv_*`, được tính toán tự động bởi hệ thống 3D-TBP dựa trên phân tích hình dạng, màu sắc và kết cấu của tổn thương. Đây *không phải* đánh giá lâm sàng chủ quan mà là kết quả của một quy trình trích xuất đặc trưng ảnh được thực hiện sẵn ngoài mô hình đề xuất.
- **Đặc trưng phái sinh theo tri thức chuyên gia (knowledge-guided derived features – KFE):** được xây dựng bởi đồ án bằng cách tổ hợp, chuẩn hóa hoặc tính tỷ lệ giữa các đặc trưng thuộc hai nhóm trên, nhằm mã hóa thêm tri thức da liễu học vào không gian đặc trưng đầu vào (trình bày chi tiết tại Mục 3.4).

Do bản chất hỗn hợp này, trong đồ án, thuật ngữ **"dữ liệu dạng bảng" (tabular data)** được sử dụng thay cho "metadata lâm sàng" nhằm phản ánh chính xác hơn nguồn gốc đa dạng của nhánh dữ liệu phi hình ảnh. Bảng 3.3 tóm tắt các nhóm thuộc tính gốc; mô tả chi tiết từng biến được trình bày tại Phụ lục A.1.

Nhóm thuộc tính	Số lượng	Mô tả vai trò
Định danh & Nguồn ảnh	6	isic_id, patient_id, attribution, copyright_license, image_type, tbp_tile_type — phục vụ truy vết, group theo bệnh nhân và kiểm soát rò rỉ dữ liệu, không đưa trực tiếp vào mô hình
Nhân khẩu học & Vị trí lâm sàng	6	age_approx, sex, anatom_site_general, clin_size_long_diam_mm, tbp_lv_location, tbp_lv_location_simple
Toạ độ không gian 3D-TBP	3	tbp_lv_x, tbp_lv_y, tbp_lv_z — vị trí tổn thương trên bản đồ toàn thân
Màu sắc LAB* (trong/ngoài tổn thương)	12	Các thành phần L, A, B, Chroma (C), Hue (H) đo trong và ngoài viền tổn thương, cùng độ lệch chuẩn L
Độ tương phản & bất thường màu	8	Chênh lệch màu trong–ngoài tổn thương (tbp_lv_delta*), độ bất đối xứng màu, độ đồng nhất màu và chuẩn hóa màu sắc (tbp_lv_norm_color)
Hình thái & kích thước	8	Diện tích, chu vi, độ chuẩn hóa viền (tbp_lv_norm_border), độ lệch tâm, độ bất đối xứng hình dạng
Điểm tin cậy từ mô hình AI phụ trợ	1	tbp_lv_nevi_confidence — xác suất tổn thương là nốt ruồi lành tính theo một CNN được huấn luyện riêng
Tổng cộng (dùng được cho cả train/test)	**44**	**Đầu vào khả dụng tại thời điểm suy luận**

Bảng 3.3: Tóm tắt các nhóm thuộc tính metadata gốc của ISIC 2024.

Trong 44 thuộc tính khả dụng ở trên, tập train-metadata.csv có các cột chỉ tồn tại ở tập huấn luyện (nhãn target, lesion_id, chuỗi chẩn đoán chi tiết iddx_full, iddx_1--5, mel_thick_mm, mel_mitotic_index, tbp_lv_dnn_lesion_confidence...). Đây là các thuộc tính mang tính rò rỉ nhãn (label leakage) hoặc không có mặt ở tập test, do đó được loại bỏ hoàn toàn trước khi đưa vào pipeline trích xuất đặc trưng.

Đặc điểm nổi bật nhất của bộ dữ liệu là **tỷ lệ mất cân bằng lớp cực đoan** (extreme class imbalance) với chưa tới 0.1% số mẫu là ác tính. Điều này đặt ra thách thức rất lớn đối với quá

trình lấy mẫu (sampling) và thiết kế hàm mất mát.

Lưu trữ và Xử lý I/O bằng HDF5: Với hơn 400.000 tệp ảnh rời rạc, việc đọc trực tiếp từ ổ cứng trong quá trình huấn luyện sẽ tạo ra nút thắt cổ chai (I/O bottleneck), khiến GPU không thể hoạt động tối đa công suất. Nhằm giải quyết vấn đề này, toàn bộ hình ảnh được nén, biên dịch và lưu trữ tuần tự dưới định dạng HDF5 (Hierarchical Data Format version 5). Phương pháp này giúp nạp khối lượng lớn dữ liệu vào RAM một cách hiệu quả và liên tục.

Phân tách dữ liệu (Cross Validation): Quá trình đánh giá được thực hiện qua kỹ thuật phân tách `StratifiedGroupKFold` dựa trên hai nguyên tắc. Thứ nhất là **phân nhóm theo bệnh nhân (`patient_id`)**, đảm bảo tất cả tổn thương của một bệnh nhân chỉ nằm trọn vẹn trong một nếp gấp (fold). Điều này ngăn chặn rò rỉ dữ liệu (data leakage) — nơi mô hình có thể vô tình học được đặc điểm sinh học chung của bệnh nhân thay vì các dấu hiệu ác tính thực sự. Thứ hai là **phân tầng (Stratified)**, đảm bảo tỷ lệ số lượng mẫu ung thư hiếm hoi được dàn đều giữa các nếp gấp. Hệ thống cho phép tinh chỉnh số nếp gấp `n_splits` (mặc định là 5 cho thiết lập đầy đủ). Hạt giống ngẫu nhiên `random_state=42` được áp dụng xuyên suốt để đảm bảo khả năng tái lập thí nghiệm.

3.4 Knowledge-guided Feature Engineering

Thay vì nạp trực tiếp metadata thô, hệ thống sử dụng kiến thức y khoa chuyên ngành để định hướng quá trình tạo đặc trưng, số hóa các quy tắc chẩn đoán thành con số. Quy trình kiến tạo đặc trưng này được thực hiện khép kín qua ba bước nhằm bảo đảm an toàn dữ liệu và tránh rò rỉ thông tin. Bước đầu tiên là **điền khuyết cơ sở (Base Imputation)**, trong đó các đặc trưng số học gốc (như `age_approx`) được điền khuyết bằng trung vị (median) của tập huấn luyện, trong khi các biến phân loại bị thiếu (như `sex`, `anatom_site_general`) được gán nhãn ``UNK'' (Unknown) để biểu diễn trạng thái thiếu dữ liệu như một lớp riêng biệt; việc phân tách chiến lược điền khuyết theo từng loại biến giúp ngăn chặn việc các giá trị khuyết (`NaN`) bị lan truyền vào các phép toán KFE sau đó. Bước tiếp theo là **kiến tạo đặc trưng**, sản sinh ra 651 đặc trưng từ các biến gốc, được phân tầng theo bốn ngữ cảnh Ablation chính. Cuối cùng là **điền khuyết bổ trợ (Engineered Imputation)**, trong đó một lượt điền khuyết bằng trung vị bổ trợ được thực hiện trên các cột đặc trưng mới nhằm xử lý triệt để các giá trị khuyết hoặc vô cùng phát sinh từ quá trình tính toán (ví dụ: chia cho 0 hoặc độ lệch chuẩn bằng 0).

3.4.1 Đặc trưng nội tại nốt ruồi (ABCD) — 69 đặc trưng

Khai thác theo nguyên tắc lâm sàng **ABCD** [10]:

- **A (Asymmetry):** Các chỉ số `asymmetry_ratio`, `asymmetry_area_ratio` phản ánh độ lệch trục.
- **B (Border):** Đánh giá độ nham nhở qua tỷ lệ tương tác `border_complexity`, `compactness`, và `border_sharpness_index`.
- **C (Color):** Phân tích sự đồng nhất sắc tố bằng `color_uniformity`, `hue_contrast`, và không gian LAB.
- **D (Diameter):** Kích thước chuẩn hóa `normalized_lesion_size` và độ tương quan.
- **Tương tác:** Các tích số kết hợp hình thái học (như `age × size`).

3.4.2 Chuẩn hóa mức bệnh nhân (Patient Norm) — 109 đặc trưng

Thực hiện hiệu chỉnh sự khác biệt sinh học giữa các bệnh nhân bằng cách đưa các biến số học về cùng một phân phối chuẩn hóa cục bộ thông qua việc tính toán điểm Z-score thường (bao gồm cả tổn thương đang xét) theo từng bệnh nhân cho mỗi biến số học:

$$\mu_{patient} = \frac{1}{N}\sum_{j=1}^{N}\tilde{x}_j, \qquad z_{patient} = \frac{\tilde{x}_i - \mu_{patient}}{\sigma_{patient} + \epsilon} \tag{3.1}$$

Trong đó, N là tổng số tổn thương của chính bệnh nhân đó. Phép chuẩn hóa này giúp mô tả vị trí tương đối của nốt ruồi so với các nốt khác trên cùng cơ thể.

3.4.3 Ngoại lai và Giải phẫu học (UD Advanced) — 116 đặc trưng

Ứng dụng lý thuyết **Dấu hiệu Vịt con xấu xí (Ugly Duckling Sign)** [7] và các thuật toán phát hiện bất thường nâng cao:

- **Z-score loại bỏ bản thân (Leave-One-Out Z-score - z_{LOO}):** Tính toán sự sai lệch của nốt ruồi với các nốt còn lại của bệnh nhân tại cùng vùng giải phẫu (đóng góp 109 đặc trưng `ud_loc_*`):

$$\mu_{-i} = \frac{1}{N-1}\sum_{j\neq i}\tilde{x}_j, \qquad z_{LOO} = \frac{\tilde{x}_i - \mu_{-i}}{\sigma_{patient} + \epsilon} \tag{3.2}$$

Với bệnh nhân chỉ có 1 tổn thương ($N = 1$), đặc trưng này được gán mặc định bằng 0.0 để tránh chia cho 0 và thể hiện không có sự sai lệch.

- **Ngoại lai cục bộ (LOF):** Sử dụng thuật toán `LocalOutlierFactor` [24] chấm điểm `patient_lof_score` (1 đặc trưng) trên không gian 6 chiều đặc trưng hình thái cốt lõi để phát hiện bất thường đa biến.
- **Khoảng cách cảnh báo (UD Metrics):** Khoảng cách Euclid tổng hợp từ các z-score LOO (`ud_composite_distance`) và các thống kê tóm tắt (`ud_count_location`, `ud_max_...`) đóng góp 4 đặc trưng.
- **Tích lũy diện tích và giải phẫu nâng cao:** Tổng diện tích tổn thương của bệnh nhân (`tbp_lv_areaMM2_patient`, `tbp_lv_areaMM2_bp`) và Z-score vùng giải phẫu toàn cục (`_anatomical_zscore`) đóng góp 5 đặc trưng.

3.4.4 Ngữ cảnh tương tác phân loại (Categorical Context) — 318 đặc trưng

Khai phá tri thức dựa trên sự kết hợp chéo giữa các đặc trưng số học và phân loại của bệnh nhân:

- **Tương tác chéo giải phẫu (Patient×Site):** Tính toán Z-score của 109 biến số học theo nhóm (bệnh nhân × vùng giải phẫu) để chuẩn hóa cục bộ chi tiết hơn. Đóng góp 109 đặc trưng (`_patient_site_general_norm`).
- **Tương tác (NUM×CAT):** Nhân chéo 34 biến nền tảng với 5 biến phân loại tương tác trên cùng bệnh nhân ($34 \times 5 = 170$ đặc trưng).
- **Các bộ đếm tần suất (Counters):** Số nốt ruồi của bệnh nhân (`count_per_patient`), cờ đơn tổn thương (`is_single_lesion_patient`) và bộ đếm tần suất xuất hiện của các biến phân loại đóng góp 39 đặc trưng.

Nhóm đặc trưng	Số lượng	Mô tả vai trò
Base (Cơ sở)	34	Các giá trị số học nguyên bản từ hệ thống 3D-TBP (38 cột gốc trừ 4 cột định danh/rò rỉ như `patient_id`, `isic_id`, `lesion_id`, `attribution` đã loại ở Bước 1)
ABCD (Hình thái học)	69	Các chỉ số cấu trúc hình học, hình dạng và sắc tố nội tại của nốt ruồi
Patient Norm	109	Điểm chuẩn hóa Z-score thường theo cơ thể bệnh nhân (chuẩn hóa ngữ cảnh cá thể)
UD Advanced	116	Điểm chuẩn hóa loại bỏ bản thân z_{LOO} (Lõi Vịt con xấu xí), thuật toán dò ngoại lai đa biến LOF và đối chiếu diện tích/giải phẫu học
Categorical Context	318	Chuẩn hóa giải phẫu chéo (Patient×Site), tương tác chéo NUM×CAT và các bộ đếm sinh học
Categorical Embeddings	5	5 biến phân loại gốc (mã hóa Integer Codes và nạp qua lớp Categorical Embedding của mô hình)
Tổng cộng	**651**	**Đầu vào chính thức của mạng Tabular Ensembling**

Bảng 3.4: Tổng hợp cấu hình đặc trưng đầu vào mạng TabM (Baseline & Ablation)

3.4.5 Kiểm soát đa cộng tuyến và rủi ro quá khớp (Overfitting)

Việc tăng kích thước đặc trưng từ 38 lên 651 biến chắc chắn dẫn đến hai thách thức lớn: hiện tượng đa cộng tuyến (các đặc trưng tương quan tuyến tính rất cao, ví dụ: `asymmetry_ratio` và `asymmetry_area_ratio`) và rủi ro quá khớp do không gian đặc trưng quá lớn so với tập mẫu dương hiếm hoi (chỉ 393 ca ác tính). Hệ thống giải quyết các vấn đề này mà không cần dùng đến các phương pháp giảm chiều (Dimensionality Reduction) thông qua đặc tính nội tại của kiến trúc.

Thứ nhất là khả năng **kháng đa cộng tuyến của mạng nơ-ron phi tuyến**. Đối với các mô hình hồi quy tuyến tính cổ điển, đa cộng tuyến gây mất ổn định số học nghiêm trọng do ma trận hiệp phương sai gần suy biến. Tuy nhiên, kiến trúc phi tuyến như TabM không giải trực tiếp hệ phương trình trên không gian đặc trưng. Kết hợp với mã hóa PLE (băm từng biến thành các hàm cơ sở độc lập), mô hình linh hoạt phân bổ trọng số (attention/gating) ngay cả khi hai biến tương quan cao, giảm thiểu tác động tiêu cực lên quá trình tối ưu hóa trọng số.

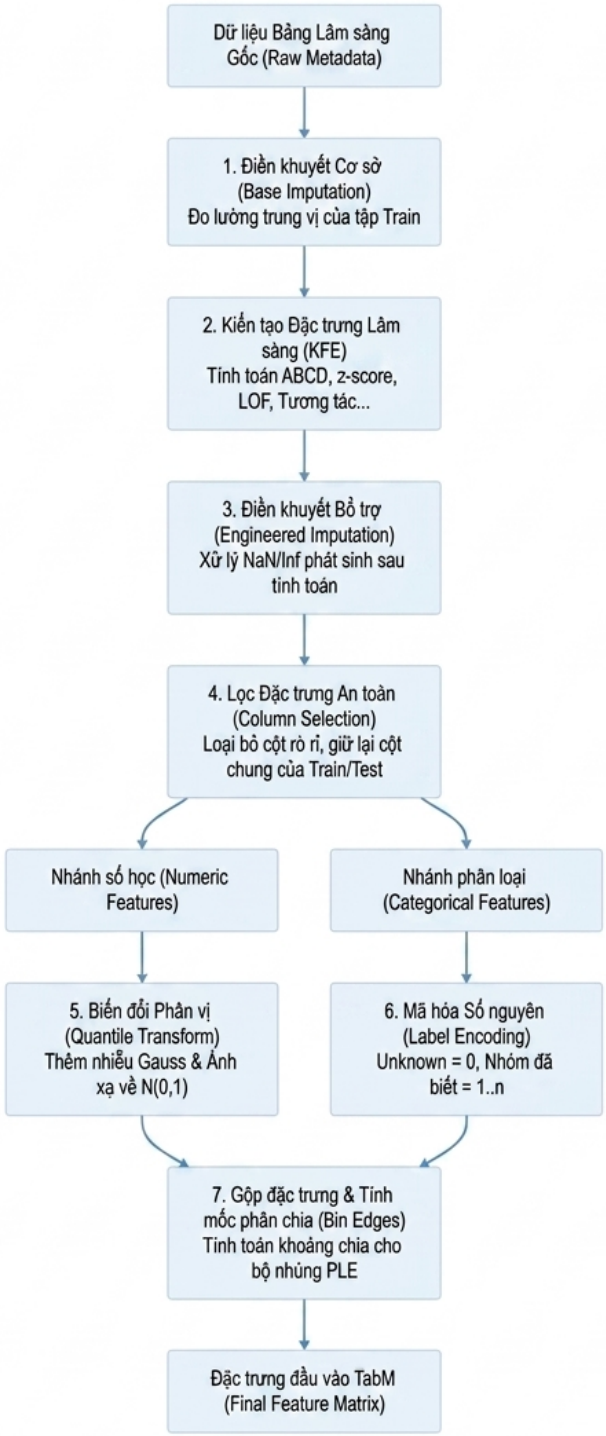
Thứ hai là **Ensemble giảm phương sai (Variance Reduction)**. Thay vì học một tập trọng số duy nhất dễ bị quá khớp vào 651 đặc trưng, TabM áp dụng kỹ thuật Parameter-efficient Ensembling chia sẻ trọng số nền tảng nhưng tạo ra các vector nhiễu (rank-1 perturbation) cho $K = 32$ thành viên. Đầu ra cuối cùng là trung bình cộng (soft-averaging) của 32 dự đoán này, giúp giảm phương sai đáng kể và kìm hãm Overfitting.

Cuối cùng là **tác động phụ từ Undersampling động**. Hàm `EpochRandomUndersampler` vốn được thiết kế để giải quyết sự mất cân bằng lớp (Class Imbalance) bằng cách chọn ngẫu nhiên một tập âm mới mỗi epoch (chỉ diễn ra bên trong tập Train). Việc làm mới tập âm liên tục đã đóng vai trò như một kỹ thuật làm nhiễu dữ liệu (data augmentation), ép mô hình không thể ghi nhớ cứng các mẫu âm cố định, góp phần đẩy lùi hiện tượng học vẹt.

Giao thức chống rò rỉ dữ liệu (Anti-Leakage Protocol): Toàn bộ 651 đặc trưng nêu trên được tái tính toán (refit) độc lập bên trong từng fold huấn luyện. Hơn nữa, với cơ chế `StratifiedGroupKFold` theo định danh bệnh nhân, các phép tính như Z_{LOO} hay LOF chỉ tham chiếu đến các nốt ruồi đang nằm trọn vẹn trong một Fold duy nhất. Quy trình này được thiết kế nhằm loại bỏ triệt để các con đường rò rỉ đã biết, giảm thiểu tối đa nguy cơ rò rỉ phân phối giữa Train và Valid.[23]

3.5 Quy trình tiền xử lý dữ liệu bảng

Sau khi dữ liệu bảng được làm giàu bằng các biến lâm sàng nâng cao ở Mục 3.4, toàn bộ tập đặc trưng số học và phân loại (bao gồm cả biến gốc và biến KFE) sẽ đi qua chuỗi bước tiền xử lý và chuẩn hóa cuối cùng trước khi đưa vào mô hình, minh họa tại Hình 3.2.



Hình 3.2: Luồng tiền xử lý dữ liệu bảng

Bước 4: Lọc đặc trưng an toàn (Column Selection)

Loại bỏ các cột định danh nguồn thu thập (như `attribution`, `copyright_license`) nhằm giảm thiểu rủi ro mô hình học trực tiếp các ”thiên kiến thu thập”(ví dụ: một bệnh viện

tuyến cuối chuyên nhận ca nặng nên có tỷ lệ ác tính cao bất thường). Hệ thống chỉ giữ lại những đặc trưng xuất hiện đồng thời ở cả tập huấn luyện và kiểm thử. Mặc dù vậy, sự dịch chuyển phân phối (distribution shift) của các đặc trưng phần cứng 3D (như `tbp_lv_*`) giữa các cơ sở y tế khác nhau vẫn có thể gây ra rò rỉ gián tiếp, đòi hỏi mô hình phải có năng lực khái quát hóa cao để không bị phụ thuộc vào thiết bị chụp.

Bước 5: Biến đổi phân phối (Quantile Transform)

Các biến số học trong y tế thường phân bố chênh lệch cực độ (highly skewed). Hệ thống sử dụng thuật toán `QuantileTransformer` để ánh xạ toàn bộ các biến số học về dạng phân phối chuẩn (`output_distribution='normal'`), với số lượng mốc lượng tử `n_quantiles` được giới hạn ở $\min(N/30, 1000)$. Trước khi khớp (fit) mô hình, một lượng nhiễu Gauss vi mô $\mathcal{N}(0, 10^{-5})$ được tiêm vào dữ liệu nhằm phá vỡ các giá trị trùng lặp (tie-breaking) — qua đó làm trơn hàm phân vị thực nghiệm và ổn định không gian tính toán cho thuật toán nhúng PLE [9, 17].

Bước 6: Mã hóa biến phân loại (Categorical Encoding)

Với kiến trúc TabM, các giá trị thiếu của biến phân loại được gán nhãn ``UNK'' (Unknown) trước khi mã hóa. Hệ thống sử dụng mã hóa số nguyên (Label Encoding), trong đó mã `0` được dành riêng cho nhãn vắng mặt (unknown, bao gồm cả các giá trị đã được gán ``UNK'' ở bước trước), còn các nhóm đã biết được đánh số từ `1` trở đi. Đối với các kiến trúc không dùng TabM, biến phân loại được biểu diễn qua mã hóa One-Hot. Các biến phân loại bao gồm: `sex`, `anatom_site_general`, `tbp_tile_type`, `tbp_lv_location`, và `tbp_lv_location_simple`.

Bước 7: Gộp đặc trưng và lưu mốc phân chia (Bin Edges)

Dữ liệu số học và phân loại được nối lại thành một ma trận đặc trưng hoàn chỉnh. Đối với dữ liệu số học, các mốc phân chia (bin edges) được tính toán tự động qua hàm `compute_bins` dựa trên phân phối lượng tử của tập huấn luyện. Các giá trị ngoại lai ở tập kiểm thử (nếu có) sẽ được kẹp chặt (clipping) vào các thùng ngoài cùng, tuân thủ chính xác thiết kế gốc của thuật toán nhúng Piecewise Linear Encoding (PLE) trong mạng TabM.

3.6 Image Representation Learning

3.6.1 Chuẩn hóa màu sắc (Shades of Gray Color Constancy)

Vì hình ảnh 3D-TBP chịu ảnh hưởng từ điều kiện ánh sáng phòng khám khác nhau, thuật toán màu không đổi Shades of Gray [30] được áp dụng. Dựa vào chuẩn Minkowski bậc $p = 6$,

nguồn chiếu sáng $\hat{e}_c$ được ước lượng thông qua cường độ điểm ảnh I_c:

$$\hat{e}_c = \left(\frac{1}{N} \sum_{\mathbf{p}} I_c(\mathbf{p})^p \right)^{1/p} \tag{3.3}$$

Nguồn sáng này sau đó được chuẩn hóa vector $\|\hat{e}\|_2$ và dùng để hiệu chỉnh hình ảnh: $I_{corrected} = I/(\hat{e} + \epsilon) \cdot \frac{1}{\sqrt{3}}$. Thuật toán giúp mô hình CNN tập trung vào màu sắc bệnh lý thay vì sắc thái ánh sáng môi trường.

3.6.2 Tăng cường dữ liệu (Image Augmentation)

Hệ thống sử dụng thư viện `Albumentations` [25] để nạp đa dạng biến đổi trên GPU, bắt buộc mô hình học tính bất biến (invariance) của tổn thương. Các phép biến đổi được thống kê chi tiết trong Bảng 3.5. Trong quá trình kiểm thử (Validation), hệ thống chỉ thực hiện thay đổi kích thước, chuẩn hóa ImageNet, và chuyển đổi sang dạng tensor.

Nhóm biến đổi	**Phép biến đổi cụ thể**	**Tham số chính**	**Xác suất (p)**
Không gian học	Transpose, HorizontalFlip, VerticalFlip	—	0.5
Hình học affine	ShiftScaleRotate	shift=0.1, scale=0.1, rotate=15°	0.5
Cân bằng sáng	RandomBrightnessContrast	brightness=0.2, contrast=0.2	0.75
Biến đổi màu	HueSaturationValue	hue=10, sat=20, val=10	0.5
Cân bằng Histogram	CLAHE	clip_limit=4.0	0.5
Bộ lọc làm mờ	OneOf[MotionBlur, MedianBlur, GaussianBlur, GaussNoise]	blur_limit=5	0.3
Che lấp cấu trúc	CoarseDropout	max_holes=1, kích thước max 12% ảnh	0.4
Chuẩn hóa	Normalize	ImageNet mean/std	1.0

Bảng 3.5: Danh sách các phép tăng cường dữ liệu ảnh (Training Pipeline)

3.6.3 Mạng trích xuất đặc trưng (Backbone Encoder)

Kiến trúc tiêu chuẩn cho nhánh ảnh là mạng **EfficientNet-B0** (hoặc cấu hình tùy chọn **EVA02 Small**). Mạng nơ-ron được khởi tạo thông qua thư viện `timm` với cờ `num_classes=0` nhằm gỡ bỏ toàn bộ lớp phân loại cuối cùng, biến mạng thành cỗ máy trích xuất đặc trưng thuần

túy. Chiều không gian biểu diễn đặc trưng là $d_{img} = 1280$ đối với EfficientNet-B0 và $d_{img} = 384$ đối với EVA02. Sau khi qua backbone, một lớp chiếu không gian gồm `Linear` → `GELU` → `Dropout` sẽ ánh xạ vectơ xuống chiều kích không gian giao thoa d_{fusion}. Tùy thuộc vào chiến lược dung hợp: Nếu dùng Cross-Attention, đặc trưng ảnh được giữ dưới dạng chuỗi các patch $h_{img} \in \mathbb{R}^{L \times d_{fusion}}$. Nếu dùng GMU hoặc Concat, vector ảnh được gộp (global average pooling) thành một vector đơn $\bar{h}_{img} \in \mathbb{R}^{d_{fusion}}$.

3.7 Patient Representation Learning (TabM)

Metadata là dạng dữ liệu bảng hỗn hợp, do đó cấu trúc **TabM** (Gorishniy et al., ICLR 2025) được tích hợp nhằm mang lại khả năng học sâu dữ liệu bảng tối ưu [9].

3.7.1 Piecewise Linear Embedding (PLE)

Thay vì biểu diễn biến số học bằng các giá trị vô hướng, kỹ thuật PLE chia phân phối mỗi biến số thành `n_bins = 48` vùng thùng. Quá trình nội suy tuyến tính sẽ ánh xạ các biến vô hướng này thành một vector nhúng chiều $d_{embedding} = 32$. Các mốc phân chia (bin edges) được lấy từ QuantileTransformer trong bước tiền xử lý. Tổng số chiều đầu vào của mạng TabM lúc này là $n_{num} \times 32 + n_{cat}$.

3.7.2 TabM Architecture

TabM giải quyết nguy cơ quá khớp thường thấy của mạng MLP trên dữ liệu y học thông qua **Parameter-Efficient Ensembling**. Cấu trúc này mô phỏng một tập hợp (ensemble) gồm $K = 32$ chuyên gia bên trong một mạng nơ-ron duy nhất, nhờ vào cơ chế nhân chéo ma trận hạng thấp tương tự BatchEnsemble. Cụ thể, mạng TabM sử dụng xương sống MLP gồm `n_blocks=2`, kích thước `d_block=256`, và tỷ lệ `dropout=0.3`. Đầu ra của khối là tensor biểu diễn $h_{tab} \in \mathbb{R}^{B \times K \times 256}$. Khi tham số `keep_tabm_ensemble=True`, hệ thống bảo tồn nguyên vẹn chiều kích K này, tiến thẳng tới module Fusion đa phương thức, cung cấp đa dạng góc nhìn lâm sàng để đối chiếu với hình ảnh.

3.8 Cross-modal Fusion — Cross-Attention

Việc kết hợp (Fusion) hai nhánh dữ liệu là trái tim thuật toán của hệ thống. Hệ thống sử dụng cơ chế Bidirectional Cross-Attention để điều chỉnh tương tác.

Siêu tham số	Giá trị	Mô tả
`n_bins`	48	Số lượng thùng chia của mỗi biến số trong PLE
`d_embedding`	32	Số chiều không gian của vector nhúng PLE
`tabm_k`	32	Số lượng thành viên chuyên gia (ensemble members)
`tabm_arch_type`	"tabm"	Loại kiến trúc nội bộ (MLP hoặc ResNet)
`tabm_n_blocks`	2	Số lượng khối xử lý (layers)
`tabm_d_block`	256	Chiều kích không gian ẩn (d_{tab})
`tab_dropout`	0.30	Tỷ lệ Dropout dùng để điều chuẩn
`keep_tabm_ensemble`	True	Giữ lại chiều K cho module dung hợp đa phương thức

Bảng 3.6: Các siêu tham số của mạng TabM

3.8.1 Kỹ thuật K-Expansion

Vì nhánh TabM tạo ra K góc nhìn chuyên gia khác nhau $h'_{tab} \in \mathbb{R}^{B\times K\times d_{tab}}$, nhưng nhánh ảnh chỉ tạo ra một bộ đặc trưng duy nhất, hệ thống áp dụng kỹ thuật nhân bản (Expansion). Sau khi được ánh xạ qua không gian d_{fusion}, vector ảnh được khuếch đại (unsqueeze và expand) thành tensor không gian $\mathbb{R}^{B\times K\times L\times d_{fusion}}$. Về mặt ý nghĩa, điều này tương đương với việc sao chép tổn thương trên ảnh cho K chuyên gia lâm sàng (các thành viên TabM) cùng quan sát.

3.8.2 Cross-Attention Fusion Architecture

Kiến trúc tính toán sự tương tác dựa trên cơ chế Attention hai chiều (Bidirectional). Đầu tiên, dữ liệu h'_{img} và h'_{tab} được đưa qua các lớp `LayerNorm`. Sau đó, h'_{tab} đi qua một lớp `Linear` tuyến tính tạo thành nút thắt.

Trong **Chiều Yếu (Image attends to Tabular)**, các token ảnh đóng vai trò là Truy vấn (Q), còn thông tin bệnh lý là Khóa và Giá trị (K, V). Vector ảnh nhận được sự bổ sung tri thức, sau đó được cộng dồn (Residual Connection) qua lớp `Dropout`.

Ngược lại, trong **Chiều Mạnh (Tabular attends to Image)**, thông tin lâm sàng là Q, còn toàn bộ các patch của ảnh đóng vai trò K và V. Tính toán sự tập trung đa đầu (Multihead Attention) được thực hiện như sau:

$$\text{Attention}(Q_{tab}, K_{img}, V_{img}) = \text{Softmax}\left(\frac{Q_{tab}K_{img}^T}{\sqrt{d_k}}\right)V_{img} \tag{3.4}$$

Cuối cùng, biểu diễn ảnh được gộp trung bình không gian (Mean Pooling), nối ghép với vector bệnh lý tạo thành ma trận $fused \in \mathbb{R}^{B\times K\times 2d_{fusion}}$ (mỗi trong số K chuyên gia nhận một vector dung hợp riêng), và chiếu qua lớp tuyến tính `fc_out`.

Siêu tham số	Giá trị tiêu chuẩn
`fusion_hidden_dim` (d_{fusion})	256
`cross_attention_heads`	4
`fusion_dropout`	0.20

Bảng 3.7: Các siêu tham số của mô-đun Cross-Attention Fusion

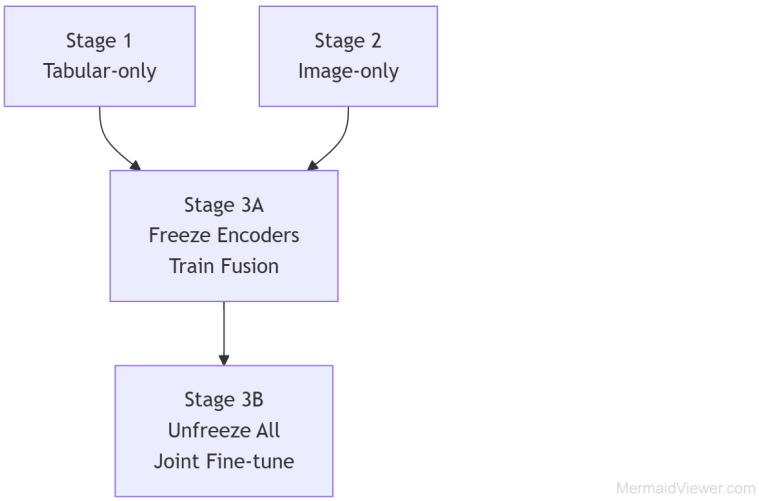
3.8.3 Gated Multimodal Unit (GMU) và Concatenation

Ngoài Cross-Attention, hệ thống hỗ trợ **GMU** [27]. GMU học một cánh cổng đa tầng (Gate) trả về trọng số nội suy $z = \sigma(\text{Gate}([h_{img}, h_{tab}]))$, sau đó dung hợp bằng cách hòa trộn $h_{fusion} = z \cdot W_{img}(h_{img}) + (1-z) \cdot W_{tab}(h_{tab})$. Ngược lại, phương pháp **Concatenation** thực hiện ghép nối thẳng vector $h_{fusion} = [h_{img}, h_{tab}]$, đóng vai trò làm điểm đối sánh cơ sở (baseline) trong thiết kế đánh giá.

3.9 Chiến lược huấn luyện & Tối ưu hóa siêu tham số

3.9.1 Huấn luyện phân tầng (Staged Pretraining)

Huấn luyện song song cả hai mạng lớn có thể dẫn đến việc mô hình ưu tiên khai thác nhánh dễ học (Tabular) và bỏ qua tiềm năng của nhánh ảnh. Để xử lý hiện tượng "Sụp đổ phương thức"[28], quy trình huấn luyện được chia làm 4 giai đoạn độc lập.



Hình 3.3: Quy trình huấn luyện phân tầng 4 bước.

Cụ thể, ở **Stage 1 & 2**, hệ thống hội tụ từng nhánh riêng lẻ (`tabular_only` và `image_only`), giúp mô hình học cách giải quyết bài toán thuần túy dựa trên một phương thức.

Tiếp theo, ở **Stage 3A**, hệ thống đóng băng hoàn toàn (freeze) trọng số của cả hai mạng trích xuất đặc trưng và chỉ cho phép tối ưu hóa module Fusion, nhằm bảo vệ các trọng số phân tầng tốt khỏi gradient lớn ban đầu. Cuối cùng, ở **Stage 3B (Joint Fine-tune)**, hệ thống mở khóa (unfreeze) mọi trọng số, huấn luyện toàn diện End-to-end với tốc độ học cực nhỏ nhằm tinh chỉnh tương tác mà không gây "lãng quên cục diện".

Giai đoạn	Trạng thái	Đóng băng trọng số	Tốc độ học	Epochs	Aux loss (img/tab)
Stage 1	tabular_only	Image backbone	config.lr	100	0.0 / 1.0
Stage 2	image_only	Tabular encoder	config.lr	30	1.0 / 0.0
Stage 3A	both	Cả 2 encoder	stage3a_lr	5	0.0 / 0.0
Stage 3B	both	Không đóng băng	stage3b_lr	10	0.5 / 0.2

Bảng 3.8: Thiết lập cấu hình cho các giai đoạn huấn luyện (Staged Pretraining)

3.9.2 Biện pháp chống sụp đổ phương thức (Anti-Modality-Collapse)

Hệ thống sử dụng đa tầng cơ chế bảo vệ song song:

1. **Huấn luyện phân tầng:** như phân tích ở 3.9.1.
2. **Hàm mất mát đa nhiệm (Auxiliary Unimodal Losses):** Ép buộc mỗi nhánh tự duy trì khả năng tiên đoán độc lập:

$$\mathscr{L}_{total} = \mathscr{L}_{fusion} + 0.5 \cdot \mathscr{L}_{image} + 0.2 \cdot \mathscr{L}_{tabular} \tag{3.5}$$

3. **Dynamic Undersampling:** Thay đổi không gian mẫu âm (negative) liên tục mỗi epoch qua sampler.

3.9.3 Lấy mẫu và Hàm mất mát

Sử dụng **EpochRandomUndersampler** để khắc phục phân phối nhãn ung thư cực hiếm. Quá trình lấy mẫu giữ nguyên toàn bộ 393 mẫu ác tính. Tại mỗi epoch, thuật toán bốc ngẫu nhiên số lượng mẫu lành tính bằng $negative_ratio \times n_{pos}$ (mặc định gấp 5 lần số lượng mẫu ác, xem Bảng 3.9). Không gian mẫu ngẫu nhiên được đổi mới sau từng epoch bằng tham số sinh ngẫu nhiên `base_seed + epoch`.

Về hàm mất mát, hệ thống sử dụng Binary Cross Entropy (`BCEWithLogitsLoss`). Trọng số dương `pos_weight` được sử dụng dưới dạng căn bậc hai: $w_{pos} = \sqrt{negative_ratio}$,

nhằm tránh để gradient của nhóm hiếm thống trị mạng. Kỹ thuật **Label Smoothing** ($y_{smooth} = y \cdot (1 - \epsilon) + 0.5 \cdot \epsilon$, với $\epsilon = 0.01$) cũng được tích hợp giúp hạ nhiệt tự tin quá mức của mô hình.

3.9.4 Tối ưu hóa

Sử dụng trình tối ưu hóa `AdamW` cùng bộ lập lịch tốc độ học hai pha `SequentialLR`: pha làm nóng tuyến tính (`LinearLR`) và pha nguội dần (`CosineAnnealingLR`). Để tối ưu VRAM và tốc độ, hệ thống tính toán với độ chính xác hỗn hợp `torch.amp.autocast`. Tránh bùng nổ gradient bằng kỹ thuật Gradient Clipping ở ngưỡng tối đa 1.0. Khởi tạo trọng số (Weight Initialization) sử dụng phân phối Xavier Uniform, riêng hệ số định kiến (Bias) lớp cuối được gán bằng $b = -\ln(\max(1, negative_ratio))$ để thích nghi ngay lập tức với phân phối mẫu âm. Kỹ thuật Early Stopping với `patience=10` trên pAUC đảm bảo chống quá khớp.

Tham số	**Giá trị**	**Tham số**	**Giá trị**
`lr` / `weight_decay`	1e-3 / 1e-4	`min_lr`	1e-6
`warmup_epochs`	2	`label_smoothing`	0.01
`gradient_clipping_norm`	1.0	`pos_weight`	$\sqrt{negative_ratio}$
`aux_loss_image_weight`	0.5	`negative_ratio`	5
`aux_loss_tab_weight`	0.2	`modality_dropout_prob`	0.15

Bảng 3.9: Tổng hợp các siêu tham số huấn luyện cốt lõi

3.9.5 Tối ưu hóa siêu tham số (Hyperparameter Tuning)

Đồ án không chạy tìm kiếm siêu tham số hỗn hợp (joint optimization) dễ gây bùng nổ tổ hợp, mà chia tách thành thiết kế tối ưu hóa 3 pha độc lập (Tabular → Image → Fusion). Phương pháp kiểm soát nhánh `MedianPruner` của thư viện Optuna giúp hệ thống sớm tự động ngắt các thử nghiệm (trials) có biểu hiện hội tụ kém [29]

3.10 Tóm tắt chương

Chương 3 đã trình bày quy trình hiện thực hóa chi tiết một kiến trúc học sâu đa phương thức toàn diện cho bài toán phát hiện ung thư da hắc tố. Những đóng góp kỹ thuật cốt lõi được xây dựng gồm: module tiền xử lý trích xuất 651 đặc trưng mang hàm lượng tri thức cao (Knowledge-guided Feature Engineering, Bảng 3.3); mạng TabM sở hữu Piecewise Linear Embedding tối ưu dữ liệu bảng; cùng với cơ chế dung hợp Bidirectional Cross-Attention cho phép đối chiếu bệnh lý trên hình ảnh lâm sàng.

Bên cạnh đó, chương thiết lập một chiến lược huấn luyện nghiêm ngặt 4 giai đoạn kết hợp cùng 4 cơ chế chống sụp đổ phương thức (Modality Dropout, Auxiliary Loss, Dynamic Undersampling) giúp triệt tiêu hiện tượng lãng quên tri thức của mạng phức tạp. Toàn bộ hiệu suất của hệ thống, đi kèm với 10 phép kiểm định tiêu hao (Ablation Study), sẽ được hệ thống hóa định lượng bằng thang đo khắt khe pAUC $TPR \geq 0.80$ trong Chương 4.

Chương 4

KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1 Kết quả huấn luyện mô hình đề xuất

4.1.1 Môi trường thực nghiệm

Thành phần	Cấu hình
Nền tảng	Kaggle Notebook
Hệ điều hành	Ubuntu Linux
GPU	NVIDIA Tesla T4 (16 GB)
GPU Memory	16 GB
CPU	4 vCPU Intel Xeon
RAM	29 GB
Python	3.11
PyTorch	2.6.0
CUDA	12.4

Bảng 4.1: Cấu hình môi trường thực nghiệm trên Kaggle Notebook

4.1.2 Thiết lập dữ liệu

Sử dụng StratifiedGroupKFold với nhóm theo patient_id để tránh data leakage:

Tập	Số mẫu	Số bệnh nhân
Train (Fold 0-3)	320.849	834
Validation (Fold 4)	80.210	208
Test (Official)	*Ẩn*	*Ẩn*

Bảng 4.2: Chi tiết số lượng mẫu và bệnh nhân sau khi chia 5 fold
(Test set được Kaggle ẩn cho quá trình chấm điểm).

Dữ liệu được tách theo nhóm bệnh nhân khoảng 80% số mẫu được dùng để huấn luyện và 20% được dùng để xác thực. Việc nhóm theo `patient_id` bảo đảm các tổn thương của cùng một bệnh nhân không xuất hiện đồng thời ở tập huấn luyện và tập xác thực, nhờ đó giảm

nguy cơ rò rỉ dữ liệu và giúp kết quả đánh giá phản ánh đúng khả năng tổng quát hóa.

4.1.3 Cấu hình huấn luyện

4.1.3.1 Giai đoạn 1: Huấn luyện TabM

Sử dụng bộ đặc trưng bảng (Tabular features) đã qua xử lý. Cấu trúc mạng TabM và bộ nhúng Piecewise Linear Embeddings (PLE) được thiết lập với các siêu tham số như sau:

Tham số	**Giá trị**
K (Số lượng sub-models)	32
Số lượng Block (n_blocks)	2
Kích thước Block (d_block)	256
Kích thước lớp ẩn (tab_hidden_dim)	256
Số lượng Bin cho PLE (n_bins)	48
Kích thước nhúng PLE (d_embedding)	32
Dropout	0.3

Bảng 4.3: Siêu tham số cấu trúc mạng TabM và PLE

Nhánh bảng sẽ được huấn luyện với cấu hình $K = 32$ mô hình con để khai thác ưu điểm ensemble của TabM, trong khi hai block ẩn kích thước 256 giữ cho kiến trúc đủ năng lực biểu diễn nhưng không quá lớn so với quy mô dữ liệu. PLE với 48 khoảng và kích thước nhúng 32 giúp mã hóa các biến số liên tục theo cách linh hoạt hơn so với việc đưa trực tiếp giá trị thô vào mạng.

Quá trình huấn luyện mạng TabM sử dụng các siêu tham số tối ưu (Optimizer & Scheduler) sau:

Tham số	**Giá trị**
Optimizer	AdamW
Learning rate	1×10^{-3}
Batch size	512
Epochs	100
Weight decay	1.32×10^{-4}
Early stopping patience	15

Bảng 4.4: Siêu tham số huấn luyện mô hình TabM (Stage 1)

Nhánh dữ liệu bảng được huấn luyện với batch size 512 và tối đa 100 epoch. Cơ chế early stopping với patience 15 được sử dụng để hạn chế quá khớp; đồng thời AdamW và weight decay giúp kiểm soát độ lớn trọng số trong quá trình tối ưu.

4.1.3.2 Giai đoạn 2: Huấn luyện EfficientNet

Huấn luyện nhánh ảnh độc lập trên backbone EfficientNet-B0:

Tham số	Giá trị
Optimizer	AdamW
Learning rate	5×10^{-4}
Batch size	64
Epochs	30
Weight decay	1×10^{-4}
Early stopping patience	5

Bảng 4.5: Siêu tham số huấn luyện nhánh ảnh EfficientNet (Stage 2)

Nhánh ảnh sử dụng batch size nhỏ hơn nhánh dữ liệu bảng do chi phí bộ nhớ của tensor ảnh. Số epoch tối đa và patience được đặt thấp hơn để tránh việc backbone nhanh chóng ghi nhớ các mẫu huấn luyện trong bối cảnh dữ liệu ảnh mất cân bằng.

4.1.3.3 Giai đoạn 3: Huấn luyện Fusion Layer

Đóng băng (Freeze) các nhánh trích xuất đặc trưng ảnh và bảng. Chỉ huấn luyện kết nối Cross- Attention (Fusion Head):

Tham số	Giá trị
Learning rate	1×10^{-4}
Batch size	64
Epochs	5

Bảng 4.6: Siêu tham số khởi tạo nhánh đa phương thức (Stage 3A)

Hai nhánh đơn phương thức được đóng băng và chỉ tầng kết hợp được cập nhật trong 5 epoch. Thiết lập này giúp tầng fusion thích nghi ban đầu với hai không gian biểu diễn đã ổn định mà không làm thay đổi đột ngột trọng số của các backbone.

4.1.3.4 Giai đoạn 3B: Fine-tuning toàn bộ

Mở khóa (Unfreeze) backbone ảnh, tiến hành tinh chỉnh (fine-tune) toàn bộ mạng với chiến lược học phân tầng (differential learning rate) để bảo vệ trọng số của backbone trong khi các head tiếp tục hội tụ:

Tham số	Giá trị
Learning rate (Image Backbone)	1×10^{-5}
Learning rate (TabM & Fusion)	5×10^{-5}
Batch size	64
Epochs	10

Bảng 4.7: Siêu tham số fine-tuning toàn bộ mạng đa phương thức (Stage 3B)

Áp dụng tốc độ học phân tầng: nhánh ảnh được cập nhật với learning rate 1×10^{-5}, nhỏ hơn năm lần so với TabM và tầng fusion. Cách thiết lập này hạn chế phá vỡ các đặc trưng thị giác đã học, trong khi vẫn cho phép toàn bộ hệ thống cùng tinh chỉnh theo mục tiêu pAUC.

4.1.3.5 Chiến lược chung cho tất cả giai đoạn

- **Loss function**: Binary Cross Entropy (`BCEWithLogitsLoss`) đi kèm trọng số dương `pos_weight` (được tính bằng $\sqrt{negative_ratio}$) nhằm cân bằng class imbalance mà không làm gradient của nhóm thiểu số áp đảo mạng.
- **Scheduler**: Lập lịch tốc độ học hai pha thông qua `SequentialLR`. Bao gồm giai đoạn làm nóng tuyến tính (`LinearLR Warmup`) để ổn định trọng số, nối tiếp bởi giai đoạn hạ nhiệt hình sin (`CosineAnnealingLR`) để tối ưu hội tụ.
- **Mixed Precision**: Tích hợp `torch.amp.autocast` để giảm lượng VRAM tiêu thụ và tăng tốc độ huấn luyện mà không làm suy giảm độ chính xác.
- **Data Augmentation**: Sử dụng thư viện Albumentations cho nhánh ảnh (với các phép biến đổi: Horizontal/Vertical Flip, ShiftScaleRotate, và RandomBrightnessContrast).
- **Reproducibility**: Ghim tĩnh hạt giống ngẫu nhiên (`random_state=42`) và thiết lập biến môi trường `CUBLAS_WORKSPACE_CONFIG=":4096:8"` nhằm đảm bảo tính xác định (deterministic) cho các phép toán CUDA.

4.1.4 Quy trình đánh giá trên tập kiểm tra

Mỗi phiên bản mô hình được huấn luyện trên tập train (theo StratifiedGroupKFold), sau đó dự đoán trên tập test chính thức của cuộc thi và nộp lên hệ thống Kaggle để nhận điểm pAUC. Nếu sử dụng ensemble từ nhiều fold, dự đoán cuối cùng là giá trị trung bình cộng từ các fold.

4.1.5 Tiến trình phát triển mô hình và Ablation Study

Để định lượng chính xác đóng góp của từng thành phần kỹ thuật, mô hình được phát triển và đánh giá qua nhiều phiên bản (ablation configurations) bám sát bốn bước huấn luyện: Stage 1, Stage 2, Stage 3A và Stage 3B:

Tên Phiên Bản	Cấu hình / Thành phần	Mục đích đánh giá
A. Đánh giá nhánh Dữ liệu bảng (Tabular Branch)		
TabM-Base	TabM + 39 biến gốc	Baseline hiệu suất của mạng TabM khi không có tri thức chuyên gia.
TabM-KFE	TabM + Bộ đặc trưng kỹ nghệ (KFE)	Chứng minh giá trị của Feature Engineering (ABCDE,Contextual, Ugly-duckling).
B. Đánh giá nhánh Hình ảnh (Image Branch)		
Image-EffNet	EfficientNet-B0 độc lập	Baseline trích xuất đặc trưng hình ảnh.
C. Đánh giá cơ chế kết hợp (Fusion Mechanisms)		
Fusion-Concat	Image + TabM + Concat	So sánh: Phép nối tensor cơ bản.
Fusion-GMU	Image + TabM + GMU Layer	So sánh: Cơ chế cổng kiểm soát (Gated Multimodal Unit).
Fusion-CrossAttn	Image + TabM + Cross-Attention	Đánh giá hiệu quả của cơ chế chú ý chéo (Đề xuất chính).
D. Đánh giá chiến lược tối ưu trên mô hình Cross-Attention		
CrossAttn-End2End	Huấn luyện Cross-Attention từ đầu (không qua Stage 1 & 2)	Chứng minh sự cần thiết của chiến lược Staged Pretraining.
Proposed Model	**Concat + Staged Pretrain + KFE**	**Phiên bản hoàn chỉnh cuối cùng được lựa chọn theo kết quả thực nghiệm.**

Bảng 4.8: Các phiên bản thử nghiệm (Ablation Study) trong tiến trình phát triển hệ thống.

Các thí nghiệm được tổ chức theo ba nhóm với mục tiêu: đánh giá chất lượng từng nhánh, so sánh các cơ chế fusion và kiểm chứng chiến lược huấn luyện phân tầng. Cách thiết kế này giúp mỗi chênh lệch pAUC ở phần sau có thể được quy về một thay đổi kỹ thuật cụ thể, thay vì so sánh các cấu hình khác nhau đồng thời ở nhiều thành phần.

4.2 Đánh giá mô hình

Dựa trên các phiên bản thử nghiệm đã thiết kế tại Bảng 4.8, kết quả pAUC được đo trên tập kiểm tra ẩn (Private Leaderboard) của cuộc thi ISIC 2024, đại diện cho hiệu suất tổng quát hóa thực tế của mô hình trên dữ liệu chưa từng thấy.

4.2.1 Kết quả nhánh dữ liệu bảng (Tabular Branch)

Phiên bản	pAUC
TabM-Base	0.13920
TabM-KFE	0.15853

Bảng 4.9: So sánh pAUC giữa TabM sử dụng biến gốc và TabM kết hợp bộ đặc trưng kỹ nghệ (KFE).

KFE làm pAUC của TabM tăng từ 0.13920 lên 0.15853, tương ứng mức tăng tuyệt đối 0.01933 và khoảng 13.9% theo tỷ lệ tương đối. Kết quả này cho thấy các đặc trưng được xây dựng từ tri thức lâm sàng bổ sung lượng thông tin đáng kể so với việc chỉ sử dụng metadata gốc.

4.2.2 Kết quả nhánh hình ảnh (Image Branch)

Phiên bản	pAUC
Image-EffNet	0.13873

Bảng 4.10: Hiệu suất pAUC của nhánh hình ảnh độc lập (EfficientNet-B0).

EfficientNet-B0 độc lập đạt pAUC 0.13873. Mức điểm này thấp hơn TabM-KFE 0.01980, cho thấy trong thiết lập hiện tại, metadata đã được tăng cường bằng tri thức miền cung cấp tín hiệu phân biệt mạnh hơn ảnh tổn thương đơn lẻ.

4.2.3 Kết quả tối ưu hóa Tầng kết hợp (Fusion) và Chiến lược huấn luyện

Sau khi các nhánh đơn phương thức (TabM và EfficientNet) đã đạt hiệu suất tối ưu ở Giai đoạn 1 và 2, hệ thống tiến hành thử nghiệm các cơ chế kết hợp và chiến lược huấn luyện để tìm ra cấu hình tốt nhất. Tất cả đều sử dụng chung bộ siêu tham số và hàm mất mát phụ trợ:

Phiên bản	Chiến lược Huấn luyện	pAUC (Test)
A. Cố định chiến lược Staged Pretraining (Qua 3 Stage)		
Fusion-Concat (Proposed)	**Staged Pretraining**	**0.16523**
Fusion-GMU	Staged Pretraining	0.16190
Fusion-CrossAttn	Staged Pretraining	0.16365
B. Cố định kiến trúc Cross-Attention		
CrossAttn-End2End	Huấn luyện từ đầu (Không qua Stage 1 & 2)	0.16004

Bảng 4.11: So sánh pAUC trên tập kiểm tra chính thức Kaggle giữa các cơ chế kết hợp đa phương thức.

Kết quả ở Bảng 4.11 cho thấy Concatenation đạt pAUC cao nhất (0.16523), cao hơn Cross-Attention 0.00158 và cao hơn GMU 0.00333. Khi giữ nguyên kiến trúc Cross-Attention, chiến lược staged pretraining cải thiện 0.00361 so với huấn luyện end-to-end từ đầu (0.16365 so với 0.16004), qua đó xác nhận lợi ích của việc huấn luyện ổn định từng nhánh trước khi tối ưu toàn hệ thống.

4.3 So sánh với các nghiên cứu liên quan

Để đặt kết quả của mô hình đề xuất trong bối cảnh chung, Bảng 4.12 trình bày các mức tham chiếu được công bố chính thức trong báo cáo tổng kết cuộc thi ISIC 2024.

Phương pháp	**pAUC (>80% TPR)**
Best across all ISIC'24 submissions	0.173
Marchetti et al.	0.032
ISIC'24 winner — ablation	
Tiles only (Image only)	0.142
Meta-basic + WB360 + Patient context (Metadata + KFE)	0.164
Meta-basic + WB360 + Tiles + Patient context (Full)	0.173

Bảng 4.12: Kết quả pAUC (>80% TPR, Private set) tham chiếu từ báo cáo chính thức ISIC 2024.

Bảng 4.12 cho thấy mô hình cuối cùng của đồ án đạt 0.16523, còn cách mức 0.173 của kết quả tốt nhất 0.00777. Đáng chú ý, kết quả này gần với cấu hình metadata kết hợp KFE của đội thắng (0.164), củng cố nhận định rằng ngữ cảnh bệnh nhân và kỹ nghệ đặc trưng đóng vai trò rất quan trọng; phần chênh lệch còn lại có thể đến từ backbone ảnh, ensemble và quy mô tối ưu hóa lớn hơn.

4.4 Phân tích

4.4.1 Phân tích kết quả nội bộ

4.4.1.1 Đóng góp của Feature Engineering (KFE)

Kết quả tại Bảng 4.9 cho thấy việc bổ sung bộ đặc trưng kỹ nghệ (KFE) giúp cải thiện đáng kể hiệu suất của nhánh dữ liệu bảng, từ pAUC = 0.13920 (TabM-Base, chỉ dùng biến gốc) lên pAUC = 0.15853 (TabM-KFE), tương ứng mức tăng tuyệt đối +0.01933 (khoảng +13.9% tương đối). Đây là mức cải thiện lớn nhất được ghi nhận trong toàn bộ các thí nghiệm ablation của đồ án, khẳng định rằng tri thức lâm sàng được mã hóa thông qua các đặc trưng ABCD, Ugly

Duckling, và Patient Normalization mang lại giá trị thông tin quan trọng mà mô hình học sâu không thể tự học được đầy đủ chỉ từ 39 biến metadata thô.

Hiệu suất của TabM-KFE (0.15853) khi đứng độc lập đã gần tiệm cận với hiệu suất của các cấu hình fusion đầy đủ ở giai đoạn sau (0.161–0.165), cho thấy nhánh metadata sau khi được tăng cường bằng KFE đóng vai trò đóng góp chính vào hiệu suất tổng thể của hệ thống.

4.4.1.2 So sánh nhánh đơn phương thức

So sánh giữa hai nhánh độc lập cho thấy TabM-KFE (0.15853) vượt trội hơn Image-EffNet (0.13873), với chênh lệch +0.01980. Điều này gợi ý rằng, trong bài toán này, thông tin từ metadata lâm sàng (đặc biệt sau khi được tăng cường bằng KFE) mang tính phân biệt cao hơn so với đặc trưng thị giác trích xuất từ ảnh lesion-crop đơn lẻ. Nguyên nhân có thể đến từ việc EfficientNet-B0 huấn luyện từ đầu trên tập dữ liệu có kích thước hạn chế, trong khi các đặc trưng KFE đã được thiết kế dựa trên tri thức domain-specific, giúp giảm phụ thuộc vào lượng dữ liệu lớn để đạt hiệu suất tốt.

4.4.1.3 Vì sao Concatenation vượt trội hơn Cross-Attention và GMU

Bảng 4.11 (nhóm A) cho thấy, khi cố định chiến lược Staged Pretraining, thứ tự hiệu suất giữa các cơ chế kết hợp là:

$$\text{Concat } (0.16523) > \text{Cross-Attention } (0.16365) > \text{GMU } (0.16190)$$

Kết quả này đi ngược lại giả thuyết ban đầu của đồ án, vốn kỳ vọng Cross-Attention — với khả năng học tương tác động giữa hai phương thức — sẽ vượt trội hơn phép nối tensor đơn giản. Một số nguyên nhân khả dĩ:

Đầu tiên là **đặc trưng KFE đã mã hóa sẵn phần lớn tương tác quan trọng**. Vì các đặc trưng như Ugly Duckling và Patient Normalization vốn được thiết kế để nắm bắt mối quan hệ giữa tổn thương và bối cảnh bệnh nhân, cơ chế Cross-Attention có thể không còn nhiều thông tin bổ sung để khai thác, trong khi vẫn phải đánh đổi bằng số lượng tham số lớn hơn.

Tiếp theo là **nguy cơ overfitting trên tập dữ liệu có quy mô hạn chế**. Cross-Attention và GMU đều có độ phức tạp tham số cao hơn Concat, khiến chúng dễ học các mối tương quan đặc thù của tập huấn luyện nhưng kém ổn định hơn khi tổng quát hóa.

Cuối cùng, **GMU có xu hướng thiên lệch (bias) về một nhánh**. Cơ chế cổng của GMU (0.16190) cho kết quả thấp nhất trong ba phương án, có thể do quá trình huấn luyện phân tầng khiến cổng gating hội tụ về trạng thái ưu tiên một nhánh duy nhất, làm giảm hiệu quả kết hợp

thông tin.

4.4.1.4 Vai trò của chiến lược Staged Pretraining

Bảng 4.11 (nhóm B) cho thấy khi huấn luyện Cross-Attention theo kiểu end-to-end ngay từ đầu (không qua Stage 1 và 2), pAUC chỉ đạt 0.16004 — thấp hơn 0.00361 so với việc huấn luyện Cross-Attention theo chiến lược Staged Pretraining (0.16365). Kết quả này khẳng định giá trị của việc huấn luyện phân tầng: việc để từng nhánh đơn phương thức hội tụ độc lập trước khi huấn luyện tầng kết hợp giúp ổn định quá trình tối ưu hóa và tránh hiện tượng một nhánh chi phối nhánh còn lại ngay từ giai đoạn đầu (modality collapse).

4.4.1.5 Lựa chọn cấu hình cuối cùng

Dựa trên các kết quả trên, cấu hình **Concatenation + Staged Pretraining + KFE** được lựa chọn làm mô hình đề xuất cuối cùng của đồ án (pAUC = 0.16523), thay vì cấu hình Cross-Attention ban đầu được kỳ vọng. Quyết định này dựa trên bằng chứng thực nghiệm nhất quán.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đồ án tập trung nghiên cứu bài toán phát hiện ung thư da trên bộ dữ liệu ISIC 2024, trong bối cảnh các hệ thống hỗ trợ chẩn đoán ngày càng có xu hướng khai thác đồng thời dữ liệu hình ảnh và dữ liệu lâm sàng. Khác với các bộ dữ liệu truyền thống chỉ bao gồm ảnh của từng tổn thương riêng lẻ, ISIC 2024 cung cấp thêm metadata và thông tin ở mức bệnh nhân thu thập từ hệ thống 3D Total Body Photography, mở ra khả năng xây dựng các mô hình học đa phương thức.

Trên cơ sở đó, đồ án đề xuất một kiến trúc học đa phương thức kết hợp nhánh dữ liệu bảng (TabM, tăng cường bằng bộ đặc trưng kỹ nghệ dựa trên tri thức da liễu — KFE) và nhánh hình ảnh (EfficientNet-B0), được huấn luyện theo chiến lược phân tầng (Staged Pretraining) qua 4 giai đoạn nhằm ổn định quá trình học biểu diễn của từng nhánh trước khi kết hợp.

Thông qua quá trình thực nghiệm và ablation study có hệ thống (10 cấu hình), đồ án rút ra một số kết luận định lượng quan trọng:

Đặc trưng kỹ nghệ dựa trên tri thức lâm sàng (KFE) là thành phần đóng góp lớn nhất vào hiệu suất của hệ thống. Việc bổ sung KFE giúp cải thiện pAUC của nhánh dữ liệu bảng từ 0.13920 lên 0.15853 (tăng khoảng 13.9% tương đối), cho thấy tri thức miền (ABCD, Ugly Duckling, Patient Normalization) mang lại giá trị thông tin mà mô hình học sâu khó tự học được nếu chỉ dựa vào metadata thô.

Chiến lược huấn luyện phân tầng (Staged Pretraining) là yếu tố cần thiết để đạt hiệu suất tối ưu. So với việc huấn luyện end-to-end ngay từ đầu (pAUC = 0.16004), việc để từng nhánh hội tụ độc lập trước khi huấn luyện tầng kết hợp giúp cải thiện pAUC lên 0.16365–0.16523, đồng thời hạn chế hiện tượng một phương thức lấn át phương thức còn lại (modality collapse).

Kết quả pAUC tốt nhất đạt được (0.16523) vẫn thấp hơn giải pháp đạt giải nhất cuộc thi ISIC 2024 (0.173). Tuy nhiên, kết quả đạt được vượt xa baseline học thuật tham chiếu (Marchetti et al., pAUC = 0.032). Điều này cho thấy hướng tiếp cận kết hợp Feature Engineering dựa trên tri thức lâm sàng và chiến lược Staged Pretraining là hợp lý và có tiềm năng, dù kiến trúc học sâu

đơn (single deep-learning model) của đồ án vẫn còn khoảng cách so với các giải pháp ensemble phức tạp, đặc biệt là phần dữ liệu bảng. Trong lĩnh vực học máy cho dữ liệu dạng bảng (tabular data) nói chung, GBDT thường có ưu thế hơn các kiến trúc học sâu trên tập dữ liệu có quy mô vừa và nhỏ, do đặc tính inductive bias phù hợp với dữ liệu có cấu trúc rời rạc và ít mẫu [8]. Đây có thể là một trong những nguyên nhân góp phần vào khoảng cách hiệu suất giữa mô hình đề xuất và giải pháp đạt giải nhất.

Nhìn chung, đồ án không chỉ xây dựng một mô hình học đa phương thức có hiệu suất cạnh tranh cho bài toán phát hiện ung thư da, mà quan trọng hơn, thông qua ablation study có hệ thống, đồ án cung cấp bằng chứng định lượng rõ ràng về vai trò của từng thành phần thiết kế — từ đó đưa ra khuyến nghị thực nghiệm có giá trị tham khảo cho các nghiên cứu tiếp theo trong lĩnh vực học đa phương thức ứng dụng vào phân tích ảnh y tế.

5.2 Hạn chế

Bên cạnh những kết quả đã đạt được, đồ án vẫn còn một số hạn chế cần được xem xét trong quá trình phát triển và hoàn thiện mô hình.

Thứ nhất, quá trình xây dựng và đánh giá mô hình chỉ được thực hiện trên bộ dữ liệu ISIC 2024 — vốn phản ánh đặc điểm của một tập bệnh nhân và quy trình thu thập cụ thể — mà chưa được kiểm chứng trên dữ liệu lâm sàng thực tế hay các bộ dữ liệu khác với điều kiện thu nhận ảnh khác biệt. Do đó, khả năng tổng quát hóa của mô hình vẫn cần được xác minh thêm, và hệ thống hiện tại chỉ dừng ở mục tiêu nghiên cứu, chưa trải qua kiểm định lâm sàng hay tích hợp vào quy trình khám chữa bệnh, cũng như không nhằm thay thế quyết định chuyên môn của bác sĩ.

Thứ hai, bộ dữ liệu ISIC 2024 có mức độ mất cân bằng lớp rất lớn, trong đó số lượng mẫu melanoma chỉ chiếm một tỷ lệ nhỏ so với các tổn thương lành tính. Mặc dù đồ án lựa chọn chỉ số pAUC để phù hợp với tiêu chí đánh giá của cuộc thi và áp dụng các chiến lược huấn luyện nhằm giảm ảnh hưởng của sự mất cân bằng, đây vẫn là một thách thức có ảnh hưởng đến khả năng học của mô hình, đặc biệt đối với lớp thiểu số.

Thứ ba, kết quả thực nghiệm cho thấy cơ chế Cross-Attention — kiến trúc được đề xuất ban đầu làm trọng tâm nghiên cứu — không vượt trội hơn phép kết hợp Concatenation đơn giản trên quy mô dữ liệu và cấu hình hiện tại của đồ án. Do giới hạn về thời gian và tài nguyên tính toán, đồ án chưa có điều kiện khảo sát liệu Cross-Attention có phát huy ưu thế trên quy mô dữ liệu lớn hơn, hoặc với các biến thể kiến trúc và chiến lược regularization khác. Vì vậy, kết luận về việc lựa chọn cơ chế kết hợp tối ưu chỉ có giá trị trong phạm vi thực nghiệm của đồ án.

Thứ tư, do giới hạn tài nguyên tính toán (Kaggle Notebook, GPU T4 16GB), đồ án chưa thực hiện huấn luyện ensemble đa mô hình (kết hợp nhiều backbone hoặc nhiều fold dự đoán độc lập) — một kỹ thuật phổ biến ở các giải pháp top đầu của cuộc thi. Ngoài ra, backbone hình ảnh sử dụng trong đồ án (EfficientNet-B0) có quy mô tham số khiêm tốn hơn so với các kiến trúc lớn hơn (ConvNeXt, EVA02) được một số giải pháp khác áp dụng.

Thứ năm, bộ đặc trưng từ kiến thức miền y khoa (KFE) được thiết kế thủ công dựa trên tri thức da liễu hiện có (ABCD, Ugly Duckling, Patient Normalization). Cách tiếp cận này, dù mang lại cải thiện hiệu suất đáng kể, có thể giới hạn khả năng mở rộng của mô hình khi áp dụng cho các bộ dữ liệu có cấu trúc metadata khác hoặc thiếu các trường thông tin cần thiết để tính toán các đặc trưng này.

Cuối cùng, mặc dù đồ án đã triển khai Grad-CAM để trực quan hóa vùng ảnh ảnh hưởng đến quyết định của nhánh hình ảnh, độ tin cậy của các bản đồ nhiệt (heatmap) thu được cần được xem xét thận trọng. Do hiệu suất của nhánh hình ảnh độc lập còn khiêm tốn (pAUC = 0.13873, thấp hơn nhánh dữ liệu bảng), các vùng được Grad-CAM làm nổi bật có thể chưa phản ánh chính xác đặc điểm lâm sàng thực sự của tổn thương, mà một phần đến từ các tương quan giả mà mô hình học được trên tập dữ liệu huấn luyện. Do đó, kết quả Grad-CAM trong đồ án nên được xem như một công cụ tham khảo bước đầu, chưa đủ độ tin cậy để sử dụng làm căn cứ diễn giải lâm sàng.

5.3 Hướng phát triển

Từ những kết quả và hạn chế đã trình bày, đồ án vẫn còn nhiều hướng có thể tiếp tục nghiên cứu và phát triển trong tương lai nhằm nâng cao hiệu quả của mô hình cũng như khả năng ứng dụng trong thực tế:

Trước hết, mô hình cần được đánh giá trên nhiều bộ dữ liệu khác ngoài ISIC 2024, bao gồm dữ liệu thu thập từ môi trường lâm sàng thực tế, để kiểm chứng khả năng tổng quát hóa trước sự khác biệt về thiết bị chụp, điều kiện thu nhận ảnh và đặc điểm của từng nhóm bệnh nhân. Đây là bước cần thiết trước khi xem xét khả năng tích hợp mô hình vào quy trình hỗ trợ khám chữa bệnh trong thực tế.

Về vấn đề mất cân bằng lớp, các nghiên cứu tiếp theo có thể khảo sát thêm các kỹ thuật xử lý chuyên sâu hơn, như focal loss có điều chỉnh theo pAUC, các phương pháp sinh dữ liệu tổng hợp cho lớp thiểu số (ví dụ: sinh ảnh tổn thương ác tính bằng mô hình khuếch tán), hoặc chiến lược lấy mẫu động (dynamic sampling) tinh vi hơn, nhằm cải thiện khả năng học đặc trưng của lớp **ác tính (malignant)**.

Liên quan đến cơ chế kết hợp đa phương thức, cần tiếp tục khảo sát hiệu quả của Cross-Attention trên quy mô dữ liệu lớn hơn hoặc với các biến thể kiến trúc và chiến lược regularization khác, nhằm xác định rõ điều kiện mà cơ chế này thực sự phát huy ưu thế so với phép kết hợp Concatenation đơn giản.

Bên cạnh việc mở rộng dữ liệu và kiến trúc, các nghiên cứu tiếp theo có thể tập trung vào việc huấn luyện ensemble đa mô hình (kết hợp nhiều backbone hoặc nhiều fold dự đoán độc lập) và thử nghiệm các backbone hình ảnh có quy mô tham số lớn hơn (ConvNeXt, EVA02), trong điều kiện tài nguyên tính toán cho phép. Song song đó, cần tối ưu kiến trúc nhằm giảm số lượng tham số và rút ngắn thời gian suy luận, tạo điều kiện thuận lợi cho việc triển khai trên các hệ thống có cấu hình hạn chế.

Đối với bộ đặc trưng kỹ nghệ (KFE), có thể nghiên cứu các phương pháp tự động hóa một phần quá trình trích xuất đặc trưng dựa trên tri thức miền (ví dụ: học biểu diễn có giám sát yếu từ các quy tắc lâm sàng), nhằm giảm sự phụ thuộc vào thiết kế thủ công và tăng khả năng thích ứng khi áp dụng cho các bộ dữ liệu có cấu trúc metadata khác.

Về khả năng giải thích, cần tiếp tục cải thiện độ tin cậy của cơ chế Grad-CAM đã được tích hợp trong đồ án, thông qua việc nâng cao hiệu suất của nhánh hình ảnh (backbone lớn hơn, quy mô dữ liệu huấn luyện lớn hơn, hoặc attention có giám sát). Đồng thời, có thể bổ sung SHAP đối với nhánh dữ liệu bảng để cung cấp góc nhìn giải thích toàn diện hơn, giúp đối chiếu và xác thực lẫn nhau giữa hai cơ chế giải thích trên hai phương thức dữ liệu.

Về mặt triển khai hệ thống, mô hình có thể được tích hợp thành một dịch vụ suy luận thông qua Backend Inference API, cho phép tiếp nhận dữ liệu đầu vào, thực hiện dự đoán và trả về kết quả cho các ứng dụng bên ngoài. Trên cơ sở đó, có thể phát triển một giao diện người dùng trực quan hỗ trợ bác sĩ hoặc nhân viên y tế trong quá trình sàng lọc tổn thương da, giúp việc sử dụng mô hình trong thực tế trở nên thuận tiện hơn.

Nhìn chung, hướng tiếp cận kết hợp dữ liệu hình ảnh, metadata và kiến thức miền trong đồ án là nền tảng cho nhiều hướng nghiên cứu tiếp theo. Việc tiếp tục hoàn thiện mô hình, mở rộng dữ liệu và phát triển hệ thống theo hướng có khả năng giải thích và hỗ trợ triển khai thực tế sẽ góp phần nâng cao giá trị ứng dụng của các hệ thống hỗ trợ phát hiện sớm ung thư da trong tương lai.

Chương A

Phụ lục

A.1 Danh mục biến metadata gốc của ISIC 2024

Bảng A.1 liệt kê chi tiết toàn bộ thuộc tính metadata gốc có mặt đồng thời ở tập huấn luyện và tập kiểm tra của ISIC 2024, được tổng hợp từ tài liệu mô tả bộ dữ liệu chính thức trên Kaggle.

Bảng A.1: Danh mục biến metadata gốc (khả dụng ở cả train và test) — ISIC 2024.

Tên biến	**Nhóm**	**Mô tả**
`isic_id`	Định danh	Mã định danh duy nhất cho mỗi ảnh/mẫu.
`patient_id`	Định danh	Mã định danh duy nhất cho mỗi bệnh nhân, dùng để nhóm fold và tính các đặc trưng patient-level.
`attribution`	Định danh	Nguồn cung cấp ảnh (bệnh viện/tổ chức đóng góp dữ liệu).
`copyright_license`	Định danh	Giấy phép bản quyền của ảnh.
`image_type`	Định danh	Loại ảnh theo phân loại chuẩn của kho lưu trữ ISIC.
`tbp_tile_type`	Định danh	Chế độ chiếu sáng khi chụp ảnh gốc bằng hệ thống 3D-TBP.
`age_approx`	Nhân khẩu học	Tuổi xấp xỉ của bệnh nhân tại thời điểm chụp.
`sex`	Nhân khẩu học	Giới tính bệnh nhân.
`anatom_site_general`	Vị trí lâm sàng	Vị trí giải phẫu tổng quát của tổn thương trên cơ thể.
`clin_size_long_diam_mm`	Vị trí lâm sàng	Đường kính dài nhất của tổn thương (mm).

Bảng A.1 — (tiếp theo)

Tên biến	Nhóm	Mô tả
tbp_lv_location	Vị trí lâm sàng	Vị trí giải phẫu chi tiết (tay/chân chia trên–dưới, thân chia ba phần).
tbp_lv_location_simple	Vị trí lâm sàng	Vị trí giải phẫu ở dạng rút gọn.
tbp_lv_x	Toạ độ 3D-TBP	Toạ độ X của tổn thương trên bản đồ 3D toàn thân.
tbp_lv_y	Toạ độ 3D-TBP	Toạ độ Y của tổn thương trên bản đồ 3D toàn thân.
tbp_lv_z	Toạ độ 3D-TBP	Toạ độ Z của tổn thương trên bản đồ 3D toàn thân.
tbp_lv_L	Màu sắc LAB*	Độ sáng (L) trung bình bên trong tổn thương.
tbp_lv_Lext	Màu sắc LAB*	Độ sáng (L) trung bình vùng da xung quanh tổn thương.
tbp_lv_A	Màu sắc LAB*	Thành phần A (trục xanh lá–đỏ) bên trong tổn thương.
tbp_lv_Aext	Màu sắc LAB*	Thành phần A bên ngoài tổn thương.
tbp_lv_B	Màu sắc LAB*	Thành phần B (trục xanh dương–vàng) bên trong tổn thương.
tbp_lv_Bext	Màu sắc LAB*	Thành phần B bên ngoài tổn thương.
tbp_lv_C	Màu sắc LAB*	Độ bão hoà màu (Chroma) bên trong tổn thương.
tbp_lv_Cext	Màu sắc LAB*	Độ bão hoà màu bên ngoài tổn thương.
tbp_lv_H	Màu sắc LAB*	Sắc độ (Hue) bên trong tổn thương, tính theo góc của A* và B* (khoảng 25–75: đỏ đến nâu).
tbp_lv_Hext	Màu sắc LAB*	Sắc độ bên ngoài tổn thương.
tbp_lv_stdL	Màu sắc LAB*	Độ lệch chuẩn của L bên trong tổn thương.

Bảng A.1 — (tiếp theo)

Tên biến	Nhóm	Mô tả
tbp_lv_stdLExt	Màu sắc LAB*	Độ lệch chuẩn của L bên ngoài tổn thương.
tbp_lv_deltaA	Tương phản màu	Chênh lệch trung bình thành phần A giữa trong và ngoài tổn thương.
tbp_lv_deltaB	Tương phản màu	Chênh lệch trung bình thành phần B giữa trong và ngoài tổn thương.
tbp_lv_deltaL	Tương phản màu	Chênh lệch trung bình độ sáng L giữa trong và ngoài tổn thương.
tbp_lv_deltaLB	Tương phản màu	Độ tương phản màu sắc (thành phần L và B kết hợp) chênh lệch giữa trong và ngoài tổn thương.
tbp_lv_deltaLBnorm	Tương phản màu	Độ tương phản chuẩn hoá giữa tổn thương và vùng da lân cận trong không gian LAB*; giá trị thấp ứng với tổn thương mờ nhạt (như tàn nhang), giá trị cao ứng với sắc tố đậm.
tbp_lv_color_std_mean	Tương phản màu	Độ bất thường màu, đo bằng phương sai màu trong ranh giới tổn thương.
tbp_lv_radial_color_std_max	Tương phản màu	Độ bất đối xứng phân bố màu, tính từ độ lệch chuẩn LAB* theo các vòng tròn đồng tâm quanh trọng tâm tổn thương.
tbp_lv_norm_color	Tương phản màu	Chỉ số biến thiên màu tổng hợp (chuẩn hoá thang 0- -10), trung bình giữa bất đối xứng và bất thường màu.
tbp_lv_areaMM2	Hình thái & kích thước	Diện tích tổn thương (mm^2).
tbp_lv_perimeterMM	Hình thái & kích thước	Chu vi tổn thương (mm).

Bảng A.1 — (tiếp theo)

Tên biến	Nhóm	Mô tả
tbp_lv_area_perim_ratio	Hình thái & kích thước	Chỉ số tỷ lệ diện tích / chu vi tổn thương.
tbp_lv_minorAxisMM	Hình thái & kích thước	Đường kính ngắn nhất của tổn thương (mm).
tbp_lv_eccentricity	Hình thái & kích thước	Độ lệch tâm hình học của tổn thương.
tbp_lv_symm_2axis	Hình thái & kích thước	Độ bất đối xứng viền quanh trục đối xứng thứ hai (vuông góc với trục đối xứng chính); tổn thương có 2 trục đối xứng cho giá trị thấp.
tbp_lv_symm_2axis_angle	Hình thái & kích thước	Góc của trục bất đối xứng viền.
tbp_lv_norm_border	Hình thái & kích thước	Chỉ số bất thường viền tổng hợp (chuẩn hoá thang 0–10), trung bình giữa độ nham nhở và độ bất đối xứng viền.
tbp_lv_nevi_confidence	Điểm tin cậy AI	Xác suất (thang 0–100) tổn thương là nốt ruồi lành tính, ước lượng bởi một mạng CNN huấn luyện trên ~57.000 tổn thương đã được bác sĩ da liễu gán nhãn.

Ghi chú: Ngoài các biến trên, tập huấn luyện còn chứa thêm các cột chỉ có ở train (target, lesion_id, iddx_full, iddx_1–iddx_5, mel_mitotic_index, mel_thick_mm, tbp_lv_dnn_lesion_confidence) — đây là các thuộc tính liên quan trực tiếp đến nhãn chẩn đoán hoặc không tồn tại ở tập test, nên bị loại bỏ để tránh rò rỉ dữ liệu trước khi đưa vào bước Knowledge-guided Feature Engineering.

A.2 Mã nguồn dự án

Toàn bộ mã nguồn cài đặt của đồ án, bao gồm các thành phần tiền xử lý dữ liệu, Knowledge-guided Feature Engineering (KFE), huấn luyện các nhánh mô hình (EfficientNet-B0, TabM), các cơ chế fusion (Concatenation, Cross-Attention, GMU), notebook thực nghiệm

và đánh giá, cũng như ứng dụng demo minh hoạ hệ thống, được công khai tại kho lưu trữ GitHub sau:

`https://github.com/khoadz2609/skin-cancer-screening-system`

Tài liệu tham khảo

[1] World Health Organization,"Radiation: Ultraviolet (UV) radiation and skin cancer," *WHO Q&A*, 2017. [Online]. Available: https://www.who.int/news-room/questions-and-answers/item/radiation-ultraviolet-(uv)-radiation-and-skin-cancer. [Accessed: Jul. 10, 2026].

[2] International Agency for Research on Cancer (IARC), "Global Cancer Observatory (GLOBOCAN)," *IARC*, 2024. [Online]. Available: https://gco.iarc.who.int/. [Accessed: Jul. 10, 2026].

[3] American Cancer Society, "Survival Rates for Melanoma Skin Cancer, by Stage," *American Cancer Society*, 2024. [Online]. Available: https://www.cancer.org/cancer/types/melanoma-skin-cancer/detection-diagnosis-staging/survival-rates-for-melanoma-skin-cancer-by-stage.html. [Accessed: Jul. 10, 2026].

[4] N. R. Kurtansky, M. C. Gillis, N. C. F. Codella, et al., "Automated triage of cancer-suspicious skin lesions with 3D total-body photography," *npj Digital Medicine*, Vol. 8, No. 12, 2025.

[5] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, "Dermatologist-level classification of skin cancer with deep neural networks," *Nature*, Vol. 542, No. 7639, pp. 115–118, 2017.

[6] C. Carrera, M. A. Marchetti, S. W. Dusza, et al., "Validity and Reliability of Dermoscopic Criteria Used to Differentiate Nevi From Melanoma: A Web-Based International Dermoscopy Society Study," *JAMA Dermatology*, Vol. 152, No. 7, pp. 798–806, 2016.

[7] J. J. Grob and J. J. Bonerandi, "The Ugly Duckling Sign: Identification of the Common Characteristics of Nevi in an Individual as a Basis for Melanoma Screening," *Archives of Dermatology*, Vol. 134, No. 1, pp. 103–104, 1998.

[8] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on tabular data?," *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 35, pp. 507–520, 2022.

[9] Y. Gorishniy, A. Kotelnikov, and A. Babenko, “TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling,” *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[10] F. Nachbar, W. Stolz, T. Merkle, et al., “The ABCD rule of dermatoscopy: high prospective value in the diagnosis of doubtful melanocytic skin lesions,” *Journal of the American Academy of Dermatology*, Vol. 30, No. 4, pp. 551–559, 1994.

[11] S. M. Swetter, H. Tsao, C. K. Bichakjian, et al., “Guidelines of care for the management of primary cutaneous melanoma,” *Journal of the American Academy of Dermatology*, Vol. 80, No. 1, pp. 208–250, 2019.

[12] R. J. Friedman, D. S. Rigel, and A. W. Kopf, “Early detection of malignant melanoma: The role of physician examination and self-examination of the skin,” *CA: A Cancer Journal for Clinicians*, Vol. 35, No. 3, pp. 130–151, 1985.

[13] American Cancer Society, “Signs and Symptoms of Melanoma Skin Cancer,” *American Cancer Society*, 2024. [Online]. Available: `https://www.cancer.org/cancer/types/melanoma-skin-cancer/detection-diagnosis-staging/signs-and-symptoms.html`. [Accessed: Jul. 10, 2026].

[14] Y. Bengio, A. Courville, and P. Vincent, “Representation Learning: A Review and New Perspectives,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 35, No. 8, pp. 1798–1828, 2013.

[15] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, “Multimodal Machine Learning: A Survey and Taxonomy,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 41, No. 2, pp. 423–443, 2019.

[16] S. Ö. Arik and T. Pfister, “TabNet: Attentive Interpretable Tabular Learning,” *Proc. AAAI Conference on Artificial Intelligence*, Vol. 35, No. 8, pp. 6679–6687, 2021.

[17] Y. Gorishniy, I. Rubachev, V. Khrulkov, and A. Babenko, “Revisiting Deep Learning Models for Tabular Data,” *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 34, pp. 18932–18943, 2021.

[18] Y. Gorishniy, I. Rubachev, A. Targonski, et al., “TabR: Tabular Deep Learning Meets Nearest Neighbors,” *Proc. International Conference on Learning Representations (ICLR)*, 2024.

[19] A. Vaswani, N. Shazeer, N. Parmar, et al., “Attention Is All You Need,” *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 30, 2017.

[20] T. Fawcett, “An Introduction to ROC Analysis,” *Pattern Recognition Letters*, Vol. 27, No. 8, pp. 861–874, 2006.

[21] J. A. Hanley and B. J. McNeil, “The Meaning and Use of the Area Under a ROC Curve,” *Radiology*, Vol. 143, No. 1, pp. 29–36, 1982.

[22] A. G. C. Pacheco and R. A. Krohling, “An Attention-Based Mechanism to Combine Images and Metadata in Deep Learning Models Applied to Skin Cancer Classification,” *IEEE Journal of Biomedical and Health Informatics*, Vol. 25, No. 9, pp. 3554–3563, 2021.

[23] P. Rouzrokh, B. Khosravi, S. Faghani, et al., “Mitigating Bias in Radiology Machine Learning: 1. Data Handling,” *Radiology: Artificial Intelligence*, Vol. 4, No. 5, e210290, 2022.

[24] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, “LOF: Identifying Density-Based Local Outliers,” *Proc. ACM SIGMOD International Conference on Management of Data*, pp. 93–104, 2000.

[25] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, et al., “Albumentations: Fast and Flexible Image Augmentations,” *Information*, Vol. 11, No. 2, p. 125, 2020.

[26] Z. Liu, H. Mao, C.-Y. Wu, et al., “A ConvNet for the 2020s,” *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11976–11986, 2022.

[27] J. Arevalo, T. Solorio, M. Montes-y-Gómez, and F. A. González, “Gated Multimodal Units for Information Fusion,” *arXiv preprint arXiv:1702.01992*, 2017.

[28] N. Wu, S. Jastrzębski, K. Cho, and K. J. Geras,“Characterizing and Overcoming the Greedy Nature of Learning in Multi-modal Deep Neural Networks,” *Proc. 39th International Conference on Machine Learning (ICML)*, PMLR 162, pp. 24043–24055, 2022.

[29] J. Tang, Y. Xu, Y. Liu, and Q. Chen, “Shaping Initial State Prevents Modality Competition in Multi-modal Fusion: A Two-stage Scheduling Framework via Fast Partial Information Decomposition,” *arXiv preprint arXiv:2509.20840*, 2025.

[30] G. D. Finlayson and E. Trezzi, “Shades of Gray and Colour Constancy,” *Proc. Color and Imaging Conference (CIC)*, pp. 37–41, 2004.

[31] D. K. McClish, “Analyzing a Portion of the ROC Curve,” *Medical Decision Making*, Vol. 9, No. 3, pp. 190–195, 1989.

[32] American Cancer Society, “Key Statistics for Melanoma Skin Cancer,” *American Cancer Society*, 2024. [Online]. Available: `https://www.cancer.org/cancer/types/melanoma-skin-cancer/about/key-statistics.html`. [Accessed: Jul. 10, 2026].