ĐẠI HỌC QUỐC GIA TP.HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN – TIN

KHOA TOÁN - TIN HỌC
FACULTY OF MATHEMATICS
AND COMPUTER SCIENCE

Xây dựng hệ thống hỗ trợ chẩn đoán khả năng mắc bệnh ung thư da

Đồ án tốt nghiệp cử nhân — Chuyên ngành khoa học dữ liệu

Sinh viên thực hiện: Nguyễn Lê Đăng Khoa & Phan Gia Thiên

Giảng viên hướng dẫn: TS. Huỳnh Thế Đăng

Tp Hồ Chí Minh, 2026

Ung thư da & Phát hiện sớm

- **Melanoma (Ung thư hắc tố):** Chỉ chiếm khoảng **~1%** số ca ung thư da nhưng lại gây ra **phần lớn tử vong** do đặc tính di căn cực nhanh.
- **Quyết định sống còn:** Nếu được phát hiện sớm khi còn khu trú, tỷ lệ sống sót sau 5 năm đạt **> 99%**.



- **Phương pháp chẩn đoán hiện tại:** Phụ thuộc vào khám lâm sàng của bác sĩ kết hợp soi da (dermoscopy), theo dõi định kỳ và sinh thiết khi có nghi ngờ cao.

Thách thức & Công nghệ 3D-TBP

Thách Thức:

- Hình thái các nốt ruồi ác tính và lành tính có sự **tương đồng rất cao**.
- Một bệnh nhân có nguy cơ cao có thể mang **hàng trăm đến hàng nghìn nốt**, gây quá tải cho việc theo dõi thủ công.
- Kết quả phụ thuộc nhiều vào tính **chủ quan và kinh nghiệm** của từng bác sĩ.
- Bác sĩ cần **bối cảnh bệnh nhân toàn diện** để so sánh, không chỉ nhìn một nốt đơn lẻ.



⟹**Công nghệ 3D-TBP (Total Body Photography):** Chụp toàn thân 3D cung cấp đồng thời hình ảnh sắc nét và metadata phong phú (vị trí, kích thước). Đây là nền tảng của bộ dữ liệu **ISIC 2024.**

Vấn đề còn bỏ ngỏ

Hạn chế của hướng tiếp cận cũ

Đa số các nghiên cứu trước đây chỉ sử dụng hướng tiếp cận **Image-only**. Mô hình coi mỗi tổn thương là một thực thể hoàn toàn độc lập, tách rời khỏi tình trạng chung của bệnh nhân.

⟹Điều này làm mất đi góc nhìn tổng thể quan trọng mà các bác sĩ lâm sàng luôn sử dụng khi chẩn đoán.

Nhu cầu khai thác tri thức y khoa

Dữ liệu Metadata (Tuổi, giới tính, vị trí nốt...) nếu chỉ đưa vào mô hình dưới dạng **dữ liệu thô là chưa đủ** để phân loại hiệu quả.

Khoảng trống lớn nhất là làm sao để mã hóa các **tri thức y khoa** thành các đặc trưng toán học, từ đó kết hợp với hình ảnh tạo thành hệ thống **học sâu đa phương thức** toàn diện.

Mục tiêu, Vai trò và Đóng góp

Mục tiêu: Xây dựng mô hình học sâu đa phương thức (kết hợp cả Ảnh và dữ liệu Bảng) trên tập dữ liệu quy mô lớn ISIC 2024.

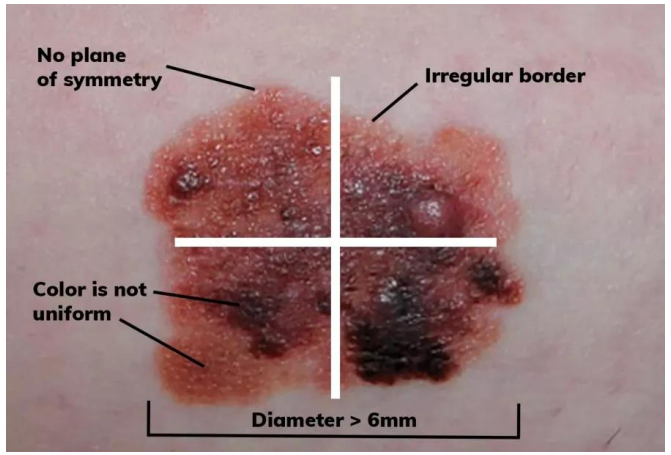
Vai trò hệ thống: Đóng vai trò là công cụ **SÀNG LỌC (Triage)**, giúp gợi ý và đẩy các tổn thương có nguy cơ cao lên đầu danh sách để bác sĩ ưu tiên soi da/sinh thiết. Hệ thống **không thay thế** quyết định lâm sàng của bác sĩ.



Các đóng góp:

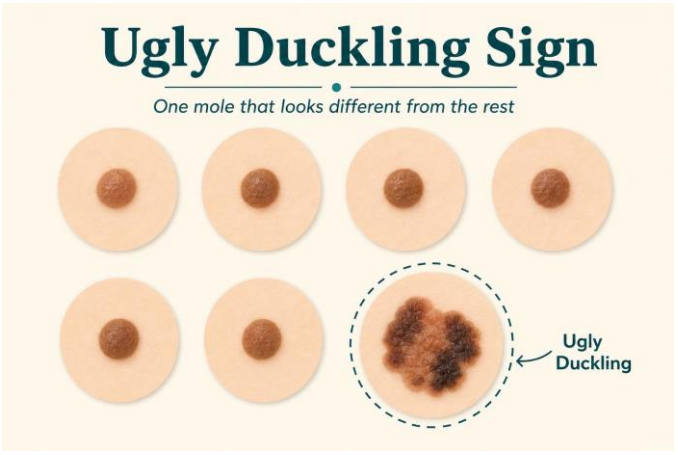
- **Knowledge-guided Feature Engineering (KFE)** – Số hóa thành công các quy tắc và tri thức da liễu thành đặc trưng máy học.
- **Patient Representation** – Học biểu diễn bệnh nhân từ metadata bằng kiến trúc mạng TabM tiên tiến.
- **Mô hình Multimodal & Ablation Study** – Khảo sát đa phương thức và có báo cáo định lượng chi tiết cho từng thành phần (Ablation).

Tri thức miền định hướng đặc trưng



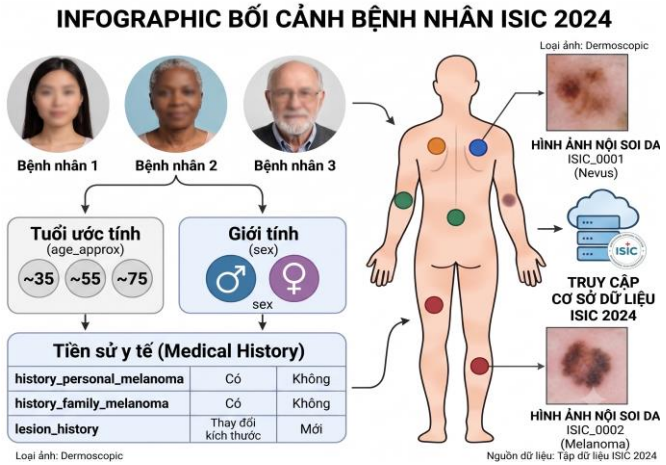
Quy tắc ABCDE

Tri thức cấp độ **từng tổn thương**. Dựa trên hình thái: Asymmetry (Bất đối xứng), Border (Bờ), Color (Màu sắc), Diameter (Đường kính).



Ugly Duckling Sign

Tri thức cấp độ **so sánh trong bệnh nhân**. Dựa trên nguyên lý "Vịt con xấu xí": Tổn thương khác biệt nhất so với phần còn lại là nguy hiểm nhất.



Patient Context

Tri thức cấp độ **toàn bộ bệnh nhân**. Khai thác sự tương quan về tuổi tác, giới tính, tiền sử bệnh lý và vùng giải phẫu tổng thể.

Lưu ý: Tri thức không dùng làm luật phân loại cứng, chỉ dùng định hướng trích xuất đặc trưng Feature Engineering.

Học sâu cho dữ liệu bảng & Multimodal

TabM (ICLR 2025)

- TabM mô phỏng một **Ensemble gồm 32 mô hình con** hoạt động đồng thời bên trong chỉ một mạng neural duy nhất.
- Khả năng vượt trội: Chống Overfit hiệu quả với dữ liệu mất cân bằng, giữ số lượng tham số ở mức thấp. Quan trọng nhất, nó có khả năng **học biểu diễn** để trích xuất vector đặc trưng ghép với nhánh ảnh (điều mà các mô hình GBDT không làm trực tiếp được).

Chiến lược kết hợp (Fusion)

Khảo sát toàn diện 3 chiến lược kết hợp hai luồng thông tin (Ảnh + Bảng):

- **Concatenation:** Nối trực tiếp các biểu diễn vector.
- **Gated Multimodal Unit (GMU):** Cổng điều khiển luồng thông tin linh hoạt.
- **Cross-Attention:** Chú ý chéo hai chiều (phương thức này làm Query để định hướng vùng chú ý trên phương thức kia làm Key, Value.

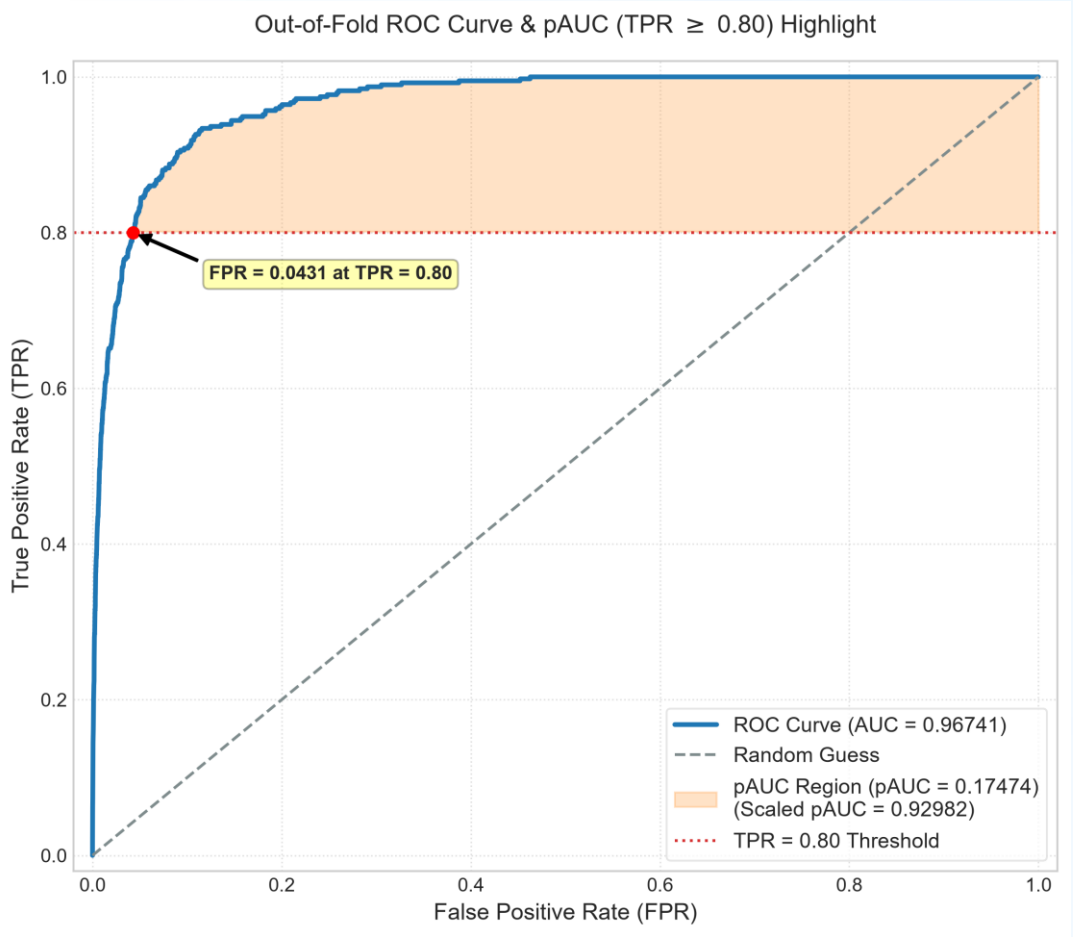
Vì sao dùng pAUC

Dữ liệu y tế trong bài toán này **mất cân bằng cực đoan** (< 0.1% dương tính). Nếu dùng Accuracy, mô hình chỉ cần đoán 100% "Âm tính" cũng đạt độ chính xác > 99.9% nhưng hoàn toàn vô dụng.

⟹**Việc bỏ sót một ca ung thư nguy hiểm hơn rất nhiều so với một báo động giả**. Báo động giả bác sĩ có thể loại trừ, nhưng bỏ sót có thể đe dọa tính mạng.

Chỉ số pAUC (Partial AUC): Thay vì tính toàn bộ đường cong ROC, pAUC chỉ tính diện tích ở vùng **Độ nhạy cực cao (TPR ≥ 80%)**.

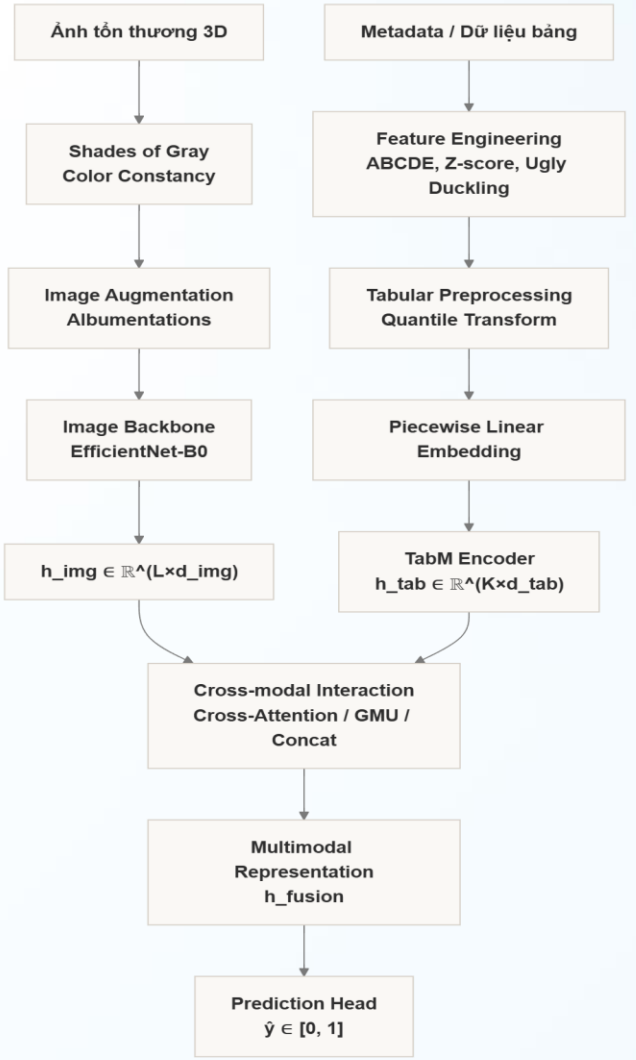
⟹Điều này bắt buộc mô hình phải hoạt động tốt ngay cả khi phải "hy sinh" để đảm bảo bắt được ít nhất 80% số ca bệnh thực sự.



Kiến trúc hệ thống đề xuất

- **Huấn luyện độc lập (Independent Training):** Nhánh bảng (TabM) và Nhánh ảnh (EfficientNet) được huấn luyện riêng biệt song song để tối ưu hóa khả năng biểu diễn của từng nguồn dữ liệu.

- **Kết hợp đa phương thức (Multimodal Fusion):** Ghép nối và trao đổi thông tin giữa các vector đặc trưng đã tối ưu từ hai nhánh ở giai đoạn sau (qua Cross-Attention, Concat, hoặc GMU) để đưa ra dự đoán cuối cùng.



Bộ dữ liệu & Giao thức chống rò rỉ

401K

Tổng số mẫu tổn thương

393

Số ca Ác tính (< 0.1%)

Khắc phục rào cản kỹ thuật & Dữ liệu

- **Phân tách theo Bệnh nhân**: Gom toàn bộ tổn thương của mỗi người vào chung một fold → Tránh mô hình học thuộc đặc tính da nền.
- **Tiền xử lý độc lập**: Chỉ tính toán các thống kê chuẩn hóa trên tập huấn luyện → Ngăn mô hình nhìn trước dữ liệu tập kiểm thử.
- **Lấy mẫu dưới (Undersampling)** động: Giữ nguyên mẫu dương, làm mới ngẫu nhiên tập mẫu âm sau mỗi vòng lặp huấn luyện → Khắc phục mất cân bằng lớp cực đoan (<0.1%).

Pipeline nhánh bảng

Pipeline Nhánh Bảng

Đầu vào: 615 đặc trưng sau quá trình KFE.

Mã hóa: Chuẩn hoá phân phối ⟹ *Piecewise Linear Embedding (PLE)* để ánh xạ biến liên tục thành không gian vector phi tuyến.

Backbone: Đưa vào mạng **TabM** cấu hình ensemble K=32 thành viên để tạo vector biểu diễn bệnh nhân.

Nhóm Đặc Trưng	Số lượng	Tri thức / Cơ sở y khoa
Base Features	34	Metadata gốc (Tuổi, giới tính, vị trí, kích thước thô)
ABCD Rules	69	Hình thái tổn thương biên, màu sắc, đối xứng
Patient Norm	109	Tính toán qua Z-Score
UD Advanced	116	Dò nốt ngoại lai bằng (LOO + LOF + summary)
Categorical Context	318	Tương tác chéo giữa các vùng giải phẫu trên cơ thể
Cat. Embeddings	5	Integer codes + Categorical embedding

Pipeline nhánh ảnh

Pipeline Nhánh Ảnh

Chuẩn hóa ánh sáng: Thuật toán *Shades of Gray* để loại bỏ ảnh hưởng từ môi trường ánh sáng phòng khám khác nhau.

Tăng cường dữ liệu (Augmentation): Lật, xoay, thay đổi độ tương phản ngẫu nhiên để tăng tính khái quát.

Backbone: Trích xuất đặc trưng sâu bằng kiến trúc mạng **EfficientNet-B0** cân bằng giữa tốc độ và độ chính xác.

Nhóm biến đổi	Phép biến đổi cụ thể	Tham số chính	Xác suất
Không gian học	Transpose, HorizontalFlip, VerticalFlip	---	0.5
Hình học affine	ShiftScaleRotate	shift=0.1, scale=0.1, rotate=15°	0.5
Cân bằng sáng	RandomBrightnessContrast	brightness=0.2, contrast=0.2	0.75
Biến đổi màu	HueSaturationValue	hue=10, sat=20, val=10	0.5
Cân bằng Histogram	CLAHE	clip_limit=4.0	0.5
Bộ lọc làm mờ	OneOf[MotionBlur, MedianBlur, GaussianBlur, GaussNoise]	blur_limit=5	0.3
Che lấp cấu trúc	CoarseDropout	max_holes=1, kích thước max 12% ảnh	0.4
Chuẩn hóa	Normalize	ImageNet mean/std	1.0

Chiến lược kết hợp đa phương thức

	Concatenation (Nối trực tiếp)	Gated Multimodal Unit (GMU)	Cross-Attention
Cơ chế	Nối cơ học hai vector đặc trưng tĩnh sau khi được trích xuất từ 2 nhánh.	Sử dụng cơ chế cổng (gating) để tự động quyết định tỷ lệ đóng góp của từng nhánh.	Trao đổi thông tin song phương chéo, ánh xạ mối tương quan giữa ảnh và bảng.
Công thức	$h_{fusion} = [h_{img}; h_{tab}]$	$z = \sigma(W_z[h_{img}; h_{tab}])$ $h_{fusion} = z \cdot \mathrm{h_{img}} + (1 - z) \cdot \mathrm{h_{tab}}$	**Luồng hoạt động song song:** 1. **Bảng →Ảnh:** Dùng đặc trưng Bảng (Q) định hướng sự tập trung trên các patch Ảnh (K, V). 2. **Ảnh→Bảng:** Dùng Ảnh (Q) truy vấn thông tin lâm sàng liên quan ở Bảng (K, V).
Ưu điểm	Giữ nguyên vẹn thông tin, không làm tăng tham số (tránh quá khớp).	Linh hoạt điều phối thông tin phù hợp cho từng ca bệnh cụ thể.	Học được tương tác phi tuyến phức tạp giữa tổn thương và ngữ cảnh bệnh nhân.

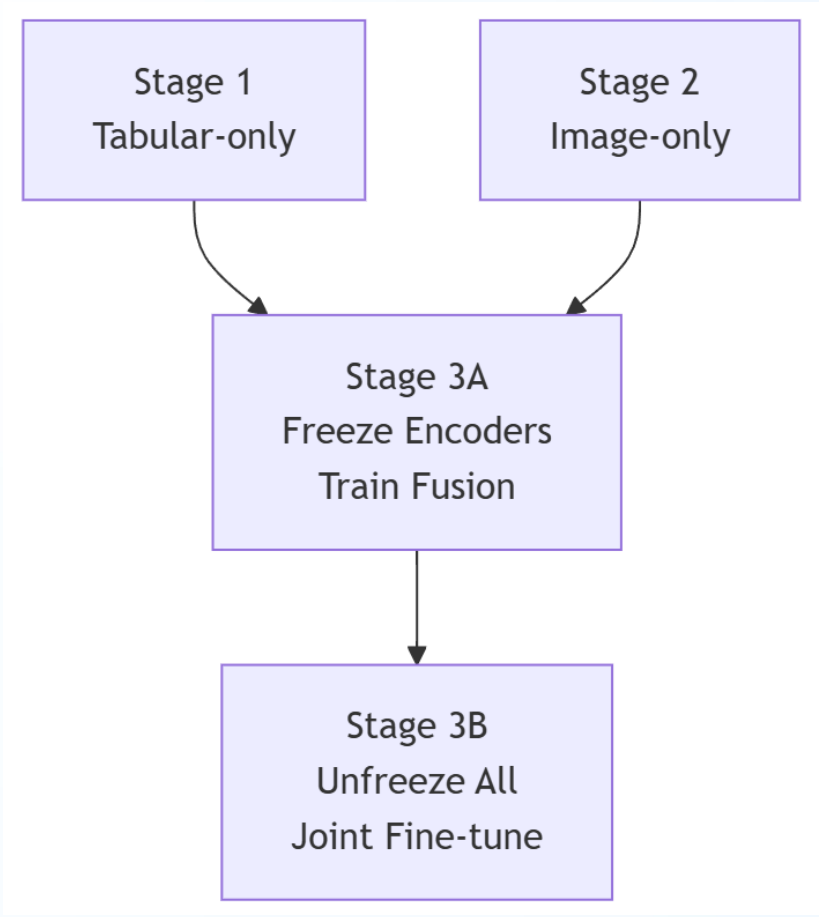
Huấn luyện phân tầng & Chống sụp đổ

Sụp đổ phương thức (Modality Collapse), mô hình chỉ bám nhánh dễ học và bỏ nhánh còn lại.
Giải pháp:

- Hàm mất mát phụ
- Modality Dropout
- Huấn luyện phân tầng

Lí do cho kiến trúc phân tầng:

- **Khắc phục tốc độ hội tụ chênh lệch:** Ép mô hình học đều cả hai nhánh ảnh và bảng, tránh hiện tượng "lười biếng".
- **Tối ưu hóa độc lập:** Giảm không gian tìm kiếm siêu tham số, tiết kiệm tài nguyên tuning.
- **Bảo vệ trọng số (Stage 3A):** Khởi động an toàn cho mạng Fusion, tránh làm nhiễu loạn các đặc trưng đã học trước khi tinh chỉnh toàn mạng (Stage 3B).



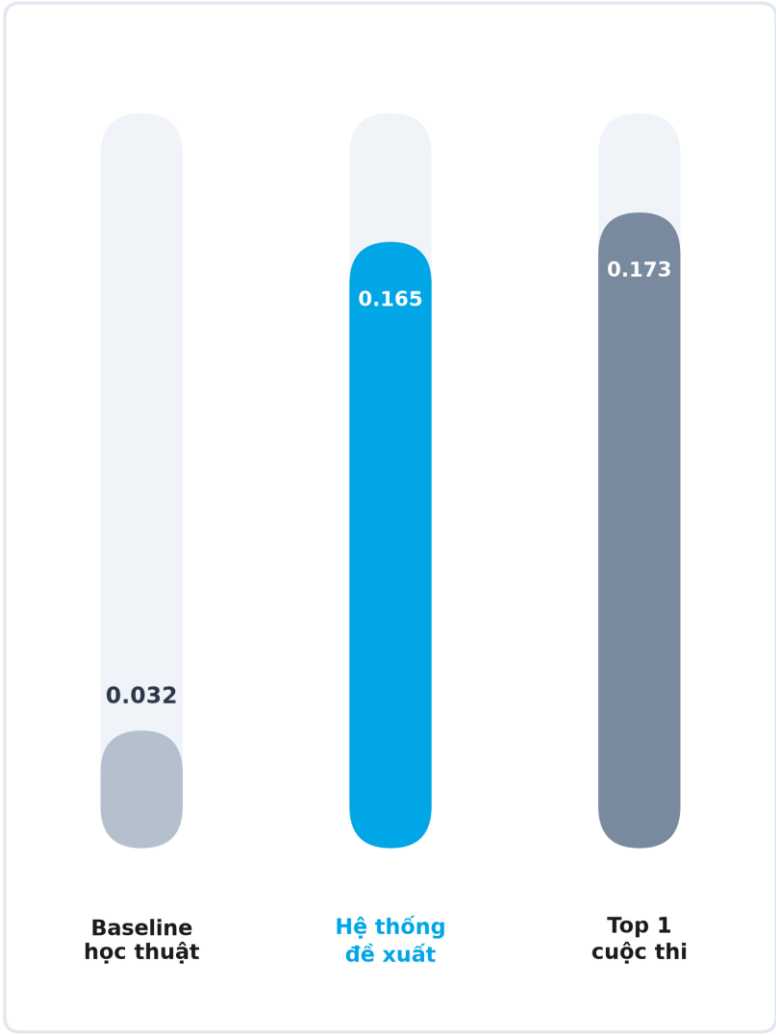
Kết quả pAUC trên tập kiểm tra

Phiên bản thử nghiệm	Nguồn Dữ Liệu	Chỉ số pAUC (↑)
Baseline ảnh (EfficientNet)	Chỉ Hình ảnh	0.13873
Baseline bảng	Chỉ Metadata	0.13920
TabM + KFE	Chỉ Metadata	**0.15853 (+13.9%)**
Multimodal: Cross-Attention (End2End)	Ảnh + Bảng	0.16101
Multimodal: Gated Multimodal Unit	Ảnh + Bảng	0.16190
Multimodal: Cross-Attention (Staged)	Ảnh + Bảng	0.16365
Multimodal: Fusion Concat	Ảnh + Bảng	**0.16523**

Phân tích & So sánh tham chiếu

Phân tích:

- Các biến đổi đặc trưng dựa trên kiến thức miền về y khoa đã chứng minh được sự hữu ích của mình khi kết quả của mô hình khi thêm KFE đặt **0.15853** so với baseline chỉ **0.13920 .**
- Trái với kỳ vọng, phép nối **Concat (0.16523)** vượt qua **Cross-Attention (0.16365)**.
- Huấn luyện phân tầng (Staged) chứng minh tính thiết yếu khi nâng điểm số từ **0.16101** lên **0.16365**.



Kết luận & Hướng phát triển

Đúc kết cốt lõi

Khẳng định **đặc trưng tri thức KFE** là nhân tố cải thiện điểm số mạnh mẽ nhất. Kỹ thuật **Staged Training** giải quyết dứt điểm lỗi sụp đổ phương thức.

Hạn chế hệ thống

Hệ thống mới được xác thực trên duy nhất 1 bộ dữ liệu (ISIC 2024). Chưa thử nghiệm với các kiến trúc mô hình có số lượng tham số lớn, chưa sử dụng kỹ thuật Ensemble nhiều mô hình. Quá trình KFE vẫn cần thiết kế thủ công.

Hướng mở rộng

Mở rộng kiến trúc: Tích hợp các mô hình có số lượng tham số lớn
Tự động hoá trích xuất: Nghiên cứu các phương pháp học biểu diễn để giảm phụ thuộc vào thiết kế KFE thủ công.
Đa dạng hóa dữ liệu: Kiểm chứng trên các nguồn dữ liệu ngoại lai và ứng dụng mô hình tạo sinh để bổ sung ảnh lớp hiếm.

Trân trọng cảm ơn!

Cảm ơn Quý Hội đồng và Thầy Cô đã lắng nghe.

“AI không thay thế bác sĩ — AI đồng hành để không một sinh mệnh nào bị bỏ sót.”

Nguyễn Lê Đăng Khoa & Phan Gia Thiên